
Econometría I

Teoría, práctica y aplicaciones

ALESSIO GAGGERO

Recurso educativo abierto publicado por la
Facultad de Ciencias Económicas y Empresariales,
UNIVERSIDAD DE GRANADA

2026-06-02

Table of contents

Prefacio	1
Qué es este libro	1
Cómo está organizado el libro	1
Ediciones y licencia	2
Cómo utilizar los materiales fuente	2
Paquetes de R necesarios	2
Agradecimientos	2
1. Conceptos Iniciales	3
Objetivos de aprendizaje	3
Pregunta motivadora	3
1.1. ¿Qué es la Econometría?	3
1.2. El modelo econométrico	4
1.3. Usos de la econometría	5
1.4. Correlación no implica causalidad	5
1.5. Tipos de experimentos	6
1.6. Tipos de datos económicos	8
1.7. Práctica: exploración de datos económicos en R	9
Auto-evaluación	14
Ejercicios	16
2. El Modelo de Regresión Lineal Simple	19
Objetivos de aprendizaje	19
Pregunta empírica motivadora	19
2.1. Introducción	20
2.2. La Función de Regresión Poblacional	20
2.3. La Función de Regresión Muestral	21
2.4. Mínimos Cuadrados Ordinarios (MCO)	21
2.5. Los supuestos de Gauss–Markov para la RLS	26
2.6. Inssegadez de MCO	27
2.7. Varianzas muestrales de los estimadores MCO	27
2.8. El teorema de Gauss–Markov	28
2.9. Estimación de σ^2	28
2.10. Bondad de ajuste: R^2	29
2.11. Práctica: RLS en R	29
Auto-evaluación	38
Ejercicios	40
3. El Modelo de Regresión Lineal Múltiple	43
Objetivos de aprendizaje	43
Pregunta motivadora	43

3.1. Motivación: el problema de la regresión simple	43
3.2. El modelo RLM	44
3.3. Notación matricial	45
3.4. MCO en forma matricial	45
3.5. Supuestos de Gauss–Markov para RLM	46
3.6. Inssegadez de MCO (forma matricial)	47
3.7. Varianza de los estimadores MCO (forma matricial)	47
3.8. R^2 y R^2 ajustado	48
3.9. Sesgo de variable omitida (SVO)	48
3.10. Práctica: Regresión Múltiple en R	50
Auto-evaluación	55
Ejercicios	56
4. Inferencia	59
Objetivos	59
Pregunta motivadora	59
4.1. De la estimación a la inferencia	59
4.2. Los supuestos del Modelo Lineal Clásico (MLC)	60
4.3. La distribución t	61
4.4. Dos maneras de equivocarse	61
4.5. Intervalos de confianza	62
4.6. Contraste de hipótesis en cuatro pasos	63
4.7. El p -valor	63
4.8. El test F de significatividad conjunta	64
4.9. Práctica: Inferencia en R	66
Auto-evaluación	72
Ejercicios	74
5. Predicción y Selección de Modelos	77
Objetivos	77
Pregunta motivadora	77
5.1. Causalidad vs. predicción	78
5.2. Predicción puntual	78
5.3. Varianza de la predicción e intervalos de predicción	79
5.4. Predicción en RLM	81
5.5. Selección de modelos: R^2 , R^2 ajustado, AIC, BIC	81
5.6. Práctica: Predicción y Selección de Modelos en R	83
Auto-evaluación	88
Ejercicios	90
6. Relaciones No Lineales e Información Cualitativa	93
Objetivos	93
Pregunta motivadora	93
6.1. Relaciones no lineales en un modelo lineal	94
6.2. Modelos cuadráticos	94
6.3. Transformaciones logarítmicas	95
6.4. Términos de interacción	96
6.5. Variables ficticias	97
6.6. Test de Chow	98
6.7. Práctica A: formas no lineales en beauty (Tutorial 6)	99
6.8. Práctica B: ficticias y test de Chow (Tutorial 7)	103
Auto-evaluación	107

Ejercicios	109
7. Heterocedasticidad	111
Objetivos	111
Pregunta motivadora	111
7.1. Introducción	111
7.2. Consecuencias de la heterocedasticidad	113
7.3. Detección de la heterocedasticidad	113
7.4. Soluciones	115
7.5. Práctica: Heterocedasticidad en R	116
Auto-evaluación	122
Ejercicios	124
8. Autocorrelación	127
Objetivos	127
Pregunta motivadora	127
8.1. Contexto: del corte transversal a la serie temporal	128
8.2. Definición, estructura AR(1) y consecuencias	129
8.3. Detección	131
8.4. Corrección: de MCG a Cochrane-Orcutt	134
8.5. Práctica: Autocorrelación en R	136
Auto-evaluación	143
Ejercicios	145
Appendices	147
A. Prerrequisitos matemáticos y estadísticos	147
Objetivos	147
A.1. A.1 Repaso de álgebra	147
A.2. A.2 Repaso de cálculo	149
A.3. A.3 Repaso de probabilidad	150
A.4. A.4 Repaso de inferencia estadística	152
A.5. A.5 Repaso de álgebra lineal	154
A.6. A.6 Configurar R y RStudio	155
A.7. A.7 Primeros gráficos	157
B. Crosswalk Wooldridge Carter–Griffiths–Lim	161
B.1. B.1 Por qué este crosswalk	161
B.2. B.2 Crosswalk de notación	161
B.3. B.3 Mapeo de capítulos	162
B.4. B.4 Dónde divergen pedagógicamente	163
B.5. B.5 Si solo tienes CGL: ruta de lectura	164
C. Tablas estadísticas	165
Cómo leer estas tablas	165
C.1. C.1 Valores críticos de la distribución t	165
C.2. C.2 Valores críticos de la distribución F	166
C.3. C.3 Valores críticos de la χ^2	168
C.4. C.4 Cotas de Durbin–Watson	169

Prefacio

Econometría I — Teoría, práctica y aplicaciones es el libro de texto abierto que acompaña a la asignatura de Econometría I en la Universidad de Granada (UGR), Facultad de Ciencias Económicas y Empresariales. Consolida tres años de materiales docentes —apuntes de clase, tutoriales en R y auto-evaluaciones interactivas— en un único volumen reproducible.

Qué es este libro

Un texto unificado de segundo curso de grado que acompaña al lector desde la *idea* de un modelo econométrico hasta las destrezas prácticas de estimación, inferencia y diagnóstico necesarias para analizar datos económicos reales. Cada capítulo sigue la misma plantilla de seis secciones:

1. **Objetivos de aprendizaje**
2. **Pregunta empírica motivadora**
3. **Teoría**
4. **Ejemplo aplicado en R**
5. **Auto-evaluación** (cuestionario interactivo)
6. **Ejercicios** (fácil, intermedio, analítico)

Cómo está organizado el libro

Capítulo	Tema
1	Conceptos iniciales
2	El modelo de regresión lineal simple
3	El modelo de regresión lineal múltiple
4	Inferencia
5	Predicción y selección de modelos
6	Relaciones no lineales e información cualitativa
7	Heterocedasticidad
8	Autocorrelación
Ap. A	Prerrequisitos matemáticos y estadísticos
Ap. B	Crosswalk Wooldridge Carter–Griffiths–Lim
Ap. C	Tablas estadísticas

Ediciones y licencia

Este libro se publica bajo una licencia **Creative Commons Atribución 4.0 Internacional (CC BY 4.0)**. La edición inglesa equivalente está disponible bajo el título *Econometrics I — Theory, Practice, and Applications*.

Cómo utilizar los materiales fuente

El libro se construye con Quarto. Cada capítulo es un archivo `.qmd` que combina texto, código R ejecutable y cuestionarios interactivos. Para reconstruir el libro localmente se utiliza el comando `quarto render`. Para la edición española, consulte `NEXT_STEPS.md` para el flujo actual de renderizado.

Paquetes de R necesarios

```
install.packages(c("wooldridge", "readxl", "lmtest", "sandwich", "orcutt"))  
# Paquete complementario (datos y funciones auxiliares)  
# remotes::install_github("agaggero-ugr/econometricsUGR")
```

Agradecimientos

Al Departamento de Métodos Cuantitativos para la Economía y la Empresa de la UGR; a los estudiantes de tres promociones consecutivas (2023/24, 2024/25, 2025/26), cuyas preguntas dieron forma a este texto; y a los autores de *Introductory Econometrics* (Wooldridge) y *Principles of Econometrics* (Carter–Griffiths–Lim), sobre cuyas tradiciones pedagógicas se construye este libro.

Conceptos Iniciales

Objetivos de aprendizaje

- **Definir** qué es la econometría y distinguirla de un modelo puramente teórico.
- **Identificar** las dos componentes de un modelo econométrico —parte sistemática y término de error— y reconocer los parámetros desconocidos $\beta_0, \beta_1, \dots$
- **Explicar** por qué correlación no implica causalidad y **diagnosticar** sesgo de selección y sesgo de variable omitida en ejemplos aplicados.
- **Distinguir** los tres grandes diseños empíricos en economía: experimentos aleatorizados, cuasi-experimentos y datos observacionales.
- **Clasificar** un conjunto de datos económicos como de corte transversal, de series temporales, de panel o panel agrupado.
- **Explorar** un conjunto de datos en R con `str()`, `summary()`, `head()`, `hist()`, `plot()` y `tapply()`, y **calcular** medias condicionales para detectar asociaciones brutas.

Pregunta motivadora

*¿Asistir a la universidad **causa** mayores salarios, o las personas que de todos modos habrían ganado más tienden a ir a la universidad?*

A lo largo del curso veremos que responder a esta pregunta —y a muchas otras del mismo tipo— exige algo más que una simple correlación entre nivel educativo y salario. Hace falta un **modelo**, una **muestra** y, sobre todo, un **diseño** que nos permita atribuir las diferencias observadas a la causa que nos interesa.

1.1. ¿Qué es la Econometría?

LA **econometría** es la aplicación de métodos estadísticos a datos económicos con el fin de dar contenido empírico a las relaciones económicas. Su objetivo principal es la **estimación** y **contraste** de relaciones entre variables económicas. Algunos ejemplos típicos:

- Educación $\Rightarrow$ Salario
- Asistencia a clase $\Rightarrow$ Nota final
- Tasas de matrícula $\Rightarrow$ Inscripción
- Renta $\Rightarrow$ Felicidad
- Gasto público en seguridad $\Rightarrow$ Criminalidad
- Publicidad $\Rightarrow$ Ventas

1. Conceptos Iniciales

En general nos referimos a estas variables como $X \Rightarrow Y$, donde X es la **variable independiente** (también llamada regresora o explicativa) e Y es la **variable dependiente** (también respuesta o resultado). Frente a cualquier relación de este tipo surgen dos preguntas fundamentales:

1. ¿**Existe** un efecto de X sobre Y ?
2. ¿Cuál es la **magnitud** del efecto?

i Decisores y preguntas de «¿cuánto?»

Cada día, quienes toman decisiones se enfrentan a preguntas cuantitativas:

- Un ayuntamiento se plantea cuánto se reducirá el crimen violento si se destina un millón de euros adicional a poner más policías en la calle.
- El propietario de una pizzería local debe decidir cuánto invertir en publicidad digital y, por tanto, necesita estimar la relación entre publicidad y ventas.
- Una universidad privada en Andalucía necesita estimar en cuánto disminuirá la matrícula si sube la tasa anual 300 euros.

La econometría es la caja de herramientas para responder este tipo de preguntas con datos (Wooldridge 2020).

1.2. El modelo econométrico

El modelo econométrico consta de **dos componentes**:

1. **La parte sistemática**: el comportamiento medio de muchos individuos, empresas u observaciones.
2. **El error aleatorio u** : recoge todos los factores que afectan a Y y que se han omitido en la especificación.

i Ejemplo: determinación del salario

Algunos factores asociados al salario por hora de un individuo son la edad, el género, la experiencia y la educación:

$$\text{Salario} = f(\text{Edad}, \text{Género}, \text{Experiencia}, \text{Educación}) + u$$

Una especificación **lineal** sería:

$$\text{Salario} = \beta_0 + \beta_1 \text{Edad} + \beta_2 \text{Género} + \beta_3 \text{Experiencia} + \beta_4 \text{Educación} + u$$

Los coeficientes $\beta_0, \beta_1, \dots, \beta_4$ son **parámetros desconocidos** que queremos estimar a partir de una muestra de datos y de una técnica econométrica (por ejemplo, Mínimos Cuadrados Ordinarios; véase el Capítulo 2).

Dos observaciones importantes:

- La **forma funcional** (lineal, log-lineal, cuadrática, ...) representa una hipótesis sobre la relación entre variables. En cada problema, uno de los retos consiste en elegir una forma funcional compatible con la teoría económica y con los datos.
- El error u **no es observable**. Cuando estimamos el modelo en una muestra, obtenemos los **residuos** $\hat{u}_i = y_i - \hat{y}_i$, que son la versión muestral —y observable— del error poblacional.

1.3. Usos de la econometría

El modelo econométrico cumple tres grandes funciones, que conviene distinguir desde el principio:

- **Contrastar teorías e hipótesis económicas.** Por ejemplo: ¿reduce el empleo un aumento del salario mínimo?
- **Predecir variables económicas.** Por ejemplo: pronosticar el crecimiento del PIB o el precio de las acciones de una empresa.
- **Estimar relaciones causales.** Por ejemplo: ¿un año adicional de educación **causa** un salario más alto, *ceteris paribus*?

El tercer punto pertenece a lo que se conoce como la **Revolución de la Credibilidad** en economía empírica, que enfatiza la importancia de identificar efectos causales en lugar de limitarse a constatar correlaciones (Hill et al. 2017). Las técnicas que veremos en los capítulos siguientes—MCO, controles, variables instrumentales (en cursos posteriores), diferencias-en-diferencias—son herramientas para acercarnos a ese objetivo.

1.4. Correlación no implica causalidad

Una de las lecciones más importantes de la econometría es que **correlación no implica causalidad**. Que dos variables se muevan juntas no significa que una cause la otra. Veamos por qué.

1.4.1. Sesgo de selección

Ejemplo: ventiladores y mortalidad

Un hospital quiere saber si los respiradores mecánicos salvan vidas. Una comparación ingenua muestra que los pacientes que reciben respirador mueren **más** que los pacientes que no lo reciben. ¿Deberíamos concluir que los respiradores matan?

Por supuesto que no. El problema es el **sesgo de selección**: los pacientes más graves reciben respirador precisamente porque están en peor estado. Esos pacientes habrían tenido mayor mortalidad **independientemente** de si se les hubiera conectado o no a un respirador.

La correlación entre uso del respirador y muerte es *positiva*, pero el verdadero efecto causal es *negativo* (los respiradores salvan vidas). La comparación ingenua confunde el efecto del tratamiento con las características de quien lo recibe.

Error frecuente

Comparar las medias de Y entre quienes reciben un tratamiento y quienes no lo reciben **no estima el efecto causal** del tratamiento, salvo que la asignación al tratamiento sea independiente de los demás determinantes de Y . Esta independencia raramente se da en datos observacionales.

1.4.2. Sesgo de variable omitida

i Ejemplo: helados y ahogamientos

Los datos muestran una fuerte correlación positiva entre las ventas de helados y los ahogamientos. ¿Deberíamos prohibir los helados para reducir las muertes por ahogamiento? Obviamente no. La **variable omitida** es la temperatura. El calor causa *a la vez* más ventas de helados y más baños en piscinas y playas (y, por tanto, más ahogamientos). Sin controlar por la temperatura, la correlación entre helados y ahogamientos es completamente engañosa: es una **correlación espuria**.

Formalmente, hablamos de **sesgo de variable omitida (SVO)** cuando una variable Z que (i) afecta a Y y (ii) está correlacionada con X se deja fuera del modelo. La estimación de β_1 —el efecto de X sobre Y — absorbe parte del efecto de Z . Volveremos sobre esto con detalle en el Capítulo 3.

1.4.3. Por qué la aleatorización resuelve el problema

Si asignamos **aleatoriamente** individuos a un grupo de **tratamiento** y otro de **control**, ambos grupos tendrán, en media, las mismas características —observables y no observables— *antes* del tratamiento. Cualquier diferencia en los resultados *después* del tratamiento puede entonces atribuirse al tratamiento mismo.

Volviendo al ejemplo de los respiradores: si pudiéramos asignar respiradores al azar (no en función de la gravedad), los grupos de tratamiento y control tendrían la misma gravedad media. La diferencia de mortalidad sería una estimación **insesgada** del efecto causal del respirador.

Por esta razón, los **Ensayos Controlados Aleatorizados (ECA)** son el «estándar de oro» para establecer relaciones de causalidad.

i Ejemplo: escuelas privadas y notas en pruebas estandarizadas

Un estudio observa que los estudiantes de escuelas privadas obtienen mejores notas en pruebas estandarizadas. ¿Podemos concluir que las escuelas privadas **causan** un mejor rendimiento?

No: los estudiantes de escuelas privadas suelen proceder de familias con más recursos en el hogar (libros, apoyo, expectativas, redes). Estamos de nuevo ante un sesgo de selección: la «asignación» a la escuela privada no es aleatoria.

1.5. Tipos de experimentos

La forma en que se generan los datos determina hasta qué punto podemos hablar de causalidad. Conviene distinguir tres grandes diseños empíricos.

1.5.1. Experimentos aleatorizados

Un **experimento aleatorizado** asigna a los participantes a uno o varios grupos mediante un mecanismo aleatorio (un sorteo, una tabla de números aleatorios, etc.). Uno de los grupos recibe la intervención —el **tratamiento**— y otro sirve como **grupo de control** (placebo o práctica

habitual). La aleatorización garantiza, en media, la **comparabilidad** entre grupos y permite inferencia causal directa.

Sin embargo, este tipo de experimentos es **poco frecuente** en economía y en ciencias sociales por dos razones principales:

- **Razones éticas:** no se puede asignar al azar a una persona a vivir en pobreza, a no recibir tratamiento médico o a cursar una educación de peor calidad.
- **Coste y financiación:** los ECA son caros y logísticamente complejos.

Existen, no obstante, ejemplos célebres: el experimento RAND de seguro de salud en Estados Unidos, los programas de transferencias condicionadas tipo *PROGRESA/Oportunidades* en México, o las evaluaciones de microcréditos del J-PAL.

1.5.2. Cuasi-experimentos

Con datos **cuasi-experimentales**, la asignación al grupo de tratamiento y al de control **no** es aleatoria, sino que depende de algún criterio **observable** (un umbral administrativo, una regla geográfica, una fecha de corte). Cuando ese criterio es exógeno respecto del resultado de interés, el cuasi-experimento puede aproximarse a un experimento puro.

i Ejemplo: confinamientos por umbral de contagio

Durante la pandemia de COVID-19, la Junta de Andalucía impuso confinamientos perimetrales (tratamiento) únicamente a los municipios con una tasa de contagio superior a 1.000 casos por cada 100.000 habitantes:

- **Grupo de tratamiento:** municipios con tasa por encima de 1.000.
- **Grupo de control:** municipios con tasa por debajo de 1.000.

Comparando municipios «justo por encima» y «justo por debajo» del umbral, es plausible que ambos grupos sean similares en todo lo demás y que las diferencias en, por ejemplo, movilidad o actividad económica reflejen el efecto causal del confinamiento.

Otros diseños cuasi-experimentales habituales son **diferencias-en-diferencias**, **regresión discontinua** y **variables instrumentales** (se estudian en cursos posteriores).

1.5.3. Datos no experimentales (observacionales)

En los datos **no experimentales** —típicamente encuestas— todas las variables se observan simultáneamente y la asignación a «grupos» no obedece a un diseño explícito: cada agente «se selecciona» en función de sus propias circunstancias. Son los datos más abundantes en economía aplicada.

Ejemplos en España:

- La **Encuesta de Población Activa (EPA)** del INE: principal fuente sobre el mercado laboral; ofrece datos trimestrales sobre empleo, paro y población activa.
- La **Encuesta Nacional de Salud (ENSE)**: información sanitaria sobre miles de hogares residentes en España.
- La **Encuesta de Condiciones de Vida (ECV)**.

1. Conceptos Iniciales

Con datos observacionales **podemos estimar correlaciones**, pero la interpretación causal exige supuestos adicionales (controlar por confusores observables, instrumentos válidos, diseños cuasi-experimentales, etc.). Esto explica por qué buena parte de la econometría moderna se dedica a **identificar** efectos causales en datos que no proceden de un experimento.

1.6. Tipos de datos económicos

Los datos económicos se presentan en varias formas. Una primera distinción útil es entre el **nivel de agregación** (datos micro frente a datos macro) y la **naturaleza de las variables**:

- **Cuantitativas**: expresadas como números (salarios, ventas, PIB).
- **Cualitativas**: expresan una situación o categoría (sí/no, sector, región). En el modelo de regresión se incorporan habitualmente como **variables ficticias**.

Una segunda distinción —la que más nos ocupará— se refiere a la **estructura temporal** de los datos.

i Datos de corte transversal

Datos recogidos sobre **unidades muestrales** (individuos, hogares, empresas, municipios, países) en un **único período**. El orden de las observaciones no contiene información: podemos reordenar las filas sin perder nada.

Ejemplo: La **Encuesta Nacional de Salud de España 2017** recoge información sanitaria sobre 23.860 hogares en un único año.

i Series temporales

Datos recogidos a **intervalos regulares** de tiempo, donde se registra la misma magnitud económica.

Ejemplos: el precio anual del trigo, la tasa de paro mensual, las cotizaciones diarias del IBEX-35.

i Datos de panel (longitudinales)

Datos sobre **micro-unidades individuales** que se observan a lo largo de **varios períodos**. El rasgo clave es que observamos *cada* micro-unidad en múltiples instantes de tiempo. Si todas las unidades se observan el mismo número de períodos, el panel es **balanceado**.

Ejemplo: 1.000 empresas seguidas durante 2010-2024, registrando ventas, empleo y exportaciones de cada empresa en cada año.

i Panel agrupado (*pooled cross-section*)

Conjunto formado por la **unión de varias secciones cruzadas** independientes, recogidas en distintos períodos. **No** se siguen las mismas unidades: cada período aporta una muestra nueva. Permite analizar cambios poblacionales a lo largo del tiempo aunque no permite seguir trayectorias individuales.

Ejemplo: unir varias olas de la EPA, donde cada trimestre se extrae una muestra fresca de hogares.

 Error frecuente

No confundir **panel** con **panel agrupado**: la diferencia clave es si las **mismas** unidades se siguen a lo largo del tiempo (panel) o si se extraen **muestras nuevas** en cada período (panel agrupado).

1.7. Práctica: exploración de datos económicos en R

En esta práctica usaremos el conjunto de datos `wage1` del paquete `wooldridge`, que contiene información de 526 trabajadores estadounidenses en mayo de 1976 (corte transversal). El objetivo es **explorar** los datos antes de cualquier modelización: calcular medias y medianas, visualizar distribuciones y obtener **medias condicionales** que ilustren —pero no demuestren— posibles relaciones.

Si es la primera vez que se usa el paquete `wooldridge`, hay que instalarlo desde la consola de R con `install.packages("wooldridge")`. La instalación se hace **una sola vez**; cargar el paquete con `library()` se hace en cada sesión.

```
library(wooldridge)
data("wage1")
```

1.7.1. Estructura del conjunto de datos

```
str(wage1)
```

```
'data.frame':  526 obs. of  24 variables:
 $ wage      : num  3.1 3.24 3 6 5.3 ...
 $ educ      : int  11 12 11 8 12 16 18 12 12 17 ...
 $ exper     : int  2 22 2 44 7 9 15 5 26 22 ...
 $ tenure    : int  0 2 0 28 2 8 7 3 4 21 ...
 $ nonwhite  : int  0 0 0 0 0 0 0 0 0 0 ...
 $ female    : int  1 1 0 0 0 0 0 1 1 0 ...
 $ married   : int  0 1 0 1 1 1 0 0 0 1 ...
 $ numdep    : int  2 3 2 0 1 0 0 0 2 0 ...
 $ smsa      : int  1 1 0 1 0 1 1 1 1 1 ...
 $ northcen  : int  0 0 0 0 0 0 0 0 0 0 ...
 $ south     : int  0 0 0 0 0 0 0 0 0 0 ...
 $ west      : int  1 1 1 1 1 1 1 1 1 1 ...
 $ construc  : int  0 0 0 0 0 0 0 0 0 0 ...
 $ ndurman   : int  0 0 0 0 0 0 0 0 0 0 ...
 $ trcommpu  : int  0 0 0 0 0 0 0 0 0 0 ...
 $ trade     : int  0 0 1 0 0 0 1 0 1 0 ...
 $ services  : int  0 1 0 0 0 0 0 0 0 0 ...
 $ profserv  : int  0 0 0 0 0 1 0 0 0 0 ...
 $ profocc   : int  0 0 0 0 0 1 1 1 1 1 ...
 $ clerocc   : int  0 0 0 1 0 0 0 0 0 0 ...
 $ servocc   : int  0 1 0 0 0 0 0 0 0 0 ...
```

1. Conceptos Iniciales

```
$ lwage      : num  1.13 1.18 1.1 1.79 1.67 ...
$ expersq    : int   4 484 4 1936 49 81 225 25 676 484 ...
$ tenursq    : int   0 4 0 784 4 64 49 9 16 441 ...
- attr(*, "time.stamp")= chr "25 Jun 2011 23:03"
```

Cada fila representa **un trabajador** observado **una sola vez** en mayo de 1976. No hay índice temporal ni identificadores individuales repetidos: estamos ante un **corte transversal**, no un panel.

1.7.2. Estadísticas descriptivas

```
summary(wage1[, c("wage", "educ", "exper", "tenure")])
```

wage	educ	exper	tenure
Min. : 0.530	Min. : 0.00	Min. : 1.00	Min. : 0.000
1st Qu.: 3.330	1st Qu.:12.00	1st Qu.: 5.00	1st Qu.: 0.000
Median : 4.650	Median :12.00	Median :13.50	Median : 2.000
Mean : 5.896	Mean :12.56	Mean :17.02	Mean : 5.105
3rd Qu.: 6.880	3rd Qu.:14.00	3rd Qu.:26.00	3rd Qu.: 7.000
Max. :24.980	Max. :18.00	Max. :51.00	Max. :44.000

Las variables principales son:

- **wage**: salario por hora en dólares de 1976.
- **educ**: años de educación.
- **exper**: años de experiencia laboral potencial.
- **tenure**: años de antigüedad en el empleo actual.

```
head(wage1[, c("wage", "educ", "exper", "female", "married")])
```

	wage	educ	exper	female	married
1	3.10	11	2	1	0
2	3.24	12	22	1	1
3	3.00	11	2	0	0
4	6.00	8	44	0	1
5	5.30	12	7	0	1
6	8.75	16	9	0	1

1.7.3. Distribuciones

```
hist(wage1$wage,
     breaks = 30, col = "lightblue",
     main = "Distribución del salario por hora",
     xlab = "Salario (USD/h)")
```





Figure 1.1.: Distribución del salario por hora (USD).

La distribución del salario es claramente **asimétrica a la derecha**: la media (aproximadamente 5,90 USD/h) es mayor que la mediana (4,65 USD/h), lo que indica una cola larga de salarios altos. Es un patrón habitual en datos de renta y salarios.

```
hist(wage1$educ,
     breaks = 18, col = "lightgreen",
     main = "Años de educación",
     xlab = "Años de educación")
```




Figure 1.2.: Distribución de los años de educación.

1.7.4. Diagrama de dispersión: salario frente a educación

```
plot(wage1$educ, wage1$wage,  
     pch = 16, col = rgb(0, 0, 1, 0.3),  
     xlab = "Años de educación",  
     ylab = "Salario por hora (USD)",  
     main = "Salario vs. educación")  
abline(lm(wage ~ educ, data = wage1), col = "red", lwd = 2)
```




Figure 1.3.: Salario por hora frente a años de educación. La línea roja es el ajuste por MCO.

```
cor(wage1$wage, wage1$educ)
```

```
[1] 0.4059033
```

La correlación entre salario y educación es aproximadamente **0,41**: positiva, como esperaríamos. Pero conviene ser cauto en la interpretación:

1. La nube muestra **heterocedasticidad**: la varianza del salario es mucho mayor para niveles altos de educación que para niveles bajos (volveremos sobre esto en el Capítulo 7).
2. La correlación **no es** el efecto causal de la educación sobre el salario. Las personas con más años de estudios difieren en habilidad innata, motivación, origen familiar y muchas otras dimensiones que también están en u .

1.7.5. Medias condicionales

Una forma rápida de detectar asociaciones brutas es calcular la **media de Y por grupos** definidos por una variable categórica. En R lo hacemos con `tapply()`.

```
# Salario medio por género (female = 1 si mujer)
tapply(wage1$wage, wage1$female, mean)
```

```
0      1
7.099489 4.587659
```

1. Conceptos Iniciales

```
# Salario medio por estado civil
tapply(wage1$wage, wage1$married, mean)
```

```
      0      1
4.843884 6.573469
```

```
# Salario medio por intervalos de educación
wage1$educ_grupo <- cut(wage1$educ,
                        breaks = c(-1, 8, 12, 16, 18),
                        labels = c("Hasta 8", "9-12", "13-16", "17+"))
tapply(wage1$wage, wage1$educ_grupo, mean)
```

```
 Hasta 8      9-12      13-16      17+
4.461000  4.947701  6.785746 10.936129
```

Estos números son **medias condicionales**, no efectos causales. La brecha salarial bruta entre hombres y mujeres (aproximadamente 7,10 vs. 4,59 USD/h) refleja diferencias en ocupación, experiencia, sector, horas, decisiones de fecundidad, posible discriminación, etc. Para interpretarlas como efectos *ceteris paribus* necesitaremos una **regresión múltiple** que mantenga fijos los confusores observables (Capítulo 3).

💡 Pista: ¿qué pasa si estimamos un MCO simple aquí?

Es perfectamente posible escribir `summary(lm(wage ~ educ, data = wage1))` ahora mismo. Pero la interpretación del coeficiente como «retorno causal de un año de educación» exige supuestos fuertes (no SVO, no sesgo de selección). En el Capítulo 2 estimaremos este modelo con cuidado; en el Capítulo 3 introduciremos controles.

Auto-evaluación

Ocho preguntas breves de opción múltiple. Intenta responder cada una antes de desplegar la solución.

💡 Q1. ¿Qué es un modelo econométrico?

Un modelo econométrico se diferencia de un modelo económico puramente teórico en que:

- A. Supone que la relación entre variables es exacta y determinista.
- B. Añade un término de error estocástico y una forma funcional, de modo que los parámetros desconocidos puedan estimarse a partir de datos.
- C. No necesita una muestra de datos porque los parámetros se derivan de la teoría.
- D. Solo se utiliza en problemas macroeconómicos, no en microeconómicos.

Respuesta: B. Un modelo econométrico combina una forma funcional con una perturbación aleatoria u , lo que permite estimar los parámetros desconocidos a partir de los datos observados.

💡 Q2. El papel del término de error

En el modelo de regresión poblacional $y = \beta_0 + \beta_1 x + u$, el término de error u :

- A. Es la diferencia entre y_i y el valor ajustado por MCO $\hat{y}_i$ en nuestra muestra.
- B. Es siempre igual a cero en la población.
- C. Recoge todos los factores —distintos de x — que influyen sobre y .
- D. Es observable tan pronto como disponemos de datos de y y x .

Respuesta: C. u es una magnitud *poblacional* y *no observable* que agrupa todos los determinantes omitidos de y . El residuo $\hat{u}_i$ es su análogo muestral, calculado solo tras la estimación.

💡 Q3. ¿Corte transversal o no?

Un conjunto de datos con información sobre 526 trabajadores entrevistados en mayo de 1976 (una observación por trabajador, todos medidos en el mismo instante) es:

- A. Datos de corte transversal.
- B. Datos de series temporales.
- C. Datos de panel (longitudinales).
- D. Panel agrupado.

Respuesta: A. Muchas unidades, un único período, sin observaciones repetidas de la misma unidad: la definición estándar de corte transversal.

💡 Q4. Series temporales

Las tasas anuales de paro en España de 1980 a 2024 son un ejemplo de:

- A. Datos de corte transversal.
- B. Datos de series temporales.
- C. Datos de panel.
- D. Datos experimentales.

Respuesta: B. Una única magnitud (la tasa de paro) registrada a una frecuencia regular en el tiempo.

💡 Q5. Panel frente a panel agrupado

Una base de datos sigue a 1.000 empresas durante los años 2010-2024, registrando las ventas, el empleo y las exportaciones de cada empresa en cada año. Esto es:

- A. Datos de corte transversal, ya que cada fila es un par empresa-año.
- B. Panel agrupado, ya que se muestrean unidades distintas en cada período.
- C. Datos de series temporales, ya que tiene una dimensión temporal.
- D. Datos de panel (longitudinales): las mismas unidades observadas repetidamente a lo largo del tiempo.

Respuesta: D. Las mismas empresas se siguen a lo largo de varios períodos, que es exactamente la estructura de panel.

1. Conceptos Iniciales

💡 Q6. ¿Qué nos dice la correlación?

Una correlación positiva alta entre dos variables X e Y implica que:

- A. X causa Y .
- B. Y causa X .
- C. Existe una relación lineal determinista entre ambas.
- D. Tienden a moverse juntas, pero esta asociación puede deberse a una tercera variable, a causalidad inversa o a sesgo de selección.

Respuesta: D. La correlación no dice nada sobre la dirección causal ni sobre la presencia de confusores. El ejemplo de los helados y los ahogamientos del §1.4.2 es la advertencia canónica.

💡 Q7. Sesgo de selección

El sesgo de selección aparece cuando:

- A. Las unidades que se «seleccionan» en el grupo de tratamiento difieren sistemáticamente de las que no, incluso antes del tratamiento.
- B. El investigador elige los regresores en función de los estadísticos t .
- C. El tamaño muestral es demasiado pequeño para detectar un efecto verdadero.
- D. La variable dependiente se mide con error.

Respuesta: A. El sesgo de selección es una propiedad de la *asignación* del tratamiento, no de la estimación ni de la medición. El ejemplo de los respiradores del §1.4.1 es el prototipo.

💡 Q8. La aleatorización como remedio

¿En cuál de los siguientes diseños la aleatorización elimina *por construcción* el sesgo de selección?

- A. Comparar individuos empleados frente a desempleados utilizando datos de encuesta de corte transversal.
- B. Un Ensayo Controlado Aleatorizado (ECA) en el que el tratamiento se asigna por sorteo.
- C. Comparar estudiantes que eligieron matricularse en una escuela privada frente a una pública.
- D. Comparar países que adoptaron el euro frente a países que no lo hicieron.

Respuesta: B. Solo la asignación aleatoria garantiza que, *en media*, las unidades tratadas y no tratadas tengan las mismas características previas al tratamiento.

Ejercicios

Ejercicio 1.1 — Clasificación de conjuntos de datos. Clasifique cada uno de los siguientes conjuntos de datos como corte transversal, serie temporal, panel o panel agrupado.

- (a) IPC mensual español de 1980 a 2024.
- (b) `wage1`: 526 trabajadores entrevistados en mayo de 1976, una fila por trabajador.

- (c) La EPA española: cada trimestre se extrae una muestra independiente nueva de hogares (no se vuelve a entrevistar a ningún hogar); después se apilan varios trimestres.
- (d) Un conjunto de datos que sigue a los mismos 800 estudiantes desde los 6 hasta los 18 años, registrando sus puntuaciones cada año.

 Mostrar solución

- (a) Serie temporal. (b) Corte transversal. (c) Panel agrupado — unidades nuevas en cada período. (d) Panel: las *mismas* unidades se siguen a lo largo de varios períodos.

Ejercicio 1.2 — Detectar sesgo de selección. Para cada escenario, indique si el sesgo de selección es un problema probable e identifique qué característica lo origina.

- (a) Un hospital compara la mortalidad de los pacientes que recibieron respirador con la de los pacientes que no lo recibieron.
- (b) Un economista compara los salarios de los trabajadores que completaron un programa de formación laboral con los salarios de los trabajadores que no se inscribieron.
- (c) Unos investigadores comparan los países que adoptaron el euro en 1999 con los países que no lo hicieron.

 Mostrar solución

- (a) Sí — la gravedad de la enfermedad determina tanto la asignación del respirador como la mortalidad. (b) Sí — la autoselección hacia la formación viene impulsada por la motivación, los ingresos previos y las perspectivas en el mercado laboral, todo lo cual también afecta al salario. (c) Sí — los países que se unieron al euro fueron elegidos en función de fundamentos macroeconómicos (los criterios de Maastricht), por lo que no son una muestra aleatoria de países europeos.

Ejercicio 1.3 — Signo del sesgo de variable omitida. Suponga que regresa el salario por hora sobre los años de educación en una muestra de adultos actualmente empleados, *sin* controlar por la habilidad innata. Suponga que (i) los trabajadores más hábiles ganan más, manteniendo fija la educación, y (ii) los trabajadores más hábiles tienden a adquirir más educación. ¿Estará el coeficiente de *educ* sesgado al alza (demasiado positivo) o a la baja (demasiado negativo)? Explique en una frase.

La solución completa se ofrece en la Edición del Profesor.

Ejercicio 1.4 — Diseño de un experimento aleatorizado. Desea saber si un curso gratuito de preparación para la universidad (el tratamiento) eleva causalmente la probabilidad de que los estudiantes de secundaria de familias con renta baja se matriculen en la universidad. Esboce el diseño de un experimento aleatorizado que permita identificar este efecto causal. Sea explícito en cuanto a: la población, la regla de asignación, los grupos de tratamiento y control, la variable de resultado y el horizonte temporal. Discuta brevemente una objeción ética que su diseño deberá abordar.

La solución completa se ofrece en la Edición del Profesor.

Ejercicio 1.5 — Un modelo ingenuo con variable omitida. El salario de un trabajador se genera mediante

$$w = 5 + 2 \cdot edu + u, \quad \mathbb{E}[u] = 0, \text{ Var}(u) = 1,$$

1. Conceptos Iniciales

donde $edu \in \{0, 1, 2, 3\}$ son los años de educación postobligatoria. Suponga que la habilidad (recogida en u) está correlacionada con la educación: $\mathbb{E}[u \mid edu] = 0,5 \cdot edu$.

- (a) Calcule $\mathbb{E}[w \mid edu]$.
- (b) Si ingenuamente suponemos $\mathbb{E}[u \mid edu] = 0$ y leemos la pendiente, ¿qué obtenemos? ¿En cuánto nos *desviamos* del verdadero efecto marginal de un año adicional de educación?

La solución completa se ofrece en la Edición del Profesor.

Ejercicio 1.6 — Chocolate y premios Nobel. Se ha documentado (Hill et al. 2017) que los países con mayor consumo de chocolate per cápita también ganan más premios Nobel per cápita. ¿Es esto evidencia de que el consumo de chocolate *causa* premios Nobel? Identifique (i) al menos una variable omitida plausible, (ii) al menos un canal causal alternativo (causalidad inversa, selección de los países que se miden, etc.) y (iii) describa un diseño de investigación *hipotético* — experimental o cuasi-experimental — que le permitiera conocer el efecto causal del chocolate sobre la obtención de premios. Sea sincero respecto a por qué es poco probable que este diseño sea factible.

La solución completa se ofrece en la Edición del Profesor.

El Modelo de Regresión Lineal Simple

Objetivos de aprendizaje

Al terminar este capítulo, el lector debería ser capaz de:

- Escribir la Función de Regresión Poblacional (FRP) y la Función de Regresión Muestral (FRM) del modelo lineal simple y explicar qué representa cada una.
- Derivar los estimadores MCO $\hat{\beta}_0$ y $\hat{\beta}_1$ como minimizadores de la suma de cuadrados de los residuos.
- Enunciar los cinco supuestos de Gauss–Markov para la Regresión Lineal Simple (RLS) y explicar qué garantiza cada uno.
- Seguir la demostración de la insesgadez de MCO e identificar qué supuesto se usa en cada paso.
- Escribir la varianza muestral de $\hat{\beta}_1$, nombrar los tres factores que determinan su precisión y explicar el significado de ELIO (BLUE en inglés).
- Descomponer la variación total en $SCT = SCE + SCR$ y calcular e interpretar el R^2 .
- Utilizar `lm()` en R para estimar, interpretar y visualizar una regresión simple sobre los conjuntos de datos `beauty` y `bwght`.

Pregunta empírica motivadora

¿Cuánto más alto es el salario, en media, de un trabajador valorado «por encima de la media» en apariencia física, frente a uno valorado «en la media»?

La literatura de economía laboral (Wooldridge 2020) documenta desde hace décadas una *prima por apariencia* (*beauty premium*): los trabajadores percibidos como más atractivos físicamente tienden a ganar salarios más altos. Si esa prima es causal (la apariencia abre puertas) o si refleja otros factores correlacionados con ella (salud, habilidades sociales, origen familiar) es una pregunta distinta. Pero antes de poder *plantearla* necesitamos una herramienta que convierta una nube de puntos en un único número. Esa herramienta es la **regresión lineal simple** del salario sobre una medida de apariencia. En §2.11 se estima exactamente esta regresión sobre el conjunto de datos `beauty` de Hamermesh.

2.1. Introducción

EL análisis de regresión investiga la relación entre dos o más variables. En este capítulo nos centramos en el modelo de **Regresión Lineal Simple** (RLS), que relaciona una variable dependiente y con una única variable independiente x :

$$y = \beta_0 + \beta_1 x + u.$$

Aquí y es la variable dependiente, x es la variable independiente (también llamada regresor o variable explicativa), β_0 es el **intercepto** (o constante), β_1 es la **pendiente**, y u es el **término de error** o *perturbación* no observable, que recoge todos los determinantes de y distintos de x (Wooldridge 2020). El parámetro de pendiente β_1 mide el cambio en y asociado a un cambio de una unidad en x , *manteniendo constantes todos los factores en u* :

$$\beta_1 = \frac{\Delta y}{\Delta x} \quad \text{cuando } \Delta u = 0.$$

El intercepto β_0 es el valor de y cuando $x = 0$. En muchas aplicaciones $x = 0$ cae fuera del rango de los datos (cero años de educación, cero metros cuadrados, cero cigarrillos diarios para un no fumador) y el intercepto carece de interpretación económica inmediata; aun así es imprescindible para situar la recta en el lugar correcto.

i Un pequeño catálogo de ejemplos de RLS

Cada uno de los siguientes es una regresión lineal simple de una variable de resultado sobre un único regresor. Volveremos a varios de ellos a lo largo del capítulo.

- Salario sobre años de educación: $\widehat{\text{Salario}} = 800 + 15 \cdot \text{Educ}$. Cada año adicional de escolarización se asocia, en media, con 15 €/mes más.
- Precio de la vivienda sobre superficie: $\widehat{\text{Precio}} = 100,000 + 50 \cdot \text{m}^2$.
- Valor de reventa de un coche sobre antigüedad: $\widehat{\text{Reventa}} = 30,000 - 1,500 \cdot \text{Años}$.
- Ventas sobre gasto en publicidad: $\widehat{\text{Ventas}} = 50 + 2 \cdot \text{Publi}$.
- Presión arterial sobre edad: $\widehat{\text{PA}} = 100 + 0,5 \cdot \text{Edad}$.

2.2. La Función de Regresión Poblacional

El modelo $y = \beta_0 + \beta_1 x + u$ contiene la perturbación no observable u . Para convertirlo en un enunciado contrastable se impone un supuesto clave sobre la media condicional del error:

$$\mathbb{E}[u \mid x] = 0.$$

Esto significa que, sean cuales sean los determinantes de y recogidos en u , no guardan relación *en media* con x . Tomando esperanzas condicionales a ambos lados del modelo y aplicando este supuesto se obtiene la **Función de Regresión Poblacional (FRP)**:

$$\mathbb{E}[y \mid x] = \beta_0 + \beta_1 x.$$

La FRP describe el valor *medio* de y para cada valor de x en la población. Es una recta de intercepto β_0 y pendiente β_1 .

i La regresión es una comparación

Léase β_1 como una *comparación entre subpoblaciones*. Si se compara el grupo de individuos con $x = a$ frente al grupo con $x = a + 1$, este último presenta un valor de y que en media es β_1 unidades superior. Que esa comparación refleje un efecto causal depende de si se cumple $\mathbb{E}[u | x] = 0$ — una cuestión a la que volvemos a lo largo del libro.

El problema fundamental de la FRP es que **no se puede observar**: es un enunciado sobre toda la población, que nunca vemos. Lo mejor que podemos hacer es tomar una muestra y estimar la recta que, a la vista de la evidencia disponible, más se aproxima a la verdadera.

⚠ Error frecuente: confundir la FRP con la FRM

La FRP $\mathbb{E}[y | x] = \beta_0 + \beta_1 x$ es una propiedad de la *población*: β_0 y β_1 son fijos pero desconocidos. La FRM $\hat{y} = \hat{\beta}_0 + \hat{\beta}_1 x$ (sección siguiente) es una recta *aleatoria* cuyo intercepto y pendiente varían de una muestra a otra. Confundir ambas es el error conceptual más frecuente del curso.

2.3. La Función de Regresión Muestral

Sea $\{(x_i, y_i) : i = 1, 2, \dots, n\}$ una muestra aleatoria de tamaño n extraída de la población. Para cada observación i el modelo poblacional es

$$y_i = \beta_0 + \beta_1 x_i + u_i.$$

Se define la **Función de Regresión Muestral (FRM)** como

$$\hat{y}_i = \hat{\beta}_0 + \hat{\beta}_1 x_i,$$

donde $\hat{\beta}_0$ y $\hat{\beta}_1$ son **estimaciones** de los parámetros poblacionales β_0 y β_1 obtenidas a partir de los datos. Los acentos circunflejos recuerdan en todo momento que se trata de cantidades muestrales. Dos muestras distintas de la misma población darán, en general, dos FRM distintas.

2.4. Mínimos Cuadrados Ordinarios (MCO)

Dado un diagrama de dispersión de pares (x_i, y_i) , podrían trazarse infinitas rectas a través de la nube de puntos, cada una con un $(\hat{\beta}_0, \hat{\beta}_1)$ distinto. ¿Cómo elegir la «mejor» recta?

Por qué necesitamos un criterio

A continuación se muestra un diagrama de dispersión de 41 estudiantes de una promoción reciente de Econometría I en la UGR, en el que se representa la asistencia frente a la nota final. Muchas rectas parecen ajustar «más o menos» bien la nube de puntos; la pregunta es cuál elegir y por qué. Antes de derivar ninguna fórmula conviene *ver* el problema.

2. El Modelo de Regresión Lineal Simple


```
# 41 estudiantes, Econometría I UGR, curso 2024-25
asistencia <- c(38.89, 94.44, 94.44, 33.33, 83.33, 0, 0, 66.67, 88.89,
               66.67, 27.78, 83.33, 0, 61.11, 0, 22.22, 0, 0, 72.22,
               88.89, 88.89, 11.11, 5.56, 33.33, 16.67, 0, 11.11,
               33.33, 100, 38.89, 5.56, 72.22, 44.44, 0, 55.56, 33.33,
               0, 66.67, 5.56, 88.89, 88.89)

nota <- c(3.45, 5.5, 6, 3.7, 7, 2.55, 5, 2.1, 5.8, 1.9, 5.1, 5,
          2, 3.5, 2, 5.15, 0.35, 1.45, 5, 4.5, 7.8, 5.2, 3.8, 6,
          1.55, 1, 4.1, 5.7, 6.5, 4.2, 0.8, 6.5, 5.8, 0, 5.1,
          0.95, 1.4, 5.6, 1.7, 6.5, 6)

# Tres rectas candidatas (calcularemos sus SCR)
candidates <- data.frame(
  label = c("A) demasiado plana", "B) demasiado inclinada", "C) MCO"),
  b0     = c(3.0, 0.0, 2.256),
  b1     = c(0.015, 0.08, 0.0411)
)

# Diagrama de dispersión + las tres rectas candidatas
plot(asistencia, nota,
     xlab = "Asistencia (%)", ylab = "Nota final (0-10)",
     pch = 19, col = "grey40", cex = 0.9,
     main = "Tres rectas candidatas para los mismos datos")
cols <- c("steelblue", "tomato", "black")
ltys <- c(2, 3, 1)
for (k in seq_len(nrow(candidates))) {
  abline(a = candidates$b0[k], b = candidates$b1[k],
        col = cols[k], lwd = 2, lty = ltys[k])
}
legend("topleft", legend = candidates$label,
      col = cols, lty = ltys, lwd = 2, bty = "n")
```

Tres rectas candidatas para los mismos datos



```
# SCR de cada candidata
ssr <- sapply(seq_len(nrow(candidates)), function(k) {
  yhat <- candidates$b0[k] + candidates$b1[k] * asistencia
  sum((nota - yhat)^2)
})
data.frame(recta = candidates$label,
           beta0 = candidates$b0,
           beta1 = candidates$b1,
           SCR    = round(ssr, 2))
```

	recta	beta0	beta1	SCR
1	A) demasiado plana	3.000	0.0150	131.95
2	B) demasiado inclinada	0.000	0.0800	185.12
3	C) MCO	2.256	0.0411	92.33


Cada recta candidata da una suma de cuadrados de los residuos (SCR) distinta. MCO es el *único* par $(\hat{\beta}_0, \hat{\beta}_1)$ que minimiza esta suma — la recta C en el gráfico anterior. La siguiente figura muestra los residuos (las cantidades que se elevan al cuadrado y se suman) como segmentos verticales discontinuos desde cada punto hasta la recta MCO.

```
m <- lm(nota ~ asistencia)
plot(asistencia, nota,
     xlab = "Asistencia (%)", ylab = "Nota final (0-10)",
     pch = 19, col = "grey40", cex = 0.9,
     main = "Recta MCO con residuos (las cantidades que se elevan al cuadrado y se suman)")
```

2. El Modelo de Regresión Lineal Simple

```
abline(m, col = "black", lwd = 2)
yhat <- predict(m)
segments(asistencia, nota, asistencia, yhat,
         col = "tomato", lty = 3)
```

Recta MCO con residuos (las cantidades que se elevan al cuadrado y se sur



La definición formal del residuo $\hat{u}_i$ aparece en §2.4.1; la derivación algebraica de los minimizadores $\hat{\beta}_0$ y $\hat{\beta}_1$ se desarrolla en §2.4.3. La intuición visual nos acompaña en todo el capítulo: MCO es la recta que hace que la suma de los segmentos discontinuos al cuadrado sea lo más pequeña posible.

i Data: 41 estudiantes de Econometría I, curso 2024-25, UGR (recogidos por el autor).

2.4.1. El residuo

Para cada observación i , el **residuo** es la distancia vertical entre el valor observado y_i y el valor predicho por la FRM:

$$\hat{u}_i = y_i - \hat{y}_i = y_i - \hat{\beta}_0 - \hat{\beta}_1 x_i.$$

El residuo es el análogo muestral de la perturbación poblacional u_i . Es observable en cuanto se dispone de las estimaciones $(\hat{\beta}_0, \hat{\beta}_1)$; la perturbación u_i , en cambio, *nunca* es observable.

2.4.2. La suma de cuadrados de los residuos

Se busca la recta que haga los residuos lo más pequeños posible en algún sentido global. Elevarlos al cuadrado (en lugar de tomar valores absolutos) penaliza con más fuerza las desviaciones grandes y produce una función objetivo suave y diferenciable. El método de MCO elige $\hat{\beta}_0$ y $\hat{\beta}_1$ de modo que minimicen la **Suma de Cuadrados de los Residuos (SCR)**:

$$\text{SCR} = \sum_{i=1}^n \hat{u}_i^2 = \sum_{i=1}^n (y_i - \hat{\beta}_0 - \hat{\beta}_1 x_i)^2.$$

2.4.3. Derivación de los estimadores MCO

Derivando SCR respecto a $\hat{\beta}_0$ y $\hat{\beta}_1$ e igualando a cero se obtienen las **condiciones de primer orden (CPO)**:

$$-2 \sum_{i=1}^n (y_i - \hat{\beta}_0 - \hat{\beta}_1 x_i) = 0, \quad -2 \sum_{i=1}^n x_i (y_i - \hat{\beta}_0 - \hat{\beta}_1 x_i) = 0.$$

La primera CPO, dividida entre n , da $\bar{y} - \hat{\beta}_0 - \hat{\beta}_1 \bar{x} = 0$, de donde

$$\hat{\beta}_0 = \bar{y} - \hat{\beta}_1 \bar{x}.$$

Sustituyendo esta expresión en la segunda CPO y simplificando, se obtiene la célebre fórmula de la pendiente:

$$\hat{\beta}_1 = \frac{\sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})}{\sum_{i=1}^n (x_i - \bar{x})^2} = \frac{\widehat{\text{Cov}}(x, y)}{\widehat{\text{Var}}(x)}.$$

La pendiente es la covarianza muestral entre x e y dividida entre la varianza muestral de x . Dos consecuencias son inmediatas:

- La pendiente MCO es una **medida escalada de asociación**. Si en la muestra x e y están positivamente correlacionados, $\hat{\beta}_1 > 0$; si están incorrelacionados, $\hat{\beta}_1 = 0$.
- La fórmula exige $\sum_{i=1}^n (x_i - \bar{x})^2 > 0$, es decir, debe haber **variación en x** . Si todas las observaciones comparten el mismo valor de x , el denominador se anula y MCO queda indefinido — simplemente no hay forma de aprender cómo responde y a x si x nunca se mueve.

i Ejemplo: salario y educación

Supongamos una muestra de $n = 1\,000$ trabajadores en la que se obtiene

$$\widehat{\text{Salario}} = 800 + 15 \times \text{Educación}.$$

Léase:

- $\hat{\beta}_0 = 800$: el salario mensual predicho para alguien con cero años de educación es de 800 €/mes (extrapolación fuera del rango de los datos).
- $\hat{\beta}_1 = 15$: un año adicional de escolarización se asocia, en media, con 15 €/mes más.

2. El Modelo de Regresión Lineal Simple

La solución MCO posee tres propiedades mecánicas que se derivan directamente de las condiciones de primer orden y que se emplearán de forma recurrente:

1. $\sum_{i=1}^n \hat{u}_i = 0$ — los residuos suman cero.
2. $\sum_{i=1}^n x_i \hat{u}_i = 0$ — los residuos están incorrelacionados con x en la muestra.
3. La recta MCO pasa por el punto $(\bar{x}, \bar{y})$ — consecuencia directa de $\hat{\beta}_0 = \bar{y} - \hat{\beta}_1 \bar{x}$.

Se trata de propiedades **algebraicas** de MCO: se cumplen por construcción en *cualquier* muestra, con independencia del proceso generador de los datos. No son propiedades estadísticas sobre la población.

2.5. Los supuestos de Gauss–Markov para la RLS

MCO produce un número a partir de cualquier muestra, pero para que ese número tenga buenas propiedades *estadísticas* — insesgadez, varianza mínima, errores estándar interpretables — se necesitan supuestos sobre la población. Los cinco **supuestos de Gauss–Markov para la RLS** son la base del resto del capítulo.

RLS.1 — Linealidad en los parámetros. El modelo poblacional se escribe como

$$y = \beta_0 + \beta_1 x + u,$$

donde β_0 y β_1 son los parámetros desconocidos y u es la perturbación no observable.

RLS.2 — Muestreo aleatorio. Se dispone de una muestra aleatoria $\{(x_i, y_i) : i = 1, \dots, n\}$ extraída de la población descrita en RLS.1.

RLS.3 — Variación muestral en x . Los valores muestrales $x_1, x_2, \dots, x_n$ no son todos iguales: $\sum_{i=1}^n (x_i - \bar{x})^2 > 0$.

RLS.4 — Media condicional cero. El error tiene esperanza nula para cualquier valor de x :

$$\mathbb{E}[u \mid x] = 0.$$

RLS.5 — Homocedasticidad. La varianza del error es constante en x :

$$\text{Var}(u \mid x) = \sigma^2.$$

 Error frecuente: confundir qué hace cada supuesto

RLS.1–RLS.3 son condiciones técnicas que aseguran que el estimador esté bien definido. RLS.4 es lo que hace al estimador **insesgado** y permite interpretar β_1 como un efecto *ceteris paribus*; es también el supuesto más difícil de verificar y el que con más frecuencia se viola en la práctica. RLS.5 solo se necesita para la fórmula de la **varianza** y para el resultado de eficiencia de Gauss–Markov, no para la insesgadez.

2.6. Insesgadez de MCO

Bajo RLS.1–RLS.4 los estimadores MCO son insesgados. Se esboza el argumento para $\hat{\beta}_1$; el álgebra para $\hat{\beta}_0$ es análoga.

Partiendo de la fórmula MCO y sustituyendo el modelo poblacional $y_i = \beta_0 + \beta_1 x_i + u_i$:

$$\hat{\beta}_1 = \frac{\sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})}{\sum_{i=1}^n (x_i - \bar{x})^2} = \beta_1 + \frac{\sum_{i=1}^n (x_i - \bar{x}) u_i}{\sum_{i=1}^n (x_i - \bar{x})^2}.$$

El segundo término es un promedio ponderado de los errores no observables, con pesos $(x_i - \bar{x})/\text{SCT}_x$ que suman cero. Tomando la esperanza condicional dada $\mathbf{x} = (x_1, \dots, x_n)$ y aplicando RLS.4 ($\mathbb{E}[u_i | x_i] = 0$ para todo i),

$$\mathbb{E}[\hat{\beta}_1 | \mathbf{x}] = \beta_1 + \frac{\sum_{i=1}^n (x_i - \bar{x}) \mathbb{E}[u_i | \mathbf{x}]}{\sum_{i=1}^n (x_i - \bar{x})^2} = \beta_1.$$

Por la ley de esperanzas iteradas, $\mathbb{E}[\hat{\beta}_1] = \beta_1$. El mismo argumento aplicado a $\hat{\beta}_0 = \bar{y} - \hat{\beta}_1 \bar{x}$ da $\mathbb{E}[\hat{\beta}_0] = \beta_0$.

i La insesgadez es propiedad del estimador, no de una estimación concreta

La igualdad $\mathbb{E}[\hat{\beta}_1] = \beta_1$ *no* dice «nuestro número es exactamente correcto». Dice que si extrajásemos muchas muestras independientes de la misma población y calculásemos $\hat{\beta}_1$ en cada una, el promedio a largo plazo de todas esas estimaciones coincidiría con β_1 . Cualquier estimación individual puede estar por encima o por debajo de la verdad.

2.7. Varianzas muestrales de los estimadores MCO

¿Cómo de precisas son las estimaciones MCO? Bajo RLS.1–RLS.5, condicionando en los regresores,

$$\text{Var}(\hat{\beta}_1 | \mathbf{x}) = \frac{\sigma^2}{\sum_{i=1}^n (x_i - \bar{x})^2} = \frac{\sigma^2}{\text{SCT}_x},$$

$$\text{Var}(\hat{\beta}_0 | \mathbf{x}) = \frac{\sigma^2 \sum_{i=1}^n x_i^2}{n \sum_{i=1}^n (x_i - \bar{x})^2}.$$

Tres factores explican la precisión de $\hat{\beta}_1$:

1. **Varianza del error σ^2 .** Datos más ruidosos producen estimaciones menos precisas. Añadir buenos controles en el Capítulo 3 reducirá σ^2 y estrechará nuestras estimaciones.
2. **Variación en x (la dispersión del regresor, SCT_x).** Un regresor que apenas se mueve resulta poco informativo; uno que recorre un rango amplio identifica con nitidez la pendiente.
3. **Tamaño muestral n .** Una muestra mayor suele elevar SCT_x , lo que reduce directamente $\text{Var}(\hat{\beta}_1)$.

Estos tres factores reaparecen, con forma similar, en todos los modelos de regresión del resto del libro.

2.8. El teorema de Gauss–Markov

El resultado fundamental que justifica usar MCO es el **teorema de Gauss–Markov**.

Bajo RLS.1–RLS.5, los estimadores MCO $\hat{\beta}_0$ y $\hat{\beta}_1$ son los **Estimadores Lineales Insesgados Óptimos (ELIO; Best Linear Unbiased Estimators, BLUE)** de β_0 y β_1 .

«Mejores» significa de *varianza mínima* en la clase de todos los estimadores que son (i) lineales en y e (ii) insesgados para β . La demostración considera un competidor arbitrario lineal e insesgado $\tilde{\beta}_1 = \sum_i w_i y_i$, escribe los pesos como $w_i = (x_i - \bar{x}) / \text{SCT}_x + d_i$ para alguna desviación d_i , impone las condiciones $\sum_i d_i = 0$ y $\sum_i d_i x_i = 0$ exigidas por la insesgadería, y calcula

$$\text{Var}(\tilde{\beta}_1 | \mathbf{x}) = \frac{\sigma^2}{\text{SCT}_x} + \sigma^2 \sum_{i=1}^n d_i^2 \geq \frac{\sigma^2}{\text{SCT}_x} = \text{Var}(\hat{\beta}_1 | \mathbf{x}),$$

con igualdad solo si $d_i = 0$ para todo i , esto es, cuando $\tilde{\beta}_1 = \hat{\beta}_1$.

 Lo que el teorema de Gauss–Markov *no* dice

El teorema **no** afirma que MCO sea el mejor estimador en algún sentido absoluto. Dice: entre los estimadores *lineales* e *insesgados*, MCO tiene varianza mínima. Pueden existir estimadores *sesgados* (ridge, LASSO) o *no lineales* (regresión por cuantiles) con menor error cuadrático medio en contextos concretos.

2.9. Estimación de σ^2

La varianza del error σ^2 aparece en las fórmulas de varianza anteriores, pero es a su vez desconocida: nunca observamos los errores poblacionales u_i , solo los residuos $\hat{u}_i$. El estimador muestral natural es

$$\hat{\sigma}^2 = \frac{\text{SCR}}{n-2} = \frac{\sum_{i=1}^n \hat{u}_i^2}{n-2}.$$

Bajo RLS.1–RLS.5 este estimador es insesgado: $\mathbb{E}[\hat{\sigma}^2] = \sigma^2$. Se divide entre $n-2$ (y no entre n) porque ya se han «consumido» dos grados de libertad al estimar β_0 y β_1 a partir de los mismos datos. La raíz cuadrada $\hat{\sigma}$ se conoce como **error estándar de la regresión** (R la muestra como *Residual standard error*).

Combinando $\hat{\sigma}^2$ con la fórmula de la varianza se obtiene el **error estándar** de la estimación de la pendiente:

$$\text{se}(\hat{\beta}_1) = \frac{\hat{\sigma}}{\sqrt{\text{SCT}_x}}.$$

El error estándar es el caballo de batalla de la inferencia en el Capítulo 4: todo lo que diremos sobre intervalos de confianza y contrastes t se construye sobre él.

2.10. Bondad de ajuste: R^2

Dos regresiones pueden tener idéntica estimación de la pendiente y, sin embargo, ajustes muy distintos, según qué fracción de la variación de y logre explicar el regresor. Para medir el ajuste se descompone la variación total de y :

$$\underbrace{\sum_{i=1}^n (y_i - \bar{y})^2}_{\text{SCT}} = \underbrace{\sum_{i=1}^n (\hat{y}_i - \bar{y})^2}_{\text{SCE}} + \underbrace{\sum_{i=1}^n \hat{u}_i^2}_{\text{SCR}},$$

donde SCT es la *Suma de Cuadrados Total*, SCE es la *Suma de Cuadrados Explicada* y SCR es la *Suma de Cuadrados de los Residuos*. La descomposición se apoya en las propiedades algebraicas de MCO ($\sum_i \hat{u}_i = 0$ y $\sum_i x_i \hat{u}_i = 0$); no se cumpliría para una recta cualquiera.

El **coeficiente de determinación** es entonces

$$R^2 = \frac{\text{SCE}}{\text{SCT}} = 1 - \frac{\text{SCR}}{\text{SCT}}.$$

R^2 es la fracción de la variación muestral de y «explicada» por x . Toma valores entre 0 y 1: vale 1 cuando todos los puntos caen sobre la recta y vale 0 cuando $\hat{\beta}_1 = 0$. En la regresión lineal simple, R^2 coincide con el cuadrado del coeficiente de correlación muestral entre y y x .

⚠ Un R^2 bajo *no* significa que el modelo sea inútil

En economía laboral, de la salud o de la educación, valores de R^2 del 5–15 % son completamente normales: los resultados individuales dependen de muchos factores que nunca medimos. Un R^2 pequeño *no* invalida por sí solo la estimación de la pendiente — $\hat{\beta}_1$ puede seguir siendo insesgado, estadísticamente significativo y relevante para la política económica. A la inversa, un R^2 elevado *no* valida un modelo en el que falle RLS.4: $\hat{\beta}_1$ puede estimarse con precisión y estar, aun así, gravemente sesgado (Hill et al. 2017).

2.11. Práctica: RLS en R

En esta práctica se estiman dos regresiones simples utilizando el paquete **wooldridge**: la regresión salario-apariencia de §2.4 («Práctica A») y la regresión peso al nacer–tabaquismo materno («Práctica B»). Ambas son secciones cruzadas pequeñas, ambas presentan R^2 reducidos y ambas ilustran la advertencia anterior.

```
library(wooldridge)
data("beauty")
data("bwght")
```

2.11.1. Práctica A — Salario y apariencia física (beauty)

El conjunto de datos `beauty`, empleado por Hamermesh y Biddle (1994) y reproducido en Wooldridge (2020), contiene salarios por hora y una valoración de la apariencia física en una escala de cinco puntos para una muestra de trabajadores estadounidenses. La variable `looks` toma valores enteros de 1 («poco agraciado») a 5 («muy atractivo»), siendo 3 «en la media». La variable `wage` es el salario por hora en dólares estadounidenses.

Se comienza con estadísticos descriptivos y una tabla de frecuencias de `looks`.

```
summary(beauty$wage)
```

Min.	1st Qu.	Median	Mean	3rd Qu.	Max.
1.020	3.708	5.300	6.307	7.695	77.720

```
summary(beauty$looks)
```

Min.	1st Qu.	Median	Mean	3rd Qu.	Max.
1.000	3.000	3.000	3.186	4.000	5.000

```
table(beauty$looks)
```

1	2	3	4	5
13	142	722	364	19

La gran mayoría de los trabajadores recibe la valoración 3 («en la media»); las categorías extremas 1 y 5 son escasas. Esto ya nos avisa de que la pendiente de la regresión de salario sobre apariencia vendrá determinada casi en exclusiva por el contraste entre las categorías 2, 3 y 4.

Antes de cualquier regresión, calcúlese el salario medio en cada categoría de apariencia. Es la media condicional *no paramétrica* y servirá de referencia frente a la cual comparar el ajuste MCO.

```
tapply(beauty$wage, beauty$looks, mean)
```

1	2	3	4	5
4.621538	5.328803	6.504598	6.299341	7.388421

Los salarios medios crecen (modestamente y no de forma estrictamente monótona) con la apariencia. El resumen natural de este patrón en un único número es la pendiente de la recta MCO.

Un diagrama de dispersión con las medias condicionales superpuestas hace visible la historia.

```
cm <- tapply(beauty$wage, beauty$looks, mean)
plot(beauty$looks, beauty$wage,
     xlab = "Valoración de apariencia (1 = poco agraciado, 5 = muy atractivo)",
     ylab = "Salario por hora (USD)",
     main = "Salario frente a apariencia",
     pch = 16, col = rgb(0, 0, 0, 0.15))
points(as.numeric(names(cm)), cm, pch = 19, col = "blue", cex = 1.6)
```




Figure 2.1.: Salario por hora frente a valoración de apariencia (beauty). Los puntos azules son medias condicionales por categoría.

Estímese ahora la regresión lineal simple del salario sobre la apariencia con `lm()`:

```
fit_beauty <- lm(wage ~ looks, data = beauty)
summary(fit_beauty)
```

Call:

```
lm(formula = wage ~ looks, data = beauty)
```

Residuals:

Min	1Q	Median	3Q	Max
-5.452	-2.737	-0.997	1.453	71.108

Coefficients:

2. El Modelo de Regresión Lineal Simple

```
              Estimate Std. Error t value Pr(>|t|)
(Intercept)   5.1139      0.6242   8.192 6.24e-16 ***
looks         0.3744      0.1916   1.954  0.0509 .
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 4.655 on 1258 degrees of freedom
Multiple R-squared:  0.003027, Adjusted R-squared:  0.002235
F-statistic:  3.82 on 1 and 1258 DF, p-value: 0.05088
```

Antes de leer la salida de R, es instructivo replicar a mano la fórmula de §2.4.3:

```
b1 <- cov(beauty$wage, beauty$looks) / var(beauty$looks)
b0 <- mean(beauty$wage) - b1 * mean(beauty$looks)
c(b0 = b0, b1 = b1)
```

```
      b0      b1
5.1139311 0.3744088
```

Las dos cifras coinciden con los coeficientes que devuelve `lm()`, como es de esperar: `lm()` no hace nada distinto de aplicar las fórmulas del §2.4.3.

Interpretación de la salida:

- El intercepto estimado $\hat{\beta}_0$ es el salario predicho para un trabajador con `looks = 0` — un valor fuera del rango de los datos, por lo que carece de interpretación económica directa.
- La pendiente estimada $\hat{\beta}_1$ sobre `looks` es el cambio en el salario predicho por cada punto adicional en la valoración de apariencia. Un trabajador valorado 4 («por encima de la media») gana aproximadamente $\hat{\beta}_1$ dólares por hora más, en media, que uno valorado 3 («en la media»).
- El error estándar de $\hat{\beta}_1$, el estadístico t y el p -valor permiten contrastar si la pendiente es estadísticamente distinta de cero. Se tratan formalmente en el Capítulo 4; por ahora basta con notar que la pendiente es significativamente distinta de cero a los niveles habituales.
- El **Residual standard error** al pie de `summary()` es $\hat{\sigma}$ del §2.9.
- El **Multiple R-squared** es el R^2 del §2.10. Es pequeño (1–2%): la apariencia explica por sí sola una fracción ínfima de la variación de los salarios. Eso no invalida la pendiente — simplemente recuerda que el salario depende de muchas otras cosas (educación, experiencia, ocupación...) que se incorporarán como controles en el Capítulo 3.

Para cerrar, superpóngase la recta MCO al diagrama de dispersión:

```
plot(beauty$looks, beauty$wage,
      xlab = "Valoración de apariencia", ylab = "Salario por hora (USD)",
      main = "Salario frente a apariencia con recta MCO",
      pch = 16, col = rgb(0, 0, 0, 0.15))
abline(fit_beauty, col = "red", lwd = 2)
points(as.numeric(names(cm)), cm, pch = 19, col = "blue", cex = 1.6)
```




Figure 2.2.: Recta MCO y medias condicionales para la regresión salario–apariencia.

La recta roja MCO aproxima la tendencia de las medias condicionales azules pero no las interpola exactamente: el modelo lineal es una *aproximación*.

Una comprobación útil consiste en verificar la descomposición $SCT = SCE + SCR$ y la identidad $R^2 = 1 - SCR/SCT$ del §2.10:

```
yhat <- fitted(fit_beauty)
uhat <- resid(fit_beauty)
y     <- beauty$wage
SCT   <- sum((y - mean(y))^2)
SCE   <- sum((yhat - mean(y))^2)
SCR   <- sum(uhat^2)
c(SCT = SCT, SCE_mas_SCR = SCE + SCR)
```

```
      SCT SCE_mas_SCR
27347.44  27347.44
```

```
c(R2_manual = 1 - SCR / SCT, R2_lm = summary(fit_beauty)$r.squared)
```

```
R2_manual    R2_lm
0.0030271 0.0030271
```

Cada pareja de números coincide (salvo redondeo numérico), tal como predice la teoría.

2.11.2. Práctica B — Peso al nacer y tabaquismo materno (bwght)

El conjunto de datos `bwght` registra el peso al nacer (en onzas) y el consumo medio diario de cigarrillos de la madre durante el embarazo, entre otras variables, para una muestra de nacimientos en Estados Unidos. El tabaquismo materno es uno de los determinantes del peso al nacer más estudiados, con un mecanismo médico claro a favor de un efecto *negativo*.

```
summary(bwght$bwght)
```

Min.	1st Qu.	Median	Mean	3rd Qu.	Max.
23.0	107.0	120.0	118.7	132.0	271.0

```
summary(bwght$cigs)
```

Min.	1st Qu.	Median	Mean	3rd Qu.	Max.
0.000	0.000	0.000	2.087	0.000	50.000

```
mean(bwght$cigs)
```

```
[1] 2.087176
```

La mayoría de las madres de la muestra no fuman (la mediana de `cigs` es cero). Entre quienes sí fuman, el consumo diario puede llegar a 50 cigarrillos. El histograma hace evidente la pesada cola a la derecha:

```
hist(bwght$cigs,  
     main = "Cigarrillos al día durante el embarazo",  
     xlab = "Cigarrillos al día",  
     col  = "lightblue",  
     breaks = 20)
```





Figure 2.3.: Distribución de cigarrillos al día durante el embarazo (bwght).

Diagrama de dispersión del peso al nacer frente al consumo de cigarrillos:

```
plot(bwght$cigs, bwght$bwght,
     xlab = "Cigarrillos al día",
     ylab = "Peso al nacer (oz)",
     main = "Peso al nacer frente a tabaquismo materno",
     pch = 16, col = rgb(0, 0, 0, 0.25))
```




Figure 2.4.: Peso al nacer en onzas frente a cigarrillos al día.

Ahora la regresión lineal simple de `bwght` sobre `cigs`:

```
fit_bwght <- lm(bwght ~ cigs, data = bwght)
summary(fit_bwght)
```

Call:

```
lm(formula = bwght ~ cigs, data = bwght)
```

Residuals:

Min	1Q	Median	3Q	Max
-96.772	-11.772	0.297	13.228	151.228

Coefficients:

	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	119.77190	0.57234	209.267	< 2e-16 ***
cigs	-0.51377	0.09049	-5.678	1.66e-08 ***


Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 20.13 on 1386 degrees of freedom

Multiple R-squared: 0.02273, Adjusted R-squared: 0.02202

F-statistic: 32.24 on 1 and 1386 DF, p-value: 1.662e-08

```
plot(bwght$cigs, bwght$bwght,
     xlab = "Cigarrillos al día",
     ylab = "Peso al nacer (oz)",
     main = "Peso al nacer frente a tabaquismo materno (recta ajustada)",
     pch = 16, col = rgb(0, 0, 0, 0.25))
abline(fit_bwght, col = "red", lwd = 2)
```



Interpretación:

- $\hat{\beta}_0$ es el peso al nacer predicho para un bebé cuya madre *no* fuma durante el embarazo ($cigs = 0$). A diferencia de la regresión *beauty*, este valor sí tiene sentido económico/médico porque la mediana de *cigs* es cero.
- $\hat{\beta}_1$ es el cambio en el peso predicho por cada cigarrillo adicional al día. La pendiente estimada es aproximadamente $-0,51$ onzas por cigarrillo, de modo que fumar diez cigarrillos más al día se asocia con unos $10 \times (-0,51) \approx -5,1$ onzas menos de peso al nacer. El signo negativo concuerda con la evidencia médica.
- El R^2 es de nuevo pequeño. El peso al nacer depende de docenas de factores — nutrición materna, edad, partos previos, atención prenatal — y *cigs* es solo uno de ellos. Como en la Práctica A, un R^2 bajo no invalida la estimación de la pendiente.

Si el $-0,51$ estimado es o no el efecto *causal* del tabaco sobre el peso al nacer es otra cuestión. Si las madres fumadoras también difieren de las no fumadoras en renta, educación o nutrición, y esas características afectan al peso al nacer por sí mismas, entonces RLS.4 falla y $\hat{\beta}_1$ está sesgado — un caso de **sesgo de variable omitida (SVO)**. Volveremos a este mismo conjunto de datos

2. El Modelo de Regresión Lineal Simple

en el Capítulo 3, una vez dispongamos de las herramientas de regresión múltiple necesarias para tratarlo.

Auto-evaluación

Siete preguntas tipo test cortas. Inténtelas antes de desplegar la respuesta.

💡 P1. La pendiente β_1

En el modelo de regresión simple $y = \beta_0 + \beta_1 x + u$, la pendiente β_1 mide:

- A. La correlación entre x e y .
- B. El cambio esperado en y cuando x aumenta una unidad, manteniendo fijos todos los factores en u .
- C. El valor esperado de y cuando $x = 0$.
- D. La fracción de la varianza de y explicada por x .

Respuesta: B. β_1 es el cambio *ceteris paribus* en la media condicional de y . C describe el intercepto β_0 ; A es la correlación (una cantidad distinta, libre de escala); D es el R^2 .

💡 P2. El supuesto de media condicional cero

El supuesto $\mathbb{E}[u | x] = 0$ implica:

- A. Que el error u se distribuye normalmente.
- B. Que $\text{Var}(u | x)$ es constante en x .
- C. Que $\mathbb{E}[u] = 0$ y $\text{Cov}(x, u) = 0$.
- D. Que x se mide sin error.

Respuesta: C. La media condicional cero implica tanto media incondicional cero (por esperanzas iteradas) como covarianza nula entre x y u . B es el supuesto independiente de homocedasticidad (RLS.5); A y D no guardan relación.

💡 P3. La fórmula MCO de la pendiente

El estimador MCO de β_1 en la regresión simple $y = \beta_0 + \beta_1 x + u$ se escribe como:

- A. $\hat{\beta}_1 = \bar{y}/\bar{x}$.
- B. $\hat{\beta}_1 = \widehat{\text{Var}}(y)/\widehat{\text{Cov}}(x, y)$.
- C. $\hat{\beta}_1 = \widehat{\text{Cov}}(x, y)/\widehat{\text{Var}}(x)$.
- D. $\hat{\beta}_1 = \bar{y} - \hat{\beta}_0 \bar{x}$.

Respuesta: C. La pendiente es la covarianza muestral entre x e y entre la varianza muestral de x . D es (una versión reordenada de) la fórmula del intercepto; A y B no son estimadores MCO.

💡 P4. Propiedades mecánicas de los residuos MCO

¿Cuál de las siguientes **NO** es una propiedad algebraica de los residuos MCO $\hat{u}_i$?

- A. $\sum_i \hat{u}_i = 0$.
- B. $\sum_i x_i \hat{u}_i = 0$.
- C. La recta MCO pasa por $(\bar{x}, \bar{y})$.
- D. Los $\hat{u}_i$ están incorrelacionados con el error no observado u_i .

Respuesta: D. A, B y C se deducen directamente de las condiciones de primer orden y se cumplen en cualquier muestra. D es un enunciado sobre la perturbación poblacional u_i , que nunca es observable; no hay ninguna identidad algebraica que relacione $\hat{u}_i$ con u_i .

💡 P5. Insesgadez frente a ELIO

Bajo RLS.1–RLS.4 únicamente (sin homocedasticidad), MCO es:

- A. Insesgado: $\mathbb{E}[\hat{\beta}_j] = \beta_j$.
- B. El Estimador Lineal Insesgado Óptimo (ELIO / BLUE).
- C. Consistente pero sesgado.
- D. Normalmente distribuido.

Respuesta: A. La insesgadez requiere únicamente RLS.1–RLS.4. Añadir RLS.5 (homocedasticidad) es lo que eleva MCO a la condición de ELIO, vía el teorema de Gauss–Markov.

💡 P6. Precisión de $\hat{\beta}_1$

¿Cuál de los siguientes factores aumenta la precisión de $\hat{\beta}_1$ (varianza muestral menor)?

- A. Una varianza del error σ^2 mayor.
- B. Un tamaño muestral menor.
- C. Menos variación en x .
- D. Más variación en x (mayor SCT_x).

Respuesta: D. La fórmula de la varianza es $\text{Var}(\hat{\beta}_1 | \mathbf{x}) = \sigma^2 / SCT_x$. Un SCT_x mayor reduce la varianza. A y B hacen lo contrario; C es una reformulación de «menor precisión».

💡 P7. Qué nos dice (y qué no nos dice) el R^2

Un R^2 bajo en una regresión lineal simple significa:

- A. Que MCO es sesgado.
- B. Que x no tiene efecto causal sobre y .
- C. Que x explica una fracción pequeña de la variación de y , pero $\hat{\beta}_1$ puede seguir siendo insesgado y relevante.
- D. Que se incumplen los supuestos de Gauss–Markov.

Respuesta: C. El R^2 es una medida de ajuste, no de sesgo ni de causalidad. Un R^2 pequeño es perfectamente compatible con una pendiente insesgada y económicamente significativa, como muestran las prácticas de salario–apariencia y peso al nacer–tabaquismo.

Ejercicios

Ejercicio 2.1 — Lectura de una ecuación estimada. Una regresión sobre 1,000 trabajadores produce la recta estimada $\widehat{\text{Salario}} = 800 + 15 \times \text{Educación}$, donde el salario está en euros mensuales y la educación en años.

- Interprete $\hat{\beta}_0$ y $\hat{\beta}_1$ verbalmente.
- ¿Cuál es el salario predicho para un trabajador con 12 años de escolarización?
- Dos trabajadores difieren en 4 años de escolarización. ¿En cuánto difieren sus salarios predichos?
- ¿Por qué conviene desconfiar de la predicción en $\text{educ} = 0$?

 Mostrar respuesta

- $\hat{\beta}_0 = 800$ es el salario predicho para $\text{educ} = 0$ (800 €/mes). $\hat{\beta}_1 = 15$ es el aumento predicho en el salario mensual por cada año adicional de escolarización.
- $800 + 15 \times 12 = 980$ €/mes.
- $4 \times 15 = 60$ €/mes.
- Porque $\text{educ} = 0$ queda muy por debajo del menor valor de cualquier muestra real de escolarización; la predicción es una *extrapolación* y puede no ser fiable.

Ejercicio 2.2 — Álgebra de MCO, a mano. Considere los datos de juguete $x = (1, 2, 3, 4, 5)$ e $y = (3, 4, 2, 5, 6)$.

- Calcule $\bar{x}$ y $\bar{y}$.
- Calcule $\hat{\beta}_1$ con la fórmula del §2.4.3.
- Calcule $\hat{\beta}_0$.
- Verifique su resultado en R contrastándolo con `coef(lm(y ~ x))`.

 Mostrar respuesta

- $\bar{x} = 3$, $\bar{y} = 4$.
- Numerador: $\sum (x_i - \bar{x})(y_i - \bar{y}) = (-2)(-1) + (-1)(0) + 0(-2) + 1(1) + 2(2) = 2 + 0 + 0 + 1 + 4 = 7$. Denominador: $\sum (x_i - \bar{x})^2 = 4 + 1 + 0 + 1 + 4 = 10$. Así, $\hat{\beta}_1 = 7/10 = 0,7$.
- $\hat{\beta}_0 = \bar{y} - \hat{\beta}_1 \bar{x} = 4 - 0,7 \times 3 = 1,9$.
- En R: `coef(lm(c(3,4,2,5,6) ~ c(1,2,3,4,5)))` devuelve los mismos números.

Ejercicio 2.3 — Varianza de la pendiente MCO. Indique, en una frase cada uno, cómo cambia $\text{Var}(\hat{\beta}_1)$ si:

- el tamaño muestral n se duplica (manteniendo fija la distribución de x);
- la varianza del error σ^2 se duplica;
- el regresor x se reescala de minutos a horas (se divide entre 60).

 Mostrar respuesta

- SCT_x se duplica aproximadamente, por lo que la varianza se reduce a la mitad. (b) La varianza se duplica (es lineal en σ^2). (c) La varianza de la *pendiente sobre el regresor reescalado* se multiplica por $60^2 = 3600$: al escalar x por c , $\hat{\beta}_1$ se multiplica por $1/c$, de modo que su varianza se multiplica por $1/c^2$.

Ejercicio 2.4 — Cambio de unidades. Demuestre que si se redefine el regresor como $x^* = c \cdot x$ (para una constante $c \neq 0$) sin modificar y , los nuevos estimadores MCO son $\hat{\beta}_1^* = \hat{\beta}_1/c$ y $\hat{\beta}_0^* = \hat{\beta}_0$. Verifique la derivación empíricamente sobre `sleep75`: regrese `sleep` sobre `totwrk` (minutos por semana) y después sobre `totwrk/60` (horas por semana), y compruebe que el intercepto no cambia mientras que la pendiente se multiplica por 60.

Una respuesta completa se ofrece en la Edición del Profesor.

Ejercicio 2.5 — Insesgadez por simulación. Simule 1 000 muestras de tamaño $n = 200$ del modelo $y = 1 + 2x + u$ con $x \sim N(0, 1)$ y $u \sim N(0, 1)$. Calcule $\hat{\beta}_1$ en cada muestra y compruebe que su media sobre las réplicas se aproxima a 2, mientras que la desviación típica entre réplicas se aproxima al valor teórico $\sigma/\sqrt{\text{SCT}_x}$ para una extracción típica. Represente el histograma de $\hat{\beta}_1$.

Una respuesta completa se ofrece en la Edición del Profesor.

Ejercicio 2.6 — Por qué prescindir del intercepto sesga la pendiente. Suponga que el modelo verdadero es $y = \beta_0 + \beta_1 x + u$ con $\beta_0 \neq 0$ y $\mathbb{E}[u | x] = 0$, pero el investigador impone $\beta_0 = 0$ y ajusta la regresión por el origen $\tilde{y}_i = \tilde{\beta}_1 x_i$.

- Derive la expresión cerrada $\tilde{\beta}_1 = \sum_i x_i y_i / \sum_i x_i^2$ como minimizador de $\sum_i (y_i - \tilde{\beta}_1 x_i)^2$.
- Demuestre que $\mathbb{E}[\tilde{\beta}_1] = \beta_1 + \beta_0 \cdot \mathbb{E}[x]/\mathbb{E}[x^2]$, de modo que $\tilde{\beta}_1$ está sesgado siempre que $\beta_0 \neq 0$ y $\mathbb{E}[x] \neq 0$.
- ¿Bajo qué condición específica sobre la población es, no obstante, insesgada la pendiente sin intercepto?

Una respuesta completa se ofrece en la Edición del Profesor.

El Modelo de Regresión Lineal Múltiple

Objetivos de aprendizaje

Al terminar el capítulo el lector debería ser capaz de:

- Explicar por qué la regresión lineal simple rara vez basta para un trabajo empírico creíble, y leer cada pendiente del modelo múltiple como un efecto parcial *ceteris paribus*.
- Escribir el modelo de regresión lineal múltiple en forma matricial, $\mathbf{y} = \mathbf{X}\beta + \mathbf{u}$, y derivar la solución MCO $\hat{\beta} = (\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}'\mathbf{y}$.
- Enunciar los supuestos de Gauss–Markov RLM.1–RLM.5 y reconocer cuál de ellos viola cada patología empírica habitual.
- Demostrar, en forma matricial, que MCO es insesgado bajo RLM.1–RLM.4 y tiene varianza $\sigma^2(\mathbf{X}'\mathbf{X})^{-1}$ bajo RLM.1–RLM.5.
- Predecir la *dirección* y el *signo* del sesgo de variable omitida (SVO) a partir de una regresión auxiliar, y verificarlo numéricamente con datos reales.
- Distinguir R^2 de R^2 ajustado y explicar por qué este último puede disminuir al añadir regresores.

Pregunta motivadora

Una vez que mantenemos constantes la experiencia, la antigüedad, el sexo y el estado civil, ¿cuál es el rendimiento de un año adicional de educación?

El Capítulo 1 mostró que la brecha bruta de salarios por nivel educativo en `wage1` confunde el efecto de la escolaridad con el de la experiencia, la antigüedad y los rasgos demográficos; el Capítulo 2 estimó una regresión simple de `wage` sobre `educ` y advirtió de forma explícita que la pendiente MCO no podía leerse en clave causal. El modelo de regresión lineal múltiple (RLM) es la herramienta de trabajo que nos permite tomar en serio esa advertencia: al incluir controles, pasamos de medias condicionales brutas a **efectos parciales** — el cambio en y asociado a un cambio unitario en un regresor, *manteniendo fijos los demás*.

3.1. Motivación: el problema de la regresión simple

EL modelo de regresión lineal simple

$$y = \beta_0 + \beta_1 x + u$$

3. El Modelo de Regresión Lineal Múltiple

tiene una debilidad estructural: todo determinante de y distinto de x queda agrupado en el término de error u . Si alguno de esos determinantes omitidos está correlacionado con x , entonces $\text{Cov}(x, u) \neq 0$, el supuesto de media condicional cero $\mathbb{E}[u | x] = 0$ falla, y MCO es **sesgado** para el efecto causal de x sobre y (Wooldridge 2020).

i Ejemplo: educación y salarios sin controles

Supongamos

$$\text{wage} = \beta_0 + \beta_1 \text{educ} + u.$$

El error u contiene la *habilidad innata*, el entorno familiar, la motivación, la calidad del centro educativo y otras muchas variables no observables. Si los trabajadores más hábiles también acumulan más educación, entonces $\text{Cov}(\text{educ}, u) > 0$, y el estimador MCO simple $\hat{\beta}_1$ no aísla el rendimiento causal de la escolaridad: confunde el retorno a la educación con el retorno a aquello que mueve conjuntamente a la habilidad y a la educación.

La solución es conceptualmente sencilla: **traer al modelo los factores omitidos relevantes como regresores adicionales**. Reemplazamos el modelo simple por

$$\text{wage} = \beta_0 + \beta_1 \text{educ} + \beta_2 \text{exper} + \beta_3 \text{tenure} + u,$$

de modo que la experiencia y la antigüedad pasan a formar parte de la componente sistemática en lugar de quedarse en u . El coeficiente β_1 en este modelo más largo se interpreta como el cambio del salario esperado ante un año adicional de educación, *manteniendo fijas la experiencia y la antigüedad*. Esa es la afirmación *ceteris paribus* a la que aspira la economía empírica.

Dos advertencias merecen subrayarse desde el principio:

- Añadir controles **no** equivale a identificar causalidad. Veremos en §3.9 que el sesgo solo desaparece para las variables cuyos confundidores relevantes incluimos efectivamente.
- Incluir demasiados regresores, o regresores muy correlacionados, puede *inflar la varianza* sin reducir el sesgo. No hay almuerzo gratis.

3.2. El modelo RLM

i Definición: el modelo de regresión lineal múltiple

Con k regresores $x_1, \dots, x_k$, el **modelo poblacional RLM** es

$$y = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \dots + \beta_k x_k + u.$$

Cada pendiente β_j es el **efecto parcial** de x_j sobre y :

$$\beta_j = \frac{\partial \mathbb{E}[y | x_1, \dots, x_k]}{\partial x_j}.$$

Es decir, β_j mide cómo se desplaza la media condicional de y cuando x_j cambia en una unidad y los demás regresores permanecen constantes.

En el ejemplo salarial, una ecuación estimada como

$$\widehat{\text{wage}} = 3,0 + 1,5 \text{educ} + 0,04 \text{age} + 0,07 \text{exper} + 0,05 \text{tenure}$$

afirma: entre dos trabajadores con la *misma* edad, experiencia y antigüedad que difieren en un año de escolaridad, el salario por hora predicho difiere en 1,50 euros en media. El matiz crucial es ese «misma edad, experiencia y antigüedad» — es lo que distingue al coeficiente RLM de la pendiente de una regresión no condicional.

⚠ Error frecuente: olvidar el *ceteris paribus*

Un error muy extendido consiste en leer $\hat{\beta}_1$ como «el efecto sobre y de cambiar x_1 », sin la cláusula condicional. En RLM toda pendiente es condicional al resto de regresores incluidos. Si cambian los controles del modelo, cambia el significado de β_1 — no solo su valor numérico.

3.3. Notación matricial

Para una muestra de n observaciones resulta mucho más limpio apilar el modelo en forma matricial. Definimos

$$\mathbf{y} = \begin{pmatrix} y_1 \\ y_2 \\ \vdots \\ y_n \end{pmatrix}_{n \times 1}, \quad \mathbf{X} = \begin{pmatrix} 1 & x_{11} & x_{12} & \cdots & x_{1k} \\ 1 & x_{21} & x_{22} & \cdots & x_{2k} \\ \vdots & \vdots & \vdots & \ddots & \vdots \\ 1 & x_{n1} & x_{n2} & \cdots & x_{nk} \end{pmatrix}_{n \times (k+1)}, \quad \boldsymbol{\beta} = \begin{pmatrix} \beta_0 \\ \beta_1 \\ \vdots \\ \beta_k \end{pmatrix}_{(k+1) \times 1}, \quad \mathbf{u} = \begin{pmatrix} u_1 \\ u_2 \\ \vdots \\ u_n \end{pmatrix}_{n \times 1}.$$

El modelo RLM para toda la muestra es entonces

$$\mathbf{y} = \mathbf{X}\boldsymbol{\beta} + \mathbf{u}.$$

La primera columna de $\mathbf{X}$ es una columna de unos, que absorbe el intercepto β_0 . A partir de ahora escribiremos las demostraciones en forma matricial; es la notación estándar de (Wooldridge 2020) y rinde frutos a partir del Capítulo 4.

3.4. MCO en forma matricial

El estimador de mínimos cuadrados ordinarios (MCO) elige $\hat{\boldsymbol{\beta}}$ minimizando la suma de cuadrados de los residuos

$$\text{SCR}(\boldsymbol{\beta}) = (\mathbf{y} - \mathbf{X}\boldsymbol{\beta})'(\mathbf{y} - \mathbf{X}\boldsymbol{\beta}) = \mathbf{y}'\mathbf{y} - 2\boldsymbol{\beta}'\mathbf{X}'\mathbf{y} + \boldsymbol{\beta}'\mathbf{X}'\mathbf{X}\boldsymbol{\beta}.$$

Derivando respecto de $\boldsymbol{\beta}$ e igualando a cero obtenemos las **ecuaciones normales**

$$\mathbf{X}'\mathbf{X}\hat{\boldsymbol{\beta}} = \mathbf{X}'\mathbf{y}.$$

Si $\mathbf{X}'\mathbf{X}$ es invertible — lo que es exactamente el Supuesto RLM.3 más abajo — la solución única es

$$\hat{\boldsymbol{\beta}} = (\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}'\mathbf{y}.$$

Los valores ajustados son $\hat{\mathbf{y}} = \mathbf{X}\hat{\boldsymbol{\beta}}$ y los residuos $\hat{\mathbf{u}} = \mathbf{y} - \hat{\mathbf{y}}$. Por construcción, las ecuaciones normales implican $\mathbf{X}'\hat{\mathbf{u}} = \mathbf{0}$: los residuos son ortogonales a todos los regresores, incluida la constante. En particular, la media muestral de $\hat{\mathbf{u}}$ es cero siempre que el modelo contenga un intercepto.

 Error frecuente: confundir u con $\hat{u}$

Como en el Capítulo 1, u es un objeto *poblacional* e inobservable. El residuo $\hat{u}_i = y_i - \hat{y}_i$ es su contrapartida *muestral*, producida *tras* la estimación. Usaremos $\hat{\mathbf{u}}$ para calcular estimadores de varianza y el R^2 , pero nunca observaremos $\mathbf{u}$ propiamente dicho.

3.5. Supuestos de Gauss–Markov para RLM

Recopilamos ahora los supuestos bajo los que MCO tiene sus propiedades clásicas. Generalizan los del Capítulo 2 sobre regresión simple.

RLM.1 — Linealidad en los parámetros

El modelo poblacional es

$$y = \beta_0 + \beta_1 x_1 + \cdots + \beta_k x_k + u.$$

La linealidad se exige *en los parámetros* β_j , no en los regresores: x_j^2 o $\ln(x_j)$ son perfectamente válidos.

RLM.2 — Muestreo aleatorio

Observamos una muestra aleatoria i.i.d. $\{(y_i, x_{i1}, \dots, x_{ik}) : i = 1, \dots, n\}$ extraída de la población descrita por RLM.1.

RLM.3 — No multicolinealidad perfecta

En la muestra (y en la población), ningún regresor es constante y no existe ninguna relación lineal exacta entre los regresores. De manera equivalente, $\mathbf{X}'\mathbf{X}$ es invertible.

RLM.4 — Media condicional cero

El error tiene media cero condicionada a cualquier valor de los regresores:

$$\mathbb{E}[u \mid x_1, \dots, x_k] = 0, \quad \text{o, en forma matricial,} \quad \mathbb{E}[\mathbf{u} \mid \mathbf{X}] = \mathbf{0}.$$

Es el supuesto que garantiza la **inesgadez** de MCO. Falla siempre que se omite una variable relevante (§3.9), se utiliza una forma funcional equivocada, o hay error de medida o simultaneidad.

RLM.5 — Homocedasticidad

La varianza condicional de u no depende de $\mathbf{X}$:

$$\text{Var}(u \mid x_1, \dots, x_k) = \sigma^2, \quad \text{Var}(\mathbf{u} \mid \mathbf{X}) = \sigma^2 \mathbf{I}_n.$$

Los supuestos RLM.1–RLM.4 proporcionan la **inesgadez** (siguiente sección); añadiendo RLM.5, MCO se convierte en el **estimador lineal inesgado óptimo** (ELIO; *BLUE* en inglés) — el teorema de Gauss–Markov.

⚠ Error frecuente: confundir colinealidad «perfecta» con «alta»

RLM.3 solo descarta la dependencia lineal *exacta* entre los regresores. Dos variables altamente correlacionadas — pero no perfectamente correlacionadas — (por ejemplo *educ* y un test de aptitud *IQ*) siguen cumpliendo RLM.3. Inflarán la varianza de los estimadores MCO (el R_j^2 de la fórmula de varianza estará cerca de 1), pero no los sesgan ni rompen el modelo.

3.6. Insesgadez de MCO (forma matricial)

i Teorema: insesgadez de MCO

Bajo RLM.1–RLM.4,

$$\mathbb{E}[\hat{\beta} \mid \mathbf{X}] = \beta.$$

Esquema de la demostración. Partiendo de la solución MCO,

$$\hat{\beta} = (\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}'\mathbf{y} = (\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}'(\mathbf{X}\beta + \mathbf{u}) = \beta + (\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}'\mathbf{u}.$$

Tomando esperanzas condicionales y usando RLM.4 ($\mathbb{E}[\mathbf{u} \mid \mathbf{X}] = \mathbf{0}$),

$$\mathbb{E}[\hat{\beta} \mid \mathbf{X}] = \beta + (\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}'\mathbb{E}[\mathbf{u} \mid \mathbf{X}] = \beta.$$

Por la ley de esperanzas iteradas, $\mathbb{E}[\hat{\beta}] = \beta$ también de forma incondicional. $\square$

La demostración deja transparente el papel de RLM.4: cualquier correlación entre $\mathbf{X}$ y $\mathbf{u}$ entra en el término de sesgo $(\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}'\mathbb{E}[\mathbf{u} \mid \mathbf{X}]$. Esta es la versión matricial del SVO que deduciremos en §3.9.

3.7. Varianza de los estimadores MCO (forma matricial)

i Teorema: varianza de MCO

Bajo RLM.1–RLM.5,

$$\text{Var}(\hat{\beta} \mid \mathbf{X}) = \sigma^2(\mathbf{X}'\mathbf{X})^{-1}.$$

Esquema de la demostración. De la prueba de insesgadez, $\hat{\beta} - \beta = (\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}'\mathbf{u}$. Por tanto

$$\text{Var}(\hat{\beta} \mid \mathbf{X}) = (\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}' \text{Var}(\mathbf{u} \mid \mathbf{X}) \mathbf{X}(\mathbf{X}'\mathbf{X})^{-1} = (\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}'(\sigma^2\mathbf{I}_n)\mathbf{X}(\mathbf{X}'\mathbf{X})^{-1} = \sigma^2(\mathbf{X}'\mathbf{X})^{-1}.$$

Los elementos de la diagonal dan las varianzas de los coeficientes individuales; los de fuera de la diagonal, sus covarianzas. $\square$

La varianza de una pendiente individual $\hat{\beta}_j$ admite una descomposición univariante muy útil,

$$\text{Var}(\hat{\beta}_j \mid \mathbf{X}) = \frac{\sigma^2}{\text{SCT}_j(1 - R_j^2)},$$

donde $\text{SCT}_j = \sum_{i=1}^n (x_{ij} - \bar{x}_j)^2$ y R_j^2 es el R^2 de la regresión auxiliar de x_j sobre **todos los demás regresores**. De aquí se extraen tres intuiciones:

3. El Modelo de Regresión Lineal Múltiple

- Mayor varianza del error (σ^2 grande) $\Rightarrow$ estimadores menos precisos.
- Mayor variación muestral de x_j (SCT_j grande) $\Rightarrow$ estimadores más precisos.
- Más colinealidad entre x_j y los demás regresores (R_j^2 próximo a 1) $\Rightarrow$ estimadores menos precisos. El factor $1/(1 - R_j^2)$ es el **factor de inflación de la varianza** (VIF).

Como σ^2 es desconocida, la estimamos mediante la varianza residual,

$$\hat{\sigma}^2 = \frac{SCR}{n - k - 1} = \frac{\hat{\mathbf{u}}' \hat{\mathbf{u}}}{n - k - 1},$$

que es insesgada bajo RLM.1–RLM.5. El denominador $n - k - 1$ son los grados de libertad: tamaño muestral menos número de coeficientes estimados (incluido el intercepto).

3.8. R^2 y R^2 ajustado

Como en la regresión simple, la variación total de y se descompone en variación explicada y residual,

$$SCT = SCE + SCR, \quad R^2 = 1 - \frac{SCR}{SCT} \in [0, 1].$$

Hay, no obstante, una sutileza específica de la RLM: el R^2 **nunca decrece al añadir un regresor** al modelo, aun cuando ese regresor sea puro ruido. Cualquier variable nueva aporta, al menos, tanto ajuste como ninguna, porque MCO siempre podría fijar el nuevo coeficiente en cero. En consecuencia, el R^2 por sí solo no permite arbitrar entre especificaciones anidadas.

El R^2 **ajustado** penaliza la complejidad del modelo:

$$\bar{R}^2 = 1 - \frac{SCR/(n - k - 1)}{SCT/(n - 1)} = 1 - \frac{n - 1}{n - k - 1} (1 - R^2).$$

A diferencia del R^2 , el $\bar{R}^2$ puede *disminuir* cuando se añade una variable irrelevante — el coste del parámetro adicional supera la ganancia en ajuste. Resulta, por tanto, un resumen más honesto al comparar modelos con distinto número de regresores.

 Error frecuente: perseguir el R^2

Un R^2 alto no implica que el modelo sea causal, ni que prediga bien fuera de la muestra. Una regresión de `educ` sobre `educ_squared` y `educ_cubed` tendrá un R^2 próximo a 1 y ningún contenido económico. Trate al R^2 como un *resumen* de bondad de ajuste, no como un criterio de selección de modelos. El AIC y el BIC, introducidos en el Capítulo 5, son más apropiados para esta última tarea.

3.9. Sesgo de variable omitida (SVO)

El sesgo de variable omitida (SVO) es el nombre formal del problema motivado en §3.1. Supongamos que el modelo poblacional **verdadero** es

$$y = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + u, \quad \mathbb{E}[u \mid x_1, x_2] = 0,$$

pero estimamos por MCO el modelo **corto**

$$y = \tilde{\beta}_0 + \tilde{\beta}_1 x_1 + \tilde{u},$$

omitiendo x_2 . ¿Qué estima $\tilde{\beta}_1$?

i Teorema: sesgo de variable omitida

Bajo el modelo verdadero anterior y una regresión MCO de y sobre x_1 únicamente,

$$\mathbb{E}[\tilde{\beta}_1 \mid \mathbf{x}_1] = \beta_1 + \beta_2 \tilde{\delta}_1,$$

donde $\tilde{\delta}_1$ es el coeficiente de pendiente de la **regresión auxiliar** de la variable omitida x_2 sobre la variable incluida x_1 :

$$x_2 = \tilde{\delta}_0 + \tilde{\delta}_1 x_1 + v.$$

Esquema de la demostración. Por la fórmula de la regresión simple,

$$\tilde{\beta}_1 = \frac{\sum_i (x_{1i} - \bar{x}_1) y_i}{\sum_i (x_{1i} - \bar{x}_1)^2}.$$

Sustituyendo el modelo verdadero $y_i = \beta_0 + \beta_1 x_{1i} + \beta_2 x_{2i} + u_i$ y usando $\sum_i (x_{1i} - \bar{x}_1) = 0$,

$$\tilde{\beta}_1 = \beta_1 + \beta_2 \underbrace{\frac{\sum_i (x_{1i} - \bar{x}_1) x_{2i}}{\sum_i (x_{1i} - \bar{x}_1)^2}}_{=\tilde{\delta}_1} + \frac{\sum_i (x_{1i} - \bar{x}_1) u_i}{\sum_i (x_{1i} - \bar{x}_1)^2}.$$

El último término tiene esperanza condicional cero por RLM.4 del modelo *verdadero*, lo que deja $\mathbb{E}[\tilde{\beta}_1 \mid \mathbf{x}_1] = \beta_1 + \beta_2 \tilde{\delta}_1$. $\square$

El **sesgo** es el producto $\beta_2 \tilde{\delta}_1$. Se anula en dos casos:

- $\beta_2 = 0$ — la variable omitida no afecta a y en el modelo verdadero; o
- $\tilde{\delta}_1 = 0$ — la variable omitida no está correlacionada con el regresor incluido.

En cualquier otro caso, omitir una variable relevante y correlacionada contamina $\tilde{\beta}_1$.

i Extensión: más de una variable omitida

La misma lógica se extiende a cualquier número de regresores omitidos. Supongamos que el modelo verdadero tiene k regresores incluidos y m omitidos, $y = \beta_0 + \beta_1 x_1 + \dots + \beta_k x_k + \gamma_1 z_1 + \dots + \gamma_m z_m + u$, y estimamos la regresión corta sobre $(x_1, \dots, x_k)$ únicamente. El sesgo sobre una pendiente concreta $\tilde{\beta}_j$ es entonces

$$\mathbb{E}[\tilde{\beta}_j \mid \mathbf{X}] - \beta_j = \sum_{\ell=1}^m \gamma_\ell \tilde{\delta}_{j\ell},$$

donde $\tilde{\delta}_{j\ell}$ es la pendiente sobre x_j en la regresión auxiliar de la ℓ -ésima variable omitida z_ℓ sobre **todos** los regresores incluidos. En palabras: cada variable omitida aporta su propio término $\gamma_\ell \tilde{\delta}_{j\ell}$, y el sesgo total es la suma. La práctica de §3.10.2 aplica esta extensión multivariable a los dos regresores omitidos **exper** y **tenure** simultáneamente.

3.9.1. Signo del sesgo: la tabla 2×2

El signo del sesgo viene determinado por los signos de β_2 y $\tilde{\delta}_1$:

3. El Modelo de Regresión Lineal Múltiple

	$\tilde{\delta}_1 > 0$	$\tilde{\delta}_1 < 0$
$\beta_2 > 0$	Sesgo positivo	Sesgo negativo
$\beta_2 < 0$	Sesgo negativo	Sesgo positivo

Ejemplo: omitir la habilidad en una ecuación salarial

Supongamos que la ecuación salarial verdadera es $\text{wage} = \beta_0 + \beta_1 \text{educ} + \beta_2 \text{habilidad} + u$.

- Los trabajadores más hábiles ganan más, manteniendo fija la educación: $\beta_2 > 0$.
- Los trabajadores más hábiles adquieren más educación: $\tilde{\delta}_1 > 0$.
- El sesgo $\beta_2 \tilde{\delta}_1 > 0$: una regresión simple del salario sobre la educación **sobreestima** el rendimiento causal de la escolaridad.

Es el clásico «sesgo de habilidad» de la literatura de economía laboral. Una pendiente MCO ingenua de, digamos, 0,60 euros por año de escolaridad puede convivir perfectamente con un retorno verdadero de 0,40 una vez se descuenta la habilidad no observada.

Incluir una variable irrelevante no es gratis

Añadir una variable cuyo coeficiente verdadero es cero **no** introduce sesgo (la fórmula del SVO da sesgo $= 0 \cdot \tilde{\delta}_1 = 0$). Pero infla la varianza de todas las demás pendientes a través del término R_j^2 de §3.7. La regla práctica es: incluya controles que la teoría o su estrategia de identificación justifique, no regresores que casualmente «parezcan significativos».

3.10. Práctica: Regresión Múltiple en R

Trabajamos de nuevo con `wage1` — una sección cruzada de 526 trabajadores estadounidenses de mayo de 1976, distribuida con el paquete `wooldridge`. La práctica tiene tres partes: regresiones salariales anidadas, demostración numérica del SVO y una advertencia de multicolinealidad perfecta.

```
library(wooldridge)
data("wage1")
```

3.10.1. De la regresión simple a la múltiple

Reestimamos primero la regresión simple de `wage` sobre `educ` y luego añadimos `exper` y `tenure`:

```
model1 <- lm(wage ~ educ, data = wage1)
model2 <- lm(wage ~ educ + exper + tenure, data = wage1)
summary(model1)
```

Call:

```
lm(formula = wage ~ educ, data = wage1)
```


Residuals:

Min	1Q	Median	3Q	Max
-5.3396	-2.1501	-0.9674	1.1921	16.6085

Coefficients:

	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	-0.90485	0.68497	-1.321	0.187
educ	0.54136	0.05325	10.167	<2e-16 ***

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 3.378 on 524 degrees of freedom

Multiple R-squared: 0.1648, Adjusted R-squared: 0.1632

F-statistic: 103.4 on 1 and 524 DF, p-value: < 2.2e-16

```
summary(model2)
```

Call:

```
lm(formula = wage ~ educ + exper + tenure, data = wage1)
```

Residuals:

Min	1Q	Median	3Q	Max
-7.6068	-1.7747	-0.6279	1.1969	14.6536

Coefficients:

	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	-2.87273	0.72896	-3.941	9.22e-05 ***
educ	0.59897	0.05128	11.679	< 2e-16 ***
exper	0.02234	0.01206	1.853	0.0645 .
tenure	0.16927	0.02164	7.820	2.93e-14 ***

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 3.084 on 522 degrees of freedom

Multiple R-squared: 0.3064, Adjusted R-squared: 0.3024

F-statistic: 76.87 on 3 and 522 DF, p-value: < 2.2e-16

Compare el coeficiente de `educ` en las dos especificaciones. En `model1`, un año adicional de educación se asocia aproximadamente con 0,54 USD/hora más; en `model2`, el mismo coeficiente *aumenta* hasta cerca de 0,59 una vez mantenidos fijos experiencia y antigüedad. En cualquiera de los casos, $\hat{\beta}_1$ en `model2` es el rendimiento *ceteris paribus* de la educación que `model1` no logró entregar.

Añadamos ahora controles demográficos:

```
model3 <- lm(wage ~ educ + exper + tenure + female + married, data = wage1)
summary(model3)
```

3. El Modelo de Regresión Lineal Múltiple

Call:

```
lm(formula = wage ~ educ + exper + tenure + female + married,
    data = wage1)
```

Residuals:

Min	1Q	Median	3Q	Max
-7.731	-1.816	-0.500	1.050	13.928

Coefficients:

	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	-1.61815	0.72305	-2.238	0.0256 *
educ	0.55568	0.04986	11.144	< 2e-16 ***
exper	0.01874	0.01203	1.558	0.1198
tenure	0.13878	0.02114	6.566	1.25e-10 ***
female	-1.74140	0.26649	-6.535	1.52e-10 ***
married	0.55924	0.28595	1.956	0.0510 .

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 2.95 on 520 degrees of freedom

Multiple R-squared: 0.3682, Adjusted R-squared: 0.3621

F-statistic: 60.61 on 5 and 520 DF, p-value: < 2.2e-16

El coeficiente de `female` es la brecha salarial de género condicional, una vez fijadas educación, experiencia, antigüedad y estado civil; el coeficiente de `married` es la prima salarial por matrimonio condicional. Ambos son menores en magnitud que las medias condicionales brutas del Capítulo 1 — los confundidores han quedado en parte controlados.

Comparemos la bondad de ajuste a lo largo de los tres modelos anidados:

```
data.frame(
  modelo = c("solo educ", "educ+exper+tenure", "completo"),
  r2      = c(summary(model1)$r.squared,
              summary(model2)$r.squared,
              summary(model3)$r.squared),
  r2_adj  = c(summary(model1)$adj.r.squared,
              summary(model2)$adj.r.squared,
              summary(model3)$adj.r.squared)
)
```

	modelo	r2	r2_adj
1	solo educ	0.1647575	0.1631635
2	educ+exper+tenure	0.3064224	0.3024364
3	completo	0.3681887	0.3621136

Tanto el R^2 como el R^2 ajustado crecen al añadir controles — aquí cada regresor adicional está justificado por la teoría de economía laboral, de modo que el resultado no debería sorprendernos.

3.10.2. Sesgo de variable omitida con datos reales

Verifiquemos ahora numéricamente la fórmula del SVO. La regresión «corta» de `wage` sobre `educ` omite dos regresores que sabemos correlacionados con la educación: `exper` y `tenure`. Estimamos las dos regresiones auxiliares:

```
aux_exper <- lm(exper ~ educ, data = wage1)
aux_tenure <- lm(tenure ~ educ, data = wage1)
delta_exper <- coef(aux_exper)["educ"]
delta_tenure <- coef(aux_tenure)["educ"]
c(delta_exper = delta_exper, delta_tenure = delta_tenure)
```

```
delta_exper.educ delta_tenure.educ
-1.4681823      -0.1465559
```

La pendiente de `exper` sobre `educ` es **negativa**: en esta sección cruzada de 1976, los trabajadores con más estudios tienen menos experiencia laboral (algo mecánico — el tiempo dedicado a estudiar es tiempo no dedicado a trabajar). La pendiente de `tenure` sobre `educ` es ligeramente positiva en esta muestra.

Sustituyamos ahora las pendientes auxiliares y los coeficientes de la *regresión larga* en la fórmula del SVO y comparemos con la diferencia observada entre las estimaciones cortas y largas:

```
b1_short <- coef(model1)["educ"]
b1_long <- coef(model2)["educ"]
b2_long <- coef(model2)["exper"]
b3_long <- coef(model2)["tenure"]

sesgo_predicho <- b2_long * delta_exper + b3_long * delta_tenure
sesgo_observado <- b1_short - b1_long

c(sesgo_predicho = sesgo_predicho,
  diferencia_observada = sesgo_observado)
```

```
sesgo_predicho.exper diferencia_observada.educ
-0.05760581      -0.05760581
```

Los dos números deben coincidir hasta la precisión de coma flotante — esta es la extensión multivariable del SVO enunciada en §3.9 (callout *Extensión: más de una variable omitida*) en acción, aplicada aquí simultáneamente a los dos regresores omitidos `exper` y `tenure`. La pendiente de la regresión simple sobre `educ` difiere de la pendiente de la regresión múltiple en exactamente $\hat{\beta}_{\text{exper}}\hat{\delta}_{\text{exper}} + \hat{\beta}_{\text{tenure}}\hat{\delta}_{\text{tenure}}$.

Lo que la igualdad numérica demuestra es, en realidad, la **identidad muestral de Frisch–Waugh–Lovell**: las pendientes muestrales de las regresiones corta y larga se relacionan mediante exactamente la misma combinación algebraica que la fórmula poblacional del SVO, pero con $(\hat{\beta}, \hat{\delta})$ en lugar de (β, δ) . El enunciado poblacional del SVO de §3.9 es la versión en valor esperado de esta identidad muestral; el Ejercicio 3.6 pide deducir el teorema FWL subyacente.

i Por qué el sesgo es *negativo* aquí

Tanto **exper** como **tenure** tienen retornos positivos ($\hat{\beta}_2, \hat{\beta}_3 > 0$). Pero **exper** está *negativamente* correlacionada con **educ** ($\tilde{\delta}_{\text{exper}} < 0$), y este efecto domina. El producto $\hat{\beta}_2 \tilde{\delta}_{\text{exper}}$ es negativo; omitir la experiencia arrastra, pues, la pendiente de la regresión corta sobre **educ** hacia *abajo* respecto a la regresión larga. La tabla 2\$×\$2 de signos de arriba captura este patrón con exactitud.

3.10.3. Multicolinealidad perfecta

Ahora una violación deliberada de RLM.3. Imaginemos que medimos la educación en años (**educ**) y, además, creamos una copia redundante en meses (**educ_meses** = 12 * **educ**):

```
wage1$educ_meses <- 12 * wage1$educ
model_collinear <- lm(wage ~ educ + exper + tenure + educ_meses, data = wage1)
summary(model_collinear)
```

Call:

```
lm(formula = wage ~ educ + exper + tenure + educ_meses, data = wage1)
```

Residuals:

Min	1Q	Median	3Q	Max
-7.6068	-1.7747	-0.6279	1.1969	14.6536

Coefficients: (1 not defined because of singularities)

	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	-2.87273	0.72896	-3.941	9.22e-05 ***
educ	0.59897	0.05128	11.679	< 2e-16 ***
exper	0.02234	0.01206	1.853	0.0645 .
tenure	0.16927	0.02164	7.820	2.93e-14 ***
educ_meses	NA	NA	NA	NA

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 3.084 on 522 degrees of freedom

Multiple R-squared: 0.3064, Adjusted R-squared: 0.3024

F-statistic: 76.87 on 3 and 522 DF, p-value: < 2.2e-16

R no se cae — pero sí *descarta silenciosamente* **educ_meses** (su coeficiente aparece como NA). La razón es exactamente RLM.3: **educ_meses** es función lineal exacta de **educ**, así que la matriz de diseño **X** es deficiente de rango, **X'****X** es singular y **(X'X)**⁻¹ no existe. No podemos saber si el «trabajo» lo hace un cambio unitario en **educ** o un cambio de 12 unidades en **educ_meses** — los datos no contienen esa información.

⚠ Error frecuente: la trampa de «168 menos horas»

Una versión más sutil del mismo problema: en una encuesta que registra las horas semanales trabajadas (**hours**), uno podría sentirse tentado a añadir la variable **resto** = 168 - **hours**

(«horas no trabajadas a la semana», puesto que $168 = 24 \times 7$). El resultado es una relación lineal perfecta entre **hours**, **resto** y la constante: $\text{hours} + \text{resto} = 168$. Cualquier regresión que incluya las tres será deficiente de rango. Regla práctica: si puede escribir un regresor como función determinista de los demás (más la constante), está violando RLM.3.

Auto-evaluación

Seis preguntas breves de elección múltiple. Intente cada una antes de desplegar la respuesta.

💡 P1. Interpretación de una pendiente RLM

En el modelo $y = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + u$, el coeficiente β_1 mide:

- A. El cambio total en y cuando x_1 aumenta una unidad, incluyendo cualquier efecto indirecto a través de x_2 .
- B. El cambio esperado en y ante un aumento unitario de x_1 , manteniendo fijo x_2 .
- C. La correlación entre y y x_1 .
- D. El cambio en y cuando x_1 y x_2 suben ambos en una unidad.

Respuesta: B. Toda pendiente RLM es un efecto parcial: aísla la variación de y asociada a x_1 una vez mantenidos fijos los demás regresores del modelo.

💡 P2. El supuesto de media condicional cero

RLM.4 exige:

- A. Únicamente $\text{Cov}(x_1, u) = 0$.
- B. $\text{Var}(u \mid \mathbf{X}) = \sigma^2$.
- C. $\mathbb{E}[u \mid x_1, x_2, \dots, x_k] = 0$.
- D. Que u sea normal.

Respuesta: C. RLM.4 es la condición de media condicional cero respecto a *todos* los regresores simultáneamente. Es lo que garantiza la insesgadez de MCO.

💡 P3. Signo del SVO

En una regresión salarial omitimos la habilidad innata. Supongamos que (i) los trabajadores más hábiles ganan más, manteniendo fija la educación, y (ii) los trabajadores más hábiles adquieren más educación. El coeficiente MCO sobre **educ** estará:

- A. Sesgado hacia abajo.
- B. Insesgado — MCO siempre lo es.
- C. Sesgado hacia arriba (sobreestimando el rendimiento de la educación).
- D. Con signo indeterminado.

Respuesta: C. Con $\beta_{\text{habilidad}} > 0$ y $\tilde{\delta}_{\text{educ}} > 0$, el sesgo $\beta_2 \tilde{\delta}_1$ es positivo: la regresión corta sobreestima el rendimiento de la escolaridad.

💡 P4. ¿Qué supuesto descarta la colinealidad perfecta?

- A. RLM.1 (linealidad en parámetros).
- B. RLM.3 (no relación lineal exacta entre regresores).
- C. RLM.4 (media condicional cero).
- D. RLM.5 (homocedasticidad).

Respuesta: B. RLM.3 es el supuesto de invertibilidad de $\mathbf{X}'\mathbf{X}$. Violarlo deja la fórmula MCO indefinida; R descartará una de las variables conflictivas e informará NA.

💡 P5. R^2 frente a R^2 ajustado

¿Qué afirmación es verdadera cuando se añade un regresor irrelevante a un modelo?

- A. Tanto R^2 como R^2 ajustado siempre suben.
- B. R^2 siempre sube (en sentido débil), pero R^2 ajustado puede bajar.
- C. R^2 puede bajar, pero R^2 ajustado siempre sube.
- D. Ambos siempre bajan.

Respuesta: B. El R^2 no puede disminuir porque MCO siempre podría fijar el nuevo coeficiente a cero. El R^2 ajustado resta una penalización por parámetro; si la variable nueva no mejora suficientemente el ajuste, la penalización gana.

💡 P6. ¿Cuándo es nulo el SVO?

El SVO sobre la pendiente de x_1 es exactamente cero cuando:

- A. El tamaño muestral es grande.
- B. El R^2 supera 0,5.
- C. O bien la variable omitida no afecta a y , o bien no está correlacionada con x_1 .
- D. Los errores son normales.

Respuesta: C. La fórmula del SVO $\beta_2 \tilde{\delta}_1$ se anula siempre que uno de los dos factores sea cero. Ni muestras grandes ni un R^2 alto corrigen el sesgo de variable omitida.

Ejercicios

Ejercicio 3.1 — Interpretar una RLM estimada. Un investigador reporta

$$\widehat{\text{wage}} = -2,87 + 0,599 \text{educ} + 0,022 \text{exper} + 0,169 \text{tenure}$$

estimada sobre **wage1**. (a) Interprete cada coeficiente de pendiente en lenguaje llano. (b) Prediga el salario por hora de un trabajador con 16 años de educación, 5 años de experiencia y 3 de antigüedad. (c) ¿Por qué *no* debe leer $\hat{\beta}_1 = 0,599$ como el rendimiento causal de la escolaridad?

💡 Ver respuesta

- (a) Cada pendiente es un efecto parcial: un año adicional de educación se asocia con 0,60 USD/hora más, *manteniendo fijas experiencia y antigüedad*; análogamente para **exper** y **tenure**. (b) $\widehat{\text{wage}} = -2,87 + 0,599 \cdot 16 + 0,022 \cdot 5 + 0,169 \cdot 3 \approx 7,32$ USD/hora. (c)

Porque es improbable que RLM.4 se cumpla aquí — la habilidad, el entorno familiar y la calidad escolar siguen en u y están correlacionadas con educ . La pendiente es el mejor resumen lineal *dentro* del modelo, no un coeficiente causal.

Ejercicio 3.2 — Detectar colinealidad perfecta. Para cada uno de los siguientes conjuntos de regresores, decida si se viola RLM.3. Si es así, identifique la dependencia lineal exacta.

- (a) $\{\text{const}, \text{age}, \text{age_squared}\}$.
- (b) $\{\text{const}, \text{female}, \text{male}\}$, donde $\text{male} = 1 - \text{female}$.
- (c) $\{\text{const}, \text{exper}, \text{tenure}, \text{exper} + \text{tenure}\}$.
- (d) $\{\text{const}, \text{educ}, \log(\text{educ})\}$ — suponga $\text{educ} > 0$.

💡 Ver respuesta

- (a) No hay violación: age^2 no es función *lineal* de age . (b) Violación: $\text{female} + \text{male} = 1$, la columna constante. (c) Violación: el cuarto regresor es la suma del segundo y el tercero. (d) No hay violación: $\log$ es no lineal, así que RLM.3 se mantiene (aunque una alta colinealidad puede inflar las varianzas).

Ejercicio 3.3 — Signo del SVO a partir de la teoría. Desea estimar el efecto de la asistencia a clase sobre la nota final pero omite el *esfuerzo del estudiante*. Suponga que el esfuerzo eleva la nota y está positivamente correlacionado con la asistencia. Prediga el signo del sesgo sobre el coeficiente de asistencia en una regresión corta que omita el esfuerzo y explíquelo en una frase.

💡 Ver respuesta

Con $\beta_{\text{esfuerzo}} > 0$ y $\tilde{\delta}_{\text{asistencia}} > 0$, el sesgo $\beta_2 \tilde{\delta}_1$ es **positivo**: la regresión corta sobreestima el efecto de la asistencia porque parte del efecto aparente es, en realidad, el efecto del esfuerzo (no observado) correlacionado con la asistencia.

Ejercicio 3.4 — R^2 ajustado que cae. Construya un pequeño ejemplo numérico (o argumente analíticamente) que muestre cómo añadir un regresor irrelevante puede dejar el R^2 prácticamente invariable mientras hace caer el R^2 ajustado. Use la identidad $\bar{R}^2 = 1 - (n-1)(1-R^2)/(n-k-1)$ para explicar por qué.

💡 Ver respuesta

Con $n = 100$, suponga $R^2 = 0,30$ con $k = 3$ regresores: $\bar{R}^2 = 1 - 99 \cdot 0,70/96 \approx 0,278$. Añadimos un cuarto regresor irrelevante que eleva R^2 a 0,301: $\bar{R}^2 = 1 - 99 \cdot 0,699/95 \approx 0,272$. El R^2 sube 0,001 pero $\bar{R}^2$ baja 0,006 porque $(n-1)/(n-k-1)$ crece más rápido de lo que decrece $1 - R^2$. Este es el sentido formal en que el $\bar{R}^2$ penaliza la complejidad.

Ejercicio 3.5 — SVO por simulación. Genere $n = 1000$ observaciones del modelo $y = 1 + 2x_1 + 3x_2 + u$, con $x_1 \sim \mathcal{N}(0, 1)$, $x_2 = 0,5x_1 + 0,5z$, $z \sim \mathcal{N}(0, 1)$ independiente de x_1 , y $u \sim \mathcal{N}(0, 1)$ independiente de todo lo demás. (a) Estime la regresión corta de y sobre x_1 solo y la regresión larga de y sobre (x_1, x_2) . (b) Use la fórmula del SVO para predecir la diferencia entre las dos pendientes sobre x_1 y verifíquela numéricamente. Pista: $\tilde{\delta}_1 = 0,5$ por construcción.

La respuesta completa figura en la edición del docente.

3. El Modelo de Regresión Lineal Múltiple

Ejercicio 3.6 — **Particionamiento de Frisch–Waugh–Lovell.** Sea $\tilde{x}_1$ los residuos de regresar x_1 sobre los demás regresores $(x_2, \dots, x_k)$ y la constante. Demuestre, usando las ecuaciones normales de MCO, que el coeficiente de la regresión múltiple sobre x_1 coincide con la pendiente de una regresión simple de y sobre $\tilde{x}_1$. Verifique su deducción numéricamente con `wage1`: regrese `educ` sobre `exper` y `tenure`, conserve los residuos y compruebe que regresar `wage` sobre esos residuos reproduce $\hat{\beta}_{\text{educ}}$ de la regresión larga de §3.10.

La respuesta completa figura en la edición del docente.

Ejercicio 3.7 — **El retorno a `bwght`.** En el Capítulo 2 §2.11 se estimó una regresión simple del peso al nacer sobre el tabaquismo materno y se advirtió que la pendiente sobre `cigs` podía estar contaminada por variables omitidas (renta, educación o nutrición de la madre). Use ahora el instrumental de la regresión múltiple para abordar esa advertencia.

- (a) Usando `bwght` del paquete `wooldridge`, estime

$$\text{bwght} = \beta_0 + \beta_1 \text{cigs} + \beta_2 \text{motheduc} + \beta_3 \text{fatheduc} + \beta_4 \text{parity} + u.$$

- Reporte $\hat{\beta}_1$ y compárelo con la pendiente de la regresión simple $-0,51$ del Capítulo 2 §2.11. ¿Se ha desplazado hacia cero, alejado de cero o permanece esencialmente igual?
- (b) Aplique la extensión multivariable del SVO de §3.9. Estime las tres regresiones auxiliares de `motheduc`, `fatheduc` y `parity` sobre `cigs`, y utilice los $\tilde{\delta}_j$ resultantes junto con los coeficientes de la regresión larga $\hat{\beta}_2, \hat{\beta}_3, \hat{\beta}_4$ para predecir la diferencia entre las pendientes de la regresión simple y la múltiple sobre `cigs`. Verifique que su diferencia predicha coincide numéricamente con la observada (es la identidad FWL en acción, exactamente como en el ejemplo salarial de §3.10.2).
- (c) ¿Cambió la inclusión de los controles su interpretación causal de $\hat{\beta}_1$ como el efecto del tabaquismo materno sobre el peso al nacer? ¿De qué supuesto entre RLM.1–RLM.4 sigue dependiendo y qué variables omitidas continúan amenazándolo?

La respuesta completa figura en la edición del docente.

Autoevaluación interactiva: `LEARNR/03_multiple_linear_regression.Rmd`.

Inferencia

Objetivos

Al terminar este capítulo, el lector debería ser capaz de:

- Enunciar los supuestos del Modelo Lineal Clásico (RLM.1–RLM.6) y explicar qué añade el supuesto de normalidad RLM.6 a Gauss–Markov.
- Derivar la distribución muestral de $\hat{\beta}_j$ bajo el MLC y explicar por qué la estandarización conduce a un estadístico t_{n-k-1} en lugar de una normal estándar.
- Construir e interpretar un intervalo de confianza del $(1 - \alpha) \times 100\%$ para un coeficiente individual.
- Ejecutar un contraste de hipótesis en cuatro pasos (bilateral y unilateral) para un coeficiente individual, y leer el p -valor correspondiente.
- Realizar un contraste F de significatividad conjunta, distinguiendo el F global del contraste restringido frente a no restringido.
- Reproducir todo lo anterior en R utilizando `summary()`, `confint()`, `qt()`, `qf()`, `pt()`, `pf()`, `anova()` y aritmética manual sobre el modelo ajustado.

Pregunta motivadora

*Una vez que mantenemos fijas educación, experiencia y edad, ¿importan **conjuntamente** la puntuación de IQ y los años de escolarización para el salario mensual — o podría haber surgido por azar la aportación aparente de la habilidad cognitiva y la educación?*

Vimos IQ brevemente en el Capítulo 3 como candidato a *proxy* de la habilidad no observada. Ahora debemos decidir, formalmente, si los coeficientes que estimamos están lo bastante alejados de cero como para tomarlos en serio. Las herramientas del capítulo — estadísticos t , p -valores, intervalos de confianza y test F — están diseñadas precisamente para esa decisión.

4.1. De la estimación a la inferencia

Los Capítulos 2 y 3 produjeron **estimaciones puntuales** $\hat{\beta}_j$ a partir de una muestra. Estos números son aleatorios: una muestra distinta habría dado números distintos. La cuestión de la inferencia es si lo que aprendimos de *nuestra* muestra nos permite decir algo creíble sobre el parámetro poblacional desconocido β_j .

La inferencia estadística proporciona dos herramientas complementarias (Wooldridge 2020):

4. Inferencia

1. **Intervalos de confianza.** Un rango de valores plausibles para el parámetro desconocido, con una probabilidad de cobertura calibrada a largo plazo.
2. **Contrastes de hipótesis.** Un procedimiento formal para decidir si los datos son compatibles con una afirmación específica sobre el parámetro — la más frecuente, que el parámetro es igual a cero.

Ambas herramientas dependen de conocer la *distribución muestral* de $\hat{\beta}_j$. Bajo Gauss–Markov solo conocemos su media (β_j) y su varianza; no conocemos su forma. Para decir algo preciso sobre probabilidades — “la probabilidad de observar un coeficiente tan alejado de cero, si la verdad es cero, es inferior al 1 %” — necesitamos una distribución. Eso es lo que aporta el siguiente supuesto.

4.2. Los supuestos del Modelo Lineal Clásico (MLC)

Gauss–Markov nos dio insesgadez, una varianza con forma cerrada y la propiedad BLUE (ELIO) de MCO. Para inferencia exacta (en muestras finitas) necesitamos un supuesto adicional.

i Definición: RLM.6 (Normalidad del término de error)

Condiciona a los regresores $\mathbf{X}$, el error poblacional u se distribuye normalmente con media cero y varianza constante:

$$u \mid \mathbf{X} \sim \mathcal{N}(0, \sigma^2).$$

El conjunto completo RLM.1–RLM.6 se denomina **supuestos del Modelo Lineal Clásico (MLC)**.

¿Por qué normalidad, y de dónde sale? En muchos contextos aplicados u es la suma de un gran número de factores omitidos pequeños e independientes, y un razonamiento basado en el teorema central del límite sugiere que su distribución debería ser aproximadamente acampanada. El supuesto es fuerte: puede fallar gravemente con variables dependientes sesgadas como salarios o conteos. Veremos en el Capítulo 6 que tomar log de la variable dependiente suele bastar para que los residuos parezcan simétricos.

La recompensa es grande. Bajo RLM.1–RLM.6, el estimador MCO hereda la normalidad de u :

$$\hat{\beta}_j \mid \mathbf{X} \sim \mathcal{N}(\beta_j, \text{Var}(\hat{\beta}_j)).$$

Esta es una afirmación *exacta* que se cumple para cualquier tamaño muestral, no solo asintóticamente. Con n grande, el teorema central del límite proporciona aproximadamente la misma conclusión incluso sin RLM.6, pero solo el MLC nos da inferencia exacta en muestras pequeñas.

⚠ Error frecuente: confundir la normalidad de u con la normalidad de y

RLM.6 es una afirmación sobre el *error* u , condicional a los regresores. **No** es la afirmación de que la distribución marginal de y sea normal. Los salarios, por ejemplo, son asimétricos a la derecha; eso no contradice por sí mismo RLM.6, porque la componente sistemática $\beta_0 + \beta_1 x_1 + \dots$ puede absorber la asimetría.

4.3. La distribución t

Si σ^2 fuera conocida podríamos estandarizar $\hat{\beta}_j$ directamente:

$$Z = \frac{\hat{\beta}_j - \beta_j}{\sqrt{\text{Var}(\hat{\beta}_j)}} \sim \mathcal{N}(0, 1).$$

En la práctica σ^2 es desconocida y se sustituye por el estimador MCO $\hat{\sigma}^2 = \text{SSR}/(n - k - 1)$. Sustituir $\hat{\sigma}^2$ en el error estándar introduce una fuente adicional de variabilidad, y el estadístico estandarizado deja de ser normal estándar: se distribuye según una t con $n - k - 1$ grados de libertad,

$$t = \frac{\hat{\beta}_j - \beta_j}{\text{se}(\hat{\beta}_j)} \sim t_{n-k-1}.$$

La distribución t es simétrica, acampanada y centrada en cero, pero tiene **colas más pesadas** que $\mathcal{N}(0, 1)$ — reflejo de la incertidumbre adicional al estimar σ^2 . A medida que los grados de libertad $n - k - 1$ crecen, las colas se adelgazan y t_{n-k-1} converge a $\mathcal{N}(0, 1)$. Para $n - k - 1 \geq 120$ las dos distribuciones son prácticamente indistinguibles; en muestras pequeñas la t es notablemente más ancha.

Esa es toda la razón por la que este capítulo usa valores críticos t como 2,013 (para $\alpha = 0,05$, $df = 45$) en lugar del familiar 1,96 de la tabla normal.

4.4. Dos maneras de equivocarse

Un jurado puede condenar a un inocente, o puede dejar libre a un culpable. Ambos errores son malos y el sistema judicial está construido para sopesarlos. Un contraste de hipótesis se enfrenta exactamente a la misma estructura 2×2 .

	H_0 verdadera	H_0 falsa
Rechazar H_0	Error de tipo I (tamaño α)	Rechazo correcto (potencia $1 - \beta$)
No rechazar H_0	No rechazo correcto	Error de tipo II (probabilidad β)

Un **error de tipo I** consiste en rechazar una nula que en realidad es verdadera — el equivalente estadístico de condenar a un inocente. La probabilidad de cometerlo, calculada bajo H_0 , se denomina **tamaño** del contraste:

$$\alpha = \Pr(\text{rechazar } H_0 \mid H_0 \text{ verdadera}).$$

Las elecciones convencionales $\alpha = 0,10, 0,05, 0,01$ son precisamente las tasas de error de tipo I que estamos dispuestos a tolerar. Obsérvese el carácter **condicional**: α *no* es la probabilidad de que la nula sea verdadera dados los datos, ni la probabilidad de rechazar en un estudio concreto. Es la frecuencia, a largo plazo, de rechazos incorrectos *entre los estudios en los que la nula resulta ser verdadera*.

Un **error de tipo II** consiste en no rechazar una nula que en realidad es falsa — el equivalente a dejar libre a un culpable. Su probabilidad se denota β . Su complementario, $1 - \beta$, es la **potencia**

4. Inferencia

del contraste: la probabilidad de detectar un efecto real cuando éste existe. A diferencia de α , la potencia depende de tres cosas: cuán grande es el efecto verdadero, cuán ruidosos son los datos y cuántas observaciones tenemos. Los estudios con potencia insuficiente pasan por alto efectos reales de manera rutinaria; por eso un resultado “no significativo” en una muestra pequeña rara vez es informativo.

No hay almuerzo gratis. Manteniendo n y el proceso generador de datos fijos, bajar α (un contraste más estricto) eleva β (más efectos reales no detectados), y viceversa. La única manera de reducir *simultáneamente* ambas probabilidades de error es recopilar más datos — que estrechan la distribución muestral bajo H_0 y encogen ambas colas.

⚠ Error frecuente: confundir α con p , y “tamaño” con “significatividad”

El tamaño α se fija *antes* de ver los datos — es la tasa de error de tipo I a largo plazo que estamos dispuestos a aceptar. El p -valor se calcula *después* de ver los datos — es el menor α al que los datos llevarían a rechazar. Son dos objetos conceptualmente distintos, aunque comparten escala. De igual modo, el “nivel de significatividad del 5 %” de un artículo se refiere a un α elegido, no a la probabilidad de error de ese estudio en concreto: cada estudio individual o rechazó correctamente o no lo hizo, y nunca lo sabremos.

Utilizaremos el vocabulario de “tamaño” y “potencia” repetidamente más adelante — en particular en §“El test F de significatividad conjunta”, donde el tamaño de un procedimiento *combinado* (contrastar varias restricciones a la vez) es precisamente lo que motiva el test F en primer lugar.

4.5. Intervalos de confianza

i Definición: intervalo de confianza para β_j

Un intervalo de confianza del $(1 - \alpha) \times 100\%$ para β_j es

$$\hat{\beta}_j \pm t_{\alpha/2, n-k-1} \cdot \text{se}(\hat{\beta}_j),$$

donde $t_{\alpha/2, n-k-1}$ es el valor crítico de la distribución t que deja probabilidad $\alpha/2$ en cada cola.

Para el intervalo del 95 % canónico, $\alpha = 0,05$ y el valor crítico es $t_{0,025, n-k-1}$. Con muestras moderadamente grandes éste se acerca a 1,96, pero en muestras pequeñas puede ser apreciablemente mayor.

⚠ Error frecuente: malinterpretar el “95 %”

Un intervalo de confianza del 95 % es una afirmación sobre el **procedimiento**, no sobre el intervalo concreto. Si extrajésemos muchas muestras independientes y construyésemos un intervalo en cada una, aproximadamente el 95 % de esos intervalos contendrían el verdadero β_j . **No** es correcto decir que hay un 95 % de probabilidad de que el intervalo concreto $[L, U]$ que hemos calculado de nuestra única muestra contenga β_j — β_j es un número fijo (aunque desconocido), y el intervalo realizado o lo cubre o no lo cubre.

Los intervalos de confianza y los contrastes de hipótesis bilaterales son dos caras de la misma moneda: un IC del $(1 - \alpha)$ para β_j contiene cero **si y solo si** el test t bilateral de $H_0 : \beta_j = 0$ al nivel α no rechaza.

4.6. Contraste de hipótesis en cuatro pasos

Contrastamos afirmaciones sobre un único coeficiente β_j usando un procedimiento estándar en cuatro pasos. Sea c el valor hipotetizado (habitualmente $c = 0$, “la variable no importa”).

Paso 1. Plantear H_0 y H_1 . Hay tres formas útiles:

- *Bilateral:* $H_0 : \beta_j = c$ frente a $H_1 : \beta_j \neq c$.
- *Unilateral a la derecha:* $H_0 : \beta_j \leq c$ frente a $H_1 : \beta_j > c$.
- *Unilateral a la izquierda:* $H_0 : \beta_j \geq c$ frente a $H_1 : \beta_j < c$.

La elección entre unilateral y bilateral viene determinada por la **teoría económica**, no por los datos: si la teoría nos dice *a priori* que β_j no puede ser negativo, procede un test unilateral.

Paso 2. Elegir un nivel de significación α y leer el valor crítico. Las elecciones estándar son $\alpha = 0,10, 0,05, 0,01$. El valor crítico es

- $t_{\alpha/2, n-k-1}$ para un test bilateral,
- $t_{\alpha, n-k-1}$ para un test unilateral.

Paso 3. Calcular el estadístico t .

$$t = \frac{\hat{\beta}_j - c}{\text{se}(\hat{\beta}_j)}.$$

Para el caso por defecto $c = 0$ se reduce a $t = \hat{\beta}_j / \text{se}(\hat{\beta}_j)$, que es exactamente el número que R muestra en la tercera columna de `summary(lm(...))`.

Paso 4. Comparar y concluir.

- Bilateral: rechazar H_0 si $|t| > t_{\alpha/2, n-k-1}$.
- Unilateral a la derecha: rechazar H_0 si $t > t_{\alpha, n-k-1}$.
- Unilateral a la izquierda: rechazar H_0 si $t < -t_{\alpha, n-k-1}$.

Si rechazamos H_0 decimos que el coeficiente es *estadísticamente significativo* al nivel elegido. Si no rechazamos decimos que los datos son *compatibles con H_0* — nunca “aceptamos” H_0 , porque el test se diseñó para detectar desviaciones, no para confirmarla.

⚠ Error frecuente: significatividad estadística no es significatividad económica

Un coeficiente puede ser estadísticamente significativo (p -valor pequeño) pero económicamente diminuto, y un coeficiente puede ser económicamente grande pero estadísticamente no significativo en una muestra pequeña. Informe siempre de los dos aspectos: la *magnitud* de $\hat{\beta}_j$ en las unidades del problema y la precisión con la que se estima. Una rentabilidad del 1 % por un año adicional de educación y otra del 10 % son ambas “significativamente distintas de cero” en una muestra grande, pero solo una de ellas es relevante para la política pública.

4.7. El p -valor

El procedimiento de los cuatro pasos nos obliga a fijar α por adelantado. Una alternativa más informativa es presentar el p -valor.

i Definición: p -valor

El p -valor es la probabilidad, calculada *bajo* H_0 , de observar un estadístico al menos tan extremo como el que hemos obtenido. Equivalentemente, es el menor nivel de significación α al que rechazaríamos H_0 .

Para un test bilateral de $H_0 : \beta_j = 0$ con estadístico calculado t ,

$$p = 2 \cdot \Pr(T_{n-k-1} > |t|) = 2 [1 - F_t(|t|; n - k - 1)],$$

donde F_t es la función de distribución de la t_{n-k-1} . Para un test unilateral el p -valor es exactamente la mitad del anterior (cuando el signo de $\hat{\beta}_j$ coincide con la alternativa).

Reglas prácticas convencionales (Wooldridge 2020):

- $p < 0,01$: evidencia fuerte contra H_0 (rechazar al nivel del 1 %).
- $p < 0,05$: evidencia contra H_0 (rechazar al nivel del 5 %).
- $p < 0,10$: evidencia débil contra H_0 (rechazar al nivel del 10 %).
- $p \geq 0,10$: evidencia insuficiente para rechazar H_0 .

R muestra p -valores bilaterales por defecto en la columna $\Pr(>|t|)$ de `summary(lm(...))`, junto con asteriscos de significatividad: *** para $p < 0,001$, ** para $p < 0,01$, * para $p < 0,05$, . para $p < 0,10$.

! Error frecuente: un p -valor pequeño no es un certificado causal

La significatividad estadística nos dice que es improbable que $\hat{\beta}_j$ haya surgido por ruido muestral si la verdad fuese cero. **No** dice nada sobre si x_j *causa* y . La interpretación causal sigue exigiendo el supuesto poblacional $\mathbb{E}[u \mid \mathbf{X}] = 0$ (RLM.4) — ningún p -valor, por pequeño que sea, puede salvar una regresión contaminada por sesgo de variable omitida o por causalidad inversa.

4.8. El test F de significatividad conjunta

Los tests t sobre un único coeficiente son la herramienta adecuada cuando tenemos un parámetro en mente. Sin embargo, a menudo la pregunta es si **varios** coeficientes son conjuntamente cero:

- “¿Son *educ* y *IQ* conjuntamente irrelevantes para los salarios una vez que controlamos por horas, experiencia y edad?”
- “¿Aportan algo al modelo los términos cuadráticos de un polinomio en *exper*?”
- “¿Importa *alguno* de los regresores — merece la pena correr la regresión global?”

Estas son hipótesis conjuntas, y requieren un contraste conjunto. Hacer q tests t separados **no** responde a la pregunta conjunta, por dos razones. Primera, cada test t individual tiene tamaño α , pero el procedimiento *combinado* — “rechazar la nula conjunta si rechaza alguno de los tests t individuales” — tiene una tasa de error de tipo I que crece con el número de comparaciones. Con $q = 2$ tests independientes, cada uno de tamaño 0,05, la probabilidad global de rechazar al menos una nula verdadera es aproximadamente $1 - (1 - 0,05)^2 \approx 0,10$, no 0,05. Segunda, dos coeficientes pueden ser conjuntamente informativos aun cuando cada uno sea individualmente marginal; correrlos por separado tira a la basura la información contenida en su *combinación*.

4.8.1. Modelos restringido y no restringido

Sea el modelo **no restringido** la regresión con k pendientes,

$$y = \beta_0 + \beta_1 x_1 + \cdots + \beta_k x_k + u.$$

Supongamos que queremos contrastar que las últimas q pendientes son cero,

$$H_0 : \beta_{k-q+1} = \beta_{k-q+2} = \cdots = \beta_k = 0,$$

frente a la alternativa de que *al menos uno* de ellos sea distinto de cero. El modelo **restringido** impone H_0 eliminando esos q regresores:

$$y = \beta_0 + \beta_1 x_1 + \cdots + \beta_{k-q} x_{k-q} + u.$$

Sean SSR_U y SSR_R las sumas de cuadrados de los residuos de los modelos no restringido y restringido. Como eliminar regresores nunca reduce la SSR, siempre se cumple $SSR_R \geq SSR_U$; la cuestión es si la *brecha* es suficientemente grande para ser incompatible con H_0 .

i Definición: el estadístico F

Bajo H_0 y RLM.1–RLM.6,

$$F = \frac{(SSR_R - SSR_U)/q}{SSR_U/(n - k - 1)} \sim F_{q, n-k-1}.$$

Rechazar H_0 al nivel α si $F > F_{q, n-k-1, \alpha}$, el valor crítico superior- α de la distribución F con q y $n - k - 1$ grados de libertad.

Una formulación equivalente utiliza el R^2 de cada modelo:

$$F = \frac{(R_U^2 - R_R^2)/q}{(1 - R_U^2)/(n - k - 1)}.$$

Ambas fórmulas son algebraicamente idénticas siempre que y sea la misma en ambas regresiones; difieren solo cuando el modelo restringido tiene una variable dependiente distinta (por ejemplo, un contraste F de $\log y$ frente a y , que la fórmula anterior **no** cubre).

4.8.2. El test F global

Un caso particular es el contraste de que **todas** las pendientes son cero,

$$H_0 : \beta_1 = \beta_2 = \cdots = \beta_k = 0.$$

Aquí el modelo restringido es la regresión sobre una constante, y $R_R^2 = 0$. El estadístico F se reduce a

$$F = \frac{R^2/k}{(1 - R^2)/(n - k - 1)},$$

4. Inferencia

que es exactamente el número que R imprime en la línea final de `summary(lm(...))` bajo “F-statistic”, junto con su p -valor.

4.8.3. F frente a t : una identidad útil

Para una *única* restricción ($q = 1$), el estadístico F es igual al cuadrado del estadístico t correspondiente:

$$F = t^2, \quad F_{1, n-k-1} = (t_{n-k-1})^2.$$

Los contrastes t y F ofrecen conclusiones idénticas en este caso; la maquinaria F solo resulta estrictamente necesaria cuando $q \geq 2$.

4.9. Práctica: Inferencia en R

Trabajamos con `wage2` del paquete **wooldridge**: una sección cruzada de $n = 935$ hombres estadounidenses procedentes del *National Longitudinal Survey* de 1980, con información sobre salario mensual (`wage`), horas semanales (`hours`), una puntuación en un test de cociente intelectual (IQ), años de escolarización (`educ`), años de experiencia laboral (`exper`), antigüedad en el empleo actual (`tenure`) y edad. El objetivo es trasladar la maquinaria inferencial de los cuatro pasos a órdenes de R y luego comprobar que los atajos integrados dan las mismas respuestas.

```
library(wooldridge)
data("wage2")
```

4.9.1. Una primera regresión y su `summary()`

Empezamos con una regresión simple de salario mensual sobre horas semanales:

```
model1 <- lm(wage ~ hours, data = wage2)
summary(model1)
```

Call:

```
lm(formula = wage ~ hours, data = wage2)
```

Residuals:

Min	1Q	Median	3Q	Max
-839.72	-287.21	-52.38	200.46	2131.26

Coefficients:

	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	981.315	81.575	12.03	<2e-16 ***
hours	-0.532	1.832	-0.29	0.772

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1


```
Residual standard error: 404.6 on 933 degrees of freedom
Multiple R-squared: 9.033e-05, Adjusted R-squared: -0.0009814
F-statistic: 0.08429 on 1 and 933 DF, p-value: 0.7716
```

El bloque `summary()` informa, para cada coeficiente, de la estimación $\hat{\beta}_j$, su error estándar $se(\hat{\beta}_j)$, el estadístico $t \hat{\beta}_j / se(\hat{\beta}_j)$ y el p -valor bilateral. Al pie vemos el estadístico F global y su p -valor, que contrastan $H_0 : \beta_{\text{hours}} = 0$ en este caso con un único regresor.

Pasemos ahora a una especificación más rica:

```
model2 <- lm(wage ~ hours + educ + exper + IQ + age, data = wage2)
summary(model2)
```

Call:

```
lm(formula = wage ~ hours + educ + exper + IQ + age, data = wage2)
```

Residuals:

Min	1Q	Median	3Q	Max
-883.49	-238.11	-47.36	190.09	2144.24

Coefficients:

	Estimate	Std. Error	t value	Pr(> t)	
(Intercept)	-778.4403	171.2506	-4.546	6.20e-06	***
hours	-2.5406	1.6811	-1.511	0.13104	
educ	52.4505	7.2981	7.187	1.36e-12	***
exper	10.9390	3.7196	2.941	0.00335	**
IQ	5.2917	0.9383	5.640	2.26e-08	***
age	14.4836	4.6657	3.104	0.00197	**

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

```
Residual standard error: 368.9 on 929 degrees of freedom
Multiple R-squared: 0.1722, Adjusted R-squared: 0.1678
F-statistic: 38.66 on 5 and 929 DF, p-value: < 2.2e-16
```

Leemos la tabla línea por línea: `educ` e `IQ` tienen estadísticos t grandes y p -valores diminutos, así que cada uno es individualmente significativo al nivel del 1% incluso tras controlar por los demás. `hours` es negativa y significativa (los hombres que trabajan más horas ganan ligeramente menos *por hora trabajada a la semana*, condicional al resto de covariables — una pista de que las horas correlacionan con la composición ocupacional). `exper` y `age` resultan estadísticamente indistinguibles de cero en esta especificación.

4.9.2. Intervalos de confianza manuales con `qt()`

Extraemos coeficientes y errores estándar de manera programática y construimos un IC del 95% a mano.

4. Inferencia

```
beta_hat <- coef(model2)
se_hat    <- summary(model2)$coefficients[, "Std. Error"]

n <- nobs(model2)
k <- length(beta_hat) - 1      # número de coeficientes pendiente
df <- n - k - 1

t_crit <- qt(0.975, df)
t_crit                                     # valor crítico  $t_{\{0.025, df\}}$ 
```

```
[1] 1.962521
```

El valor crítico se acerca a 1,96 porque los grados de libertad son grandes, pero no es idéntico. El IC manual del 95 % para β_{IQ} es

```
IQ_LB <- beta_hat["IQ"] - t_crit * se_hat["IQ"]
IQ_UB <- beta_hat["IQ"] + t_crit * se_hat["IQ"]
c(lower = IQ_LB, upper = IQ_UB)
```

```
lower.IQ upper.IQ
3.450211 7.133145
```

y para β_{hours} :

```
hours_LB <- beta_hat["hours"] - t_crit * se_hat["hours"]
hours_UB <- beta_hat["hours"] + t_crit * se_hat["hours"]
c(lower = hours_LB, upper = hours_UB)
```

```
lower.hours upper.hours
-5.8397528   0.7584696
```

El atajo integrado entrega todos los intervalos en una llamada:

```
confint(model2, level = 0.95)
```

	2.5 %	97.5 %
(Intercept)	-1114.523218	-442.3574662
hours	-5.839753	0.7584696
educ	38.127749	66.7731627
exper	3.639234	18.2387119
IQ	3.450211	7.1331452
age	5.327113	23.6400802

Los números de las filas `IQ` y `hours` coinciden con lo que calculamos manualmente. Obsérvese que el intervalo del 95 % para `IQ` excluye el cero (coherente con el p -valor pequeño en `summary()`), mientras que los intervalos para `exper` y `age` sí contienen cero (coherente con su no significatividad).

4.9.3. Test t manual para un coeficiente individual

Supongamos que queremos contrastar $H_0 : \beta_{\text{educ}} = 0$ frente a la alternativa bilateral al nivel del 5 %. Paso a paso:

```
b_educ <- coef(model2)["educ"]
se_educ <- summary(model2)$coefficients["educ", "Std. Error"]

t_stat <- b_educ / se_educ
p_value <- 2 * pt(-abs(t_stat), df) # p-valor bilateral

c(t = t_stat, p = p_value)
```

```
      t.educ      p.educ
7.186848e+00 1.361083e-12
```

```
summary(model2)$coefficients["educ", c("t value", "Pr(>|t|)")]
```

```
      t value      Pr(>|t|)
7.186848e+00 1.361083e-12
```

Las dos últimas líneas son idénticas (salvo redondeo): el cálculo manual reproduce exactamente lo que imprime R. El estadístico t está muy por encima del valor crítico del 5 %, aproximadamente 1,96, así que rechazamos H_0 . La educación tiene un efecto parcial estadísticamente significativo sobre los ingresos mensuales incluso tras controlar por horas, experiencia, cociente intelectual y edad.

4.9.4. Test F manual de significatividad conjunta

Pasemos a la pregunta principal del capítulo: ¿son `educ` e `IQ` *conjuntamente* relevantes una vez que `hours`, `exper` y `age` están en el modelo? Formalmente,

$$H_0 : \beta_{\text{educ}} = \beta_{\text{IQ}} = 0 \quad \text{frente a} \quad H_1 : \text{al menos uno de ellos} \neq 0,$$

así que $q = 2$.

El modelo no restringido es `model2`. El modelo restringido suprime `educ` e `IQ`:

```
model3 <- lm(wage ~ hours + exper + age, data = wage2)
summary(model3)
```

Call:

```
lm(formula = wage ~ hours + exper + age, data = wage2)
```

Residuals:

```
      Min      1Q  Median      3Q      Max
-749.69 -279.16  -48.16  203.20 2208.66
```

4. Inferencia

Coefficients:

	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	224.411	162.071	1.385	0.16649
hours	-1.175	1.812	-0.649	0.51665
exper	-9.430	3.443	-2.739	0.00628 **
age	27.032	4.838	5.587	3.03e-08 ***

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 398.4 on 931 degrees of freedom

Multiple R-squared: 0.03253, Adjusted R-squared: 0.02941

F-statistic: 10.44 on 3 and 931 DF, p-value: 9.332e-07

Calculamos las SSR a mano:

```
SSR_u <- sum(residuals(model2)^2)
SSR_r <- sum(residuals(model3)^2)
c(SSR_unrestricted = SSR_u, SSR_restricted = SSR_r)
```

SSR_unrestricted	SSR_restricted
126414757	147747973

Ahora el estadístico F :

```
q <- 2 # restricciones
df_u <- n - k - 1 # gl del modelo no restringido

F_stat <- ((SSR_r - SSR_u) / q) / (SSR_u / df_u)
F_crit <- qf(0.95, df1 = q, df2 = df_u)
p_val <- 1 - pf(F_stat, df1 = q, df2 = df_u)

c(F = F_stat, F_crit_5pct = F_crit, p = p_val)
```

F	F_crit_5pct	p
78.387043	3.005413	0.000000

El estadístico F está muy por encima del valor crítico del 5% y el p -valor es esencialmente cero, así que rechazamos contundentemente H_0 : educ e IQ son determinantes conjuntamente significativos de wage.

R proporciona el mismo contraste en una sola línea mediante `anova()`, que compara dos modelos anidados:

```
anova(model3, model2)
```

Analysis of Variance Table

Model 1: wage ~ hours + exper + age

```

Model 2: wage ~ hours + educ + exper + IQ + age
  Res.Df      RSS Df Sum of Sq    F    Pr(>F)
1     931 147747973
2     929 126414757  2  21333216 78.387 < 2.2e-16 ***
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

```

Las columnas F y Pr(>F) reproducen el cálculo manual. Informar del test F con `anova()` es el flujo de trabajo recomendado; la derivación manual importa porque permite ver con precisión *qué se está comparando*.

4.9.5. $F = t^2$ en un contraste con una sola restricción

La identidad del final del §4.7 es fácil de comprobar numéricamente. Contrastamos $H_0 : \beta_{\text{educ}} = 0$ por los dos caminos:

```

t_educ <- summary(model2)$coefficients["educ", "t value"]

mR <- lm(wage ~ hours + exper + IQ + age, data = wage2) # quitar solo educ
ft <- anova(mR, model2)
F_single <- ft$F[2]

c(t_squared = t_educ^2, F = F_single)

```

```

t_squared      F
51.65078 51.65078

```

Los dos números coinciden, como predice el álgebra.

4.9.6. Unilateral frente a bilateral

Supongamos que la teoría nos dice que un año adicional de experiencia no puede reducir los ingresos mensuales, de modo que la alternativa relevante es *unilateral a la derecha*: $H_0 : \beta_{\text{exper}} \leq 0$ frente a $H_1 : \beta_{\text{exper}} > 0$. El mismo estadístico t alimenta un p -valor distinto:

```

co <- summary(model2)$coefficients["exper", ]
t_exper <- co["t value"]

p_one_sided <- if (t_exper > 0) 1 - pt(t_exper, df) else 1
# ^ p-valor de la cola derecha. Solo es significativo cuando la estimación
# ya está del lado de la alternativa (aquí t_exper > 0). Si la estimación
# tuviera el signo contrario al de una alternativa unilateral a la derecha,
# el p-valor unilateral correcto sería ~1 ("ninguna evidencia en la
# dirección de la alternativa"), NO el ingenuo 1 - pt(t_exper, df), que
# devolvería un valor superior a 0,5.
p_two_sided <- 2 * pt(-abs(t_exper), df) # por defecto en summary()

c(t = t_exper, p_one_sided = p_one_sided, p_two_sided = p_two_sided)

```

4. Inferencia

t.t value	p_one_sided.t value	p_two_sided.t value
2.940922029	0.001676777	0.003353554

Cuando $t > 0$ y la alternativa está en la derecha, el p -valor unilateral es exactamente la mitad del bilateral. Un coeficiente marginal con el test bilateral por defecto puede pasar a ser claramente significativo en cuanto estemos dispuestos a comprometernos con un signo *a priori* — pero ese compromiso debe venir de la economía, no de fisionomía primero en los datos.

Auto-evaluación

Seis preguntas cortas de opción múltiple. Inténtelas antes de abrir la respuesta.

💡 P1. Qué nos aporta RLM.6

Añadir RLM.6 (normalidad de u) a los supuestos de Gauss–Markov nos permite:

- A. Demostrar que MCO es insesgado.
- B. Demostrar que MCO tiene la menor varianza entre los estimadores lineales insesgados.
- C. Derivar la distribución *exacta* en muestras finitas de $\hat{\beta}_j$ y realizar tests t y F con cualquier tamaño muestral.
- D. Estimar σ^2 .

Respuesta: C. La insesgadez (A) se sigue de RLM.1–RLM.4; la propiedad BLUE (B) de RLM.1–RLM.5; el estimador $\hat{\sigma}^2$ (D) está definido sin necesidad de RLM.6. Solo RLM.6 nos da normalidad *exacta* de $\hat{\beta}_j$ y, por tanto, inferencia t y F exacta en muestras finitas.

💡 P2. ¿Por qué t y no z ?

Bajo RLM.1–RLM.6 usamos t_{n-k-1} en lugar de $\mathcal{N}(0,1)$ para inferencia sobre un coeficiente individual porque:

- A. MCO es sesgado en muestras finitas.
- B. El error estándar utiliza una $\hat{\sigma}^2$ *estimada*, y el estadístico estandarizado resultante tiene colas más pesadas que la normal estándar.
- C. El término de error es heteroscedástico.
- D. Los regresores son no estocásticos.

Respuesta: B. Sustituir la σ desconocida en el error estándar por $\hat{\sigma}$ introduce variabilidad adicional que la distribución t contabiliza. A medida que $n - k - 1 \rightarrow \infty$, la t converge a la normal estándar.

💡 P3. Un intervalo de confianza del 95 %

Un intervalo de confianza del 95 % para β_j que excluye el cero implica:

- A. El test t bilateral de $H_0 : \beta_j = 0$ rechaza al nivel del 5 %.
- B. El verdadero β_j es definitivamente distinto de cero.
- C. El coeficiente estimado es económicamente grande.
- D. MCO es insesgado.

Respuesta: A. Un IC y un test bilateral al nivel correspondiente son algebraicamente equivalentes: el IC excluye el valor nulo si y solo si el test rechaza. El IC no dice nada sobre magnitud (C) ni sobre el sesgo de MCO (D), y una única muestra no puede certificar (B).

💡 P4. Lectura de un p -valor

Un coeficiente tiene un p -valor bilateral de 0,03. ¿Qué afirmación es correcta?

- A. Es estadísticamente significativo al nivel del 5 % pero no al del 1 %.
- B. Es significativo a todos los niveles convencionales.
- C. No es significativo al nivel del 5 %.
- D. El coeficiente es económicamente importante.

Respuesta: A. Recuérdese que p es el menor α al que se rechaza; $0,01 < 0,03 < 0,05$ sitúa la significatividad entre los niveles del 1 % y el 5 %. La significatividad estadística no contiene información sobre la magnitud económica.

💡 P5. El estadístico F

Para contrastar $H_0 : \beta_1 = \beta_2 = 0$ conjuntamente en una regresión con k pendientes y tamaño muestral n , utilizamos:

- A. Dos tests t separados, uno para cada coeficiente.
- B. $F = \frac{(SSR_R - SSR_U)/q}{SSR_U/(n - k - 1)}$, con distribución $F_{q, n-k-1}$ bajo H_0 .
- C. Un test χ^2 sobre $\hat{\beta}_1 + \hat{\beta}_2$.
- D. Un test z , comparando la suma de las estimaciones con 1,96.

Respuesta: B. Los tests t separados no controlan **la probabilidad de rechazar al menos una hipótesis nula verdadera**: con q tests individuales, cada uno de tamaño α , la tasa de error de tipo I combinada crece por encima de α . El test F está construido para que su tamaño sobre la nula *conjunta* sea exactamente α . Los tests t separados también pasan por alto el caso en que dos regresores son individualmente débiles pero conjuntamente informativos.

💡 P6. Significatividad frente a causalidad

Un regresor x_j tiene un coeficiente con $p < 0,001$. ¿Cuál de las siguientes afirmaciones es cierta?

- A. Un p -valor pequeño descarta el sesgo de variable omitida.
- B. La significatividad estadística demuestra que x_j causa y .
- C. Significatividad estadística e identificación causal son equivalentes.
- D. El p -valor nos dice que es poco probable que $\hat{\beta}_j$ sea cero por azar, pero no dice nada sobre si x_j causa y — la identificación causal sigue exigiendo $\mathbb{E}[u | \mathbf{X}] = 0$.

Respuesta: D. La §4.6 es explícita: la inferencia consiste en descartar el ruido muestral, no la confusión.

Ejercicios

Ejercicio 4.1 — **Lectura de una salida de `summary()`.** Usando el conjunto de datos `wage2`, estime el modelo

$$\text{wage} = \beta_0 + \beta_1 \text{educ} + \beta_2 \text{exper} + \beta_3 \text{tenure} + u$$

con `lm()` e inspeccione `summary()`. (a) ¿Qué coeficientes son significativos al nivel del 5 %? (b) Indique la magnitud *y* el error estándar de $\hat{\beta}_1$; ¿cuál es su interpretación económica? (c) Enuncie la hipótesis nula que contrasta el estadístico *F* global situado al pie de `summary()`.

 Mostrar respuesta

(a) Las tres pendientes son positivas y tienen *p*-valores muy por debajo de 0,05 (cada estadístico *t* supera holgadamente 2 en valor absoluto), de manera que `educ`, `exper` y `tenure` son individualmente significativas al nivel del 5 %. (b) $\hat{\beta}_1$ es aproximadamente de 60 dólares mensuales por año adicional de escolarización, con un error estándar en torno a 6 — un efecto a la vez estadísticamente y económicamente relevante. (c) El estadístico *F* global contrasta $H_0 : \beta_1 = \beta_2 = \beta_3 = 0$ (ningún regresor importa) frente a la alternativa de que al menos una pendiente sea no nula.

Ejercicio 4.2 — **IC del 95 % manual.** Para el mismo modelo, construya desde cero un intervalo de confianza del 95 % para β_{educ} usando `coef()`, `summary()$coefficients[, "Std. Error"]` y `qt()`. Compruebe su intervalo contra `confint(m)[,"educ", ]`. ¿Contiene el intervalo al cero? ¿Qué conclusión se sigue para el test *t* bilateral de $H_0 : \beta_{\text{educ}} = 0$ al nivel del 5 %?

 Mostrar respuesta

```
m <- lm(wage ~ educ + exper + tenure, data = wage2)
b <- coef(m)["educ"]
se <- summary(m)$coefficients["educ", "Std. Error"]
df <- nobs(m) - length(coef(m))      # n - k - 1
tc <- qt(0.975, df)
ci_manual <- c(b - tc * se, b + tc * se)
confint(m)["educ", ]                # debería coincidir
```

El intervalo no contiene cero, así que el test *t* bilateral de $H_0 : \beta_{\text{educ}} = 0$ al nivel del 5 % rechaza — coherente con el (diminuto) valor $\Pr(>|t|)$ de `summary()`.

Ejercicio 4.3 — **Test *F* manual.** En el modelo $\text{wage} = \beta_0 + \beta_1 \text{educ} + \beta_2 \text{exper} + \beta_3 \text{tenure} + u$ sobre `wage2`, contraste $H_0 : \beta_2 = \beta_3 = 0$ comparando las SSR de los modelos no restringido y restringido (suprimiendo `exper` y `tenure`). Calcule el valor crítico con `qf()` al nivel del 5 % y el *p*-valor con `pf()`. Compruebe el resultado con `anova()`.

 Mostrar respuesta

```
mU <- lm(wage ~ educ + exper + tenure, data = wage2)
mR <- lm(wage ~ educ, data = wage2)

SSR_u <- sum(resid(mU)^2)
SSR_r <- sum(resid(mR)^2)
n <- nobs(mU); k <- length(coef(mU)) - 1; q <- 2
df_u <- n - k - 1

F_stat <- ((SSR_r - SSR_u) / q) / (SSR_u / df_u)
F_crit <- qf(0.95, q, df_u)
p_val <- 1 - pf(F_stat, q, df_u)
anova(mR, mU)
```

El estadístico F está muy por encima de $F_{2, n-k-1, 0.05}$ y el p -valor es prácticamente cero. Rechazamos H_0 : experiencia y antigüedad son conjuntamente significativas dada la educación.

Ejercicio 4.4 — Test unilateral desde la teoría. La teoría económica sugiere que un año adicional de antigüedad no puede disminuir los ingresos mensuales, así que la alternativa relevante es unilateral a la derecha: $H_0 : \beta_{\text{tenure}} \leq 0$ frente a $H_1 : \beta_{\text{tenure}} > 0$. Usando la regresión de `wage` sobre `educ + exper + tenure`, calcule el p -valor unilateral a partir de la salida de `summary()` y decida al nivel del 5%. ¿Cómo se compara con el p -valor bilateral por defecto que imprime R?

Una respuesta completa figura en la Edición del Profesor.

Ejercicio 4.5 — Significatividad conjunta frente a individual. En el modelo del Ejercicio 4.1, añada `IQ` y `age` como regresores. (a) ¿Son `IQ` y `age` *individualmente* significativas al nivel del 5%? (b) ¿Son *conjuntamente* significativas al nivel del 5% (use `anova()`)? (c) Construya un ejemplo, o explique con palabras, en el que dos regresores sean individualmente no significativos pero conjuntamente sí. ¿Qué característica de los datos provoca esa diferencia?

Una respuesta completa figura en la Edición del Profesor.

Ejercicio 4.6 — F a partir de R^2 . Demuestre, partiendo de la fórmula basada en la SSR, que siempre que los modelos no restringido y restringido compartan la misma variable dependiente, el estadístico F puede escribirse como

$$F = \frac{(R_U^2 - R_R^2)/q}{(1 - R_U^2)/(n - k - 1)}.$$

A continuación, compruebe la identidad numéricamente para el test F de $H_0 : \beta_{\text{exper}} = \beta_{\text{tenure}} = 0$ del Ejercicio 4.3, extrayendo los dos valores R^2 de `summary()` y sustituyéndolos. ¿Por qué falla la fórmula si la variable dependiente del modelo restringido es `log(wage)` en lugar de `wage`?

Una respuesta completa figura en la Edición del Profesor.

Predicción y Selección de Modelos

Objetivos

Al terminar este capítulo, el lector debería ser capaz de:

- Distinguir la *inferencia causal* de la *predicción* como dos objetivos econométricos distintos, y explicar por qué un modelo que predice bien no es automáticamente un buen modelo causal.
- Calcular la predicción puntual $\hat{y}_0$ para una nueva observación con valores de los regresores x_0 , tanto en regresión lineal simple (RLS) como en regresión lineal múltiple (RLM).
- Construir e interpretar las dos estimaciones por intervalo: el **intervalo de confianza (IC)** para la media condicional $\mathbb{E}[y \mid x_0]$ y el **intervalo de predicción (IP)** para un resultado individual y_0 .
- Explicar por qué el intervalo de predicción es siempre más ancho que el intervalo de confianza para la media, y reconocer las condiciones bajo las cuales ambos intervalos se ensanchan.
- Comparar modelos anidados mediante R^2 , R^2 ajustado, los criterios de información de Akaike (AIC) y Bayesiano (BIC) y el test F anidado.
- Usar `predict()`, `AIC()`, `BIC()` y `anova()` en R para predecir a partir de un modelo ajustado y para elegir entre especificaciones competidoras.

Pregunta motivadora

Dos selectores entrevistan al mismo candidato —24 años, 16 años de educación, 5 años de experiencia y 2 años de antigüedad en su puesto— y ambos ajustan la misma regresión salarial sobre los mismos datos. El primero reporta un intervalo del 95 % de $[\$5\{,\}7, \$7\{,\}2]$ para el salario esperado; el segundo reporta $[\$0\{,\}5, \$12\{,\}4]$. Ambos son correctos. ¿Cuál es cuál?

La respuesta depende de una distinción fácil de pasar por alto: el primer selector está reportando incertidumbre sobre el salario *medio* de las personas como este candidato, mientras que el segundo está reportando incertidumbre sobre el salario real *de este* candidato. El mismo modelo ajustado produce ambos números —responden a preguntas distintas—. Este capítulo trata sobre esa distinción y sobre la cuestión asociada de cómo elegir entre modelos competidores en primer lugar.

5.1. Causalidad vs. predicción

HASTA el Capítulo 4 hemos usado la regresión con un único propósito: estimar el efecto *ceteris paribus* de x sobre y . El coeficiente β_j era el objeto de interés, y todo el aparato de los supuestos de Gauss–Markov, los tests t y los tests F estaba al servicio de obtener $\hat{\beta}_j$ correctamente —insesgado, eficiente y con errores estándar válidos—.

La econometría también tiene un segundo uso, igualmente legítimo: la **predicción**. Aquí no nos interesa particularmente el valor de ningún β_j individual; nos importa la precisión del valor ajustado $\hat{y}_0$ para una nueva observación.

Los dos objetivos se solapan, pero no son lo mismo:

- **Inferencia causal.** El objetivo es $\partial \mathbb{E}[y | x] / \partial x_j$. El supuesto decisivo es RLM.4 (media condicional cero): $\mathbb{E}[u | x_1, \dots, x_k] = 0$. Los coeficientes se interpretan; la afirmación típica es «un aumento de una unidad en x_j *causa* un cambio esperado de β_j en y , manteniendo el resto de factores constantes».
- **Predicción.** El objetivo es $\hat{y}_0$ para un nuevo x_0 . El supuesto decisivo es la *estabilidad*: el nuevo par (y_0, x_0) proviene de la misma población que la muestra. Los coeficientes no necesitan ser interpretables; queremos regresores con buen poder predictivo y un buen ajuste (dentro y fuera de muestra).

Un modelo puede ser excelente para un propósito y pobre para el otro. Un predictor de accidentes de tráfico que incluya «ventas de helados» como regresor puede funcionar bien porque los helados son un *proxy* del calor; resulta inútil como consejo causal de política sobre los helados. A la inversa, una estimación por variables instrumentales del rendimiento de la educación puede identificar un parámetro causal limpio a partir de un fragmento ínfimo de la variación de los datos, mientras deja sin explicar la mayor parte de la variabilidad de los salarios.

 Error frecuente: elegir el modelo con mayor R^2 y leer los efectos causales

Un R^2 alto indica que los valores ajustados siguen bien a y . **No** dice que ningún coeficiente individual mida un efecto causal. La estrategia de identificación —asignación aleatoria, un instrumento, un experimento natural o un argumento creíble de que $\mathbb{E}[u | x] = 0$ — es lo que autoriza la interpretación causal. Los criterios de selección basados en el ajuste, como el R^2 ajustado, el AIC y el BIC, son herramientas para la predicción; no pueden rescatar un modelo aquejado de sesgo por variable omitida.

5.2. Predicción puntual

Por claridad, consideremos primero el modelo de regresión lineal simple (RLS):

$$y_i = \beta_0 + \beta_1 x_i + u_i, \quad \mathbb{E}[u_i | x_i] = 0.$$

Dadas las estimaciones MCO $(\hat{\beta}_0, \hat{\beta}_1)$ y un nuevo valor x_0 del regresor, la **predicción puntual** es simplemente el valor ajustado de la regresión en x_0 :

$$\hat{y}_0 = \hat{\beta}_0 + \hat{\beta}_1 x_0.$$

La misma construcción se extiende, término a término, a la regresión lineal múltiple (RLM). Si $x_0 = (1, x_{01}, x_{02}, \dots, x_{0k})$ es el vector fila de valores de los regresores para la nueva observación, entonces

$$\hat{y}_0 = \hat{\beta}_0 + \hat{\beta}_1 x_{01} + \hat{\beta}_2 x_{02} + \dots + \hat{\beta}_k x_{0k}.$$

¿Cómo de buena es esta predicción? La cantidad natural es el **error de predicción**:

$$f \equiv y_0 - \hat{y}_0 = (\beta_0 + \beta_1 x_0 + u_0) - (\hat{\beta}_0 + \hat{\beta}_1 x_0).$$

Tomando esperanza condicional bajo RLM.1–RLM.4,

$$\mathbb{E}[f \mid x_0] = (\beta_0 + \beta_1 x_0) - \mathbb{E}[\hat{\beta}_0 + \hat{\beta}_1 x_0] = 0.$$

Por tanto, $\hat{y}_0$ es un **predictor insesgado** de y_0 . De hecho, bajo RLS.1–RLS.5 (y sus análogos para RLM) se puede demostrar que $\hat{y}_0$ tiene la varianza más pequeña entre todos los predictores lineales insesgados: es el **mejor predictor lineal insesgado** (en inglés, *Best Linear Unbiased Predictor* o BLUP).

 $\hat{y}_0$ tiene un doble papel

El mismo número $\hat{y}_0$ es *tanto* la predicción puntual del valor individual y_0 *como* la estimación de la media condicional $\mathbb{E}[y \mid x_0]$. Las dos interpretaciones de $\hat{y}_0$ son numéricamente idénticas, pero tienen una *incertidumbre* distinta. La sección siguiente lo concreta.

5.3. Varianza de la predicción e intervalos de predicción

Una estimación puntual rara vez es suficiente. Necesitamos un intervalo que cuantifique la incertidumbre —y hay dos incertidumbres distintas que cuantificar—.

5.3.1. Intervalo de confianza para la media condicional $\mathbb{E}[y \mid x_0]$

La media condicional $\mathbb{E}[y \mid x_0] = \beta_0 + \beta_1 x_0$ es una cantidad poblacional fija (no aleatoria). Su estimador es $\hat{y}_0 = \hat{\beta}_0 + \hat{\beta}_1 x_0$, que es aleatorio porque las estimaciones MCO son aleatorias. Su varianza es

$$\text{Var}(\hat{y}_0 \mid x) = \sigma^2 \left[\frac{1}{n} + \frac{(x_0 - \bar{x})^2}{\text{SCT}_x} \right],$$

donde $\text{SCT}_x = \sum_{i=1}^n (x_i - \bar{x})^2$ es la suma de cuadrados total del regresor. Reemplazando σ^2 por el estimador $\hat{\sigma}^2 = \text{SCR}/(n - k - 1)$, el intervalo de confianza al $100(1 - \alpha)\%$ para la *media* predicha es

$$\hat{y}_0 \pm t_c \cdot \hat{\sigma} \sqrt{\frac{1}{n} + \frac{(x_0 - \bar{x})^2}{\text{SCT}_x}},$$

con t_c el valor crítico apropiado de una distribución t con $n - k - 1$ grados de libertad.

5.3.2. Intervalo de predicción para un valor individual y_0

El nuevo resultado $y_0 = \beta_0 + \beta_1 x_0 + u_0$ es aleatorio porque *tanto* las estimaciones MCO *como* el nuevo error u_0 son aleatorios. Suponiendo que u_0 es independiente de la muestra,

$$\text{Var}(y_0 - \hat{y}_0 \mid x) = \sigma^2 \left[1 + \frac{1}{n} + \frac{(x_0 - \bar{x})^2}{\text{SCT}_x} \right].$$

El «1» extra dentro del corchete es la contribución de u_0 —la parte irreducible de la nueva extracción que ninguna cantidad de datos podría predecir—. El **intervalo de predicción** al $100(1 - \alpha)\%$ para y_0 es

$$\hat{y}_0 \pm t_c \cdot \hat{\sigma} \sqrt{1 + \frac{1}{n} + \frac{(x_0 - \bar{x})^2}{\text{SCT}_x}}.$$

En RLM la misma lógica conduce a $\text{Var}(y_0 - \hat{y}_0 \mid X) = \sigma^2[1 + x_0'(X'X)^{-1}x_0]$, obteniéndose el IC para la media simplemente eliminando el «1» del corchete.

i Los dos intervalos de un vistazo

Cantidad objetivo	Ingrediente de la varianza	Intervalo	Anchura
Media $\mathbb{E}[y \mid x_0]$	$1/n + (x_0 - \bar{x})^2/\text{SCT}_x$	Intervalo de confianza	Más estrecho
Individual y_0	$1 + 1/n + (x_0 - \bar{x})^2/\text{SCT}_x$	Intervalo de predicción	Más ancho

El IP es siempre más ancho que el IC. La diferencia la marca el «1»: la varianza irreducible de la nueva extracción u_0 .

Algunas observaciones adicionales sobre las fórmulas:

- Ambas varianzas se reducen cuando n crece —con datos infinitos el IC para la media colapsaría a un punto, pero el IP no, porque el «1» no desaparece nunca—.
- Ambas varianzas crecen cuando x_0 se aleja de la media muestral $\bar{x}$. Las predicciones son más precisas en el centro de los datos; predecir en los extremos (o extrapolar fuera de ellos) es peligroso.
- Ambas varianzas se reducen cuando SCT_x crece. Regresores más dispersos proporcionan más palanca para fijar la pendiente, lo que a su vez reduce la varianza de la predicción.

5.3.3. Ejemplo numérico

Supongamos que hemos estimado la RLS

$$\hat{y} = 2,0 + 0,7x,$$

con tamaño muestral $n = 100$, $\bar{x} = 12$, $\text{SCT}_x = 200$ y $\hat{\sigma}^2 = 4$ (de modo que $\hat{\sigma} = 2$). Queremos predecir en $x_0 = 16$. Usando $t_c \approx 1,98$ para un intervalo al 95 % con 98 grados de libertad:

- **Predicción puntual.** $\hat{y}_0 = 2,0 + 0,7 \times 16 = 13,2$.
- **IC para la media** $\mathbb{E}[y \mid x_0]$.

$$ee(\hat{y}_0) = \hat{\sigma} \sqrt{\frac{1}{100} + \frac{(16-12)^2}{200}} = 2\sqrt{0,01 + 0,08} = 0,6.$$

$$\text{IC 95 \%: } 13,2 \pm 1,98 \times 0,6 = [12,01, 14,39].$$

- **Intervalo de predicción** para y_0 .

$$ee(f) = \hat{\sigma} \sqrt{1 + \frac{1}{100} + \frac{(16-12)^2}{200}} = 2\sqrt{1,09} \approx 2,088.$$

$$\text{IP 95 \%: } 13,2 \pm 1,98 \times 2,088 = [9,06, 17,34].$$

El IC tiene una anchura de unos $\pm 1,20$ en torno a la predicción puntual; el IP, de unos $\pm 4,14$. La proporción la fija el tamaño relativo del «1» frente a $1/n + (x_0 - \bar{x})^2/\text{SCT}_x = 0,09$. Aquí la incertidumbre por la nueva extracción supera en un orden de magnitud a la incertidumbre por los parámetros.

5.4. Predicción en RLM

Los modelos salariales reales incluyen más de un regresor. Nada esencial cambia en la construcción de $\hat{y}_0$ y los dos intervalos —las fórmulas pasan a ser versiones vector-matriz de las de la RLS—.

Para un vector fila $x_0 = (1, x_{01}, \dots, x_{0k})$,

$$\hat{y}_0 = x_0' \hat{\beta}, \quad \text{Var}(y_0 - \hat{y}_0 \mid X) = \sigma^2 [1 + x_0'(X'X)^{-1}x_0].$$

Eliminar el «1» proporciona la varianza de $\hat{y}_0$ como estimador de $\mathbb{E}[y \mid x_0]$. En R, la función `predict()` realiza todo esto automáticamente con `interval = "confidence"` o `interval = "prediction"`. El usuario proporciona el nuevo x_0 como un *data frame*; la función devuelve el ajuste y los límites. Lo probamos sobre `wage1` en la práctica.

No extrapoles

Las fórmulas de predicción asumen que (y_0, x_0) proviene de la *misma población* que la muestra. Si x_0 está muy fuera del rango de los regresores realmente observados —pongamos, predecir el salario de alguien con 30 años de educación y 80 años de experiencia—, ambos intervalos pueden calcularse técnicamente, pero ninguno es fiable. No hay información en la muestra sobre lo que ocurre en esos valores. Mantente dentro del soporte de los datos.

5.5. Selección de modelos: R^2 , R^2 ajustado, AIC, BIC

Supongamos que tenemos varios modelos de regresión candidatos para el mismo resultado. ¿Cómo elegimos? Cuatro criterios se utilizan habitualmente.

5.5.1. R^2 y el problema de las variables «basura»

El coeficiente de determinación

$$R^2 = \frac{\text{SCE}}{\text{SCT}} = 1 - \frac{\text{SCR}}{\text{SCT}}$$

mide la proporción de la variación de y explicada por el modelo. Como mecanismo de selección de modelos tiene un defecto fatal: **añadir cualquier regresor no puede reducir R^2** . Incluso un regresor de puro ruido, casi con seguridad, aumentará ligeramente R^2 , porque MCO siempre puede encontrar una pequeña combinación lineal del ruido que ajuste por casualidad parte de la variación residual.

Si eligiéramos el modelo maximizando R^2 , incluiríamos todos los regresores a nuestro alcance—incluyendo decenas de irrelevantes—. El modelo ajustaría la muestra de maravilla y predeciría pésimamente fuera de muestra. Este es el clásico problema del *sobreajuste*. Las transparencias lo ilustran simulando un modelo con dos regresores genuinos X_1, X_2 y añadiendo después 196 variables «basura» de puro ruido: el R^2 asciende sostenidamente hacia 1 a medida que se acumula la basura, aunque ninguna de las nuevas variables tenga contenido predictivo.

5.5.2. R^2 ajustado

Una solución simple es penalizar la complejidad. El R^2 **ajustado** es

$$\bar{R}^2 = 1 - \frac{\text{SCR}/(n - k - 1)}{\text{SCT}/(n - 1)},$$

donde k es el número de regresores (excluida la constante). El numerador $\text{SCR}/(n - k - 1)$ es $\hat{\sigma}^2$, el estimador insesgado de la varianza del error. Añadir un regresor reduce SCR pero también reduce $n - k - 1$; $\bar{R}^2$ sube solo si la ganancia en ajuste supera el coste del parámetro adicional.

Algunos hechos útiles:

- $\bar{R}^2 \leq R^2$ siempre, con igualdad solo cuando $k = 0$.
- A diferencia de R^2 , $\bar{R}^2$ *puede disminuir* al añadir un regresor irrelevante —y en la simulación de basura, lo hace—.
- $\bar{R}^2$ puede en principio ser negativo si el modelo es tan malo que $\hat{\sigma}^2$ supera la varianza muestral de y .

5.5.3. AIC y BIC

El **criterio de información de Akaike** y el **criterio de información Bayesiano** combinan el ajuste del modelo (una log-verosimilitud) con una penalización por complejidad:

$$\text{AIC} = -2 \ln \hat{L} + 2(k + 1), \quad \text{BIC} = -2 \ln \hat{L} + (k + 1) \ln n.$$

Para un modelo lineal con errores normales, la log-verosimilitud es una transformación monótona de $-\text{SCR}/n$, de modo que, salvo constantes aditivas,

$$\text{AIC} \approx n \ln \left(\frac{\text{SCR}}{n} \right) + 2(k + 1), \quad \text{BIC} \approx n \ln \left(\frac{\text{SCR}}{n} \right) + (k + 1) \ln n.$$

Valores menores de AIC y BIC indican mejores modelos. Ambos criterios equilibran el ajuste (el término en SCR) con la complejidad (el segundo término). La única diferencia es el tamaño de la penalización: AIC cobra 2 por parámetro adicional, BIC cobra $\ln n$. Para $n \geq 8$, $\ln n > 2$, por lo que el BIC penaliza la complejidad con más fuerza y tiende a seleccionar modelos más parsimoniosos. El AIC está construido para minimizar el error de predicción; el BIC para identificar el modelo «verdadero» cuando existe.

⚠ AIC y BIC requieren los mismos datos y la misma variable dependiente

Si dos modelos usan distintas variables dependientes (por ejemplo, `wage` y `log(wage)`), o se estiman en submuestras distintas, sus AIC y BIC *no* son comparables —las log-verosimilitudes están en escalas diferentes—. La misma advertencia se aplica a R^2 y $\bar{R}^2$.

5.5.4. Test F anidado

Cuando un modelo está anidado dentro de otro —el modelo más pequeño se obtiene fijando a cero algunos coeficientes del modelo mayor—, el **test F de restricciones conjuntas** (Capítulo 4) es el test formal de «¿son estos regresores adicionales conjuntamente informativos?». En R, `anova(pequeño, grande)` lo realiza. El test responde a una pregunta distinta de AIC/BIC: pregunta si los datos *rechazan* el modelo pequeño en favor del grande, no qué modelo es el «mejor» según algún criterio predictivo.

5.5.5. Juntándolo todo

En la práctica reportamos los cuatro criterios uno al lado del otro. Suelen coincidir en la ordenación general; cuando discrepan, la discrepancia es informativa:

- Si R^2 sube pero $\bar{R}^2$, AIC y BIC empeoran a la vez, los nuevos regresores son ruido.
- Si $\bar{R}^2$ y AIC favorecen al modelo mayor pero BIC favorece al menor, los regresores adicionales son débilmente predictivos; con muestras grandes el BIC puede estar sobre-penalizando. En un ejercicio *puramente predictivo*, inclínese por el AIC; para *parsimonia* o para elegir un modelo «verdadero», inclínese por el BIC.

Y, siempre: los criterios de selección de modelos eligen el modelo que *mejor ajusta* según el criterio dado. No eligen el modelo que mejor *identifica un parámetro causal*. Esa elección pertenece a la estrategia de identificación.

5.6. Práctica: Predicción y Selección de Modelos en R

Trabajamos con el conjunto de datos `wage1`, que contiene 526 trabajadores estadounidenses (Capítulo 1). El objetivo es (i) ajustar una secuencia de modelos salariales anidados, (ii) compararlos mediante $\bar{R}^2$, AIC, BIC y un test F , (iii) producir predicciones puntuales y los dos intervalos para un trabajador concreto, y (iv) visualizar la diferencia entre la banda de confianza para la media y la banda de predicción para un individuo.

```
library(wooldridge)
data("wage1")
```

5.6.1. Paso 1 — Ajustar cuatro modelos salariales anidados

Enriquecemos la especificación progresivamente.

```
modelo1 <- lm(wage ~ educ, data = wage1)
modelo2 <- lm(wage ~ educ + exper, data = wage1)
modelo3 <- lm(wage ~ educ + exper + tenure, data = wage1)
modelo4 <- lm(wage ~ educ + exper + tenure + female + married, data = wage1)
```

5.6.2. Paso 2 — Comparar los cuatro modelos

Recogemos R^2 , $\bar{R}^2$, AIC y BIC en una única tabla.

```
tab <- sapply(list(m1 = modelo1, m2 = modelo2, m3 = modelo3, m4 = modelo4),
              function(m) c(
                R2      = summary(m)$r.squared,
                R2adj    = summary(m)$adj.r.squared,
                AIC      = AIC(m),
                BIC      = BIC(m)))
round(tab, 3)
```

	m1	m2	m3	m4
R2	0.165	0.225	0.306	0.368
R2adj	0.163	0.222	0.302	0.362
AIC	2777.423	2739.937	2683.662	2638.600
BIC	2790.219	2756.999	2704.988	2668.457

Algunas observaciones que se pueden leer de esta tabla:

- R^2 sube *monótonamente* de modelo1 a modelo4. Eso es mecánico: añadir regresores no puede reducir R^2 .
- $\bar{R}^2$ también sube a lo largo de los cuatro modelos, lo que indica que cada nuevo regresor añadido contribuye más en ajuste que en coste por complejidad.
- AIC y BIC *bajan* al pasar de modelo1 a modelo4 (cuanto más bajo, mejor). Los cuatro criterios coinciden: de estas cuatro especificaciones, modelo4 es la preferida.

5.6.3. Paso 3 — Un test F anidado

¿Son *female* y *married* conjuntamente informativas una vez que *educ*, *exper* y *tenure* están en el modelo?

```
anova(modelo3, modelo4)
```

Analysis of Variance Table

```
Model 1: wage ~ educ + exper + tenure
Model 2: wage ~ educ + exper + tenure + female + married
  Res.Df  RSS Df Sum of Sq    F    Pr(>F)
1     522 4966.3
```

```
2      520 4524.0  2      442.27 25.418 2.938e-11 ***
---
```

```
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

El estadístico F compara las dos SCR; si su p -valor es pequeño, rechazamos la nula conjunta $H_0 : \beta_{\text{female}} = \beta_{\text{married}} = 0$. En `wage1` resulta muy pequeño, confirmando con un test formal la preferencia de AIC/BIC por `modelo4`.

5.6.4. Paso 4 — La demostración de las variables «basura»

Ahora añadimos deliberadamente tres regresores de puro ruido a `modelo4` y observamos qué le ocurre a cada criterio.

```
set.seed(42)
wage1$ruido1 <- rnorm(nrow(wage1))
wage1$ruido2 <- rnorm(nrow(wage1))
wage1$ruido3 <- rnorm(nrow(wage1))

modelo_basura <- lm(wage ~ educ + exper + tenure + female + married +
                    ruido1 + ruido2 + ruido3, data = wage1)

rbind(
  modelo4      = c(R2 = summary(modelo4)$r.squared,
                   R2adj = summary(modelo4)$adj.r.squared,
                   AIC = AIC(modelo4), BIC = BIC(modelo4)),
  modelo_basura = c(R2 = summary(modelo_basura)$r.squared,
                   R2adj = summary(modelo_basura)$adj.r.squared,
                   AIC = AIC(modelo_basura), BIC = BIC(modelo_basura)))
```

	R2	R2adj	AIC	BIC
modelo4	0.3681887	0.3621136	2638.600	2668.457
modelo_basura	0.3708921	0.3611573	2642.345	2684.998

Inspeccionemos la salida: R^2 ha subido ligeramente (como tenía que hacer), pero $\bar{R}^2$ ha *bajado*, y tanto AIC como BIC han *subido*. Los tres regresores de puro ruido parecen superficialmente útiles para el R^2 a secas; cada criterio penalizado los desenmascara. Esta es la razón completa por la que se usan $\bar{R}^2$, AIC o BIC en lugar del R^2 bruto para elegir un modelo.

5.6.5. Paso 5 — Predicción puntual para un trabajador concreto

Tomemos el candidato de la pregunta inicial: 16 años de educación, 5 años de experiencia, 2 años de antigüedad, mujer, soltera. Usamos `modelo4`.

```
nuevo_trabajador <- data.frame(educ = 16, exper = 5, tenure = 2,
                                female = 1, married = 0)
predict(modelo4, newdata = nuevo_trabajador)
```

```
1
5.90268
```

5. Predicción y Selección de Modelos

Este es $\hat{y}_0$ —el número único que el selector ofrecería como predicción salarial—.

5.6.6. Paso 6 — Los dos intervalos

La misma función `predict()` entrega el IC para la media y el IP para el individuo.

```
predict(modelo4, newdata = nuevo_trabajador,  
        interval = "confidence", level = 0.95)
```

```
      fit      lwr      upr  
1 5.90268 5.323082 6.482277
```

```
predict(modelo4, newdata = nuevo_trabajador,  
        interval = "prediction", level = 0.95)
```

```
      fit      lwr      upr  
1 5.90268 0.07919504 11.72616
```

El primer intervalo es la respuesta del selector a «¿cuál es el salario medio de las mujeres con estas características?». El segundo es la respuesta a «¿qué salario podría ganar realmente *esta* mujer?». El IP es mucho más ancho —en este conjunto de datos, un orden de magnitud más ancho— porque incluye la varianza irreducible de la nueva extracción u_0 .

5.6.7. Paso 7 — Comprobación manual

Para que las fórmulas resulten tangibles, calcularemos el IC a mano y compararemos:

```
yhat <- predict(modelo4, newdata = nuevo_trabajador, se.fit = TRUE)  
tc    <- qt(0.975, df = modelo4$df.residual)  
ic_manual <- c(yhat$fit - tc * yhat$se.fit,  
              yhat$fit + tc * yhat$se.fit)  
ic_manual
```

```
      1      1  
5.323082 6.482277
```

```
# Y el intervalo de predicción, usando  $EE(f)^2 = EE(yhat)^2 + \sigma_{hat}^2$   
sig2 <- summary(modelo4)$sigma^2  
ee_pred <- sqrt(yhat$se.fit^2 + sig2)  
ip_manual <- c(yhat$fit - tc * ee_pred,  
              yhat$fit + tc * ee_pred)  
ip_manual
```

```
      1      1  
0.07919504 11.72616433
```

Estos valores deben coincidir (salvo redondeo) con los límites devueltos por `predict()` en el paso 6. La descomposición $\text{Var}(y_0 - \hat{y}_0) = \text{Var}(\hat{y}_0) + \sigma^2$ es la versión operativa de «dos fuentes de incertidumbre: los parámetros y la nueva extracción».

5.6.8. Paso 8 — Visualización: IC vs. IP a lo largo de educ

La distinción entre los dos intervalos se aprecia con más claridad en un gráfico. Calculamos ambas bandas sobre una rejilla de valores de educación (manteniendo el resto de regresores fijos) y las representamos sobre la recta ajustada.

```
rejilla <- data.frame(educ = seq(0, 20, by = 0.5),
                      exper = 5, tenure = 3,
                      female = 0, married = 1)
banda_ic <- predict(modelo4, newdata = rejilla, interval = "confidence")
banda_ip <- predict(modelo4, newdata = rejilla, interval = "prediction")

plot(rejilla$educ, banda_ic[, "fit"], type = "l", lwd = 2, col = "blue",
     xlab = "Años de educación",
     ylab = "Salario predicho (USD/hora)",
     main = "IC para la media vs. IP para un individuo",
     ylim = range(banda_ip))
lines(rejilla$educ, banda_ic[, "lwr"], lty = 2, col = "blue")
lines(rejilla$educ, banda_ic[, "upr"], lty = 2, col = "blue")
lines(rejilla$educ, banda_ip[, "lwr"], lty = 2, col = "red")
lines(rejilla$educ, banda_ip[, "upr"], lty = 2, col = "red")
legend("topleft",
      legend = c("Ajustado", "IC 95% (media)", "IP 95% (individual)"),
      col = c("blue", "blue", "red"),
      lty = c(1, 2, 2), lwd = c(2, 1, 1))
```




Figure 5.1.: Salario ajustado (línea azul continua), banda de confianza al 95 % para la media condicional (azul discontinua) y banda de predicción al 95 % para individuos (roja discontinua), a lo largo de los años de educación. Resto de regresores fijos en $\text{exper}=5$, $\text{tenure}=3$, $\text{female}=0$, $\text{married}=1$.

Dos rasgos del gráfico merecen comentario:

- El IP (rojo) es mucho más ancho que el IC (azul) en cada valor de educ . La distancia vertical entre las dos bandas es, esencialmente, $\pm t_c \hat{\sigma}$ —la contribución de u_0 —.
- Ambas bandas se ensanchan en los *extremos* de educ , lejos de la media muestral. Predecir el salario de un trabajador sin escolaridad, o con 20 años de escolaridad, es intrínsecamente menos preciso que predecir cerca de la media muestral. Es el término $(x_0 - \bar{x})^2 / \text{SCT}_x$ de la fórmula de la varianza haciendo su trabajo.

Ya podemos responder a la pregunta inicial. El intervalo estrecho es el IC para el salario *medio* de los trabajadores con el perfil del candidato; el intervalo ancho es el IP para el salario *de este* candidato. Los dos provienen del mismo modelo, sobre los mismos datos, con la diferencia de una sola palabra en la llamada a `predict()`.

Auto-evaluación

Seis preguntas cortas. Intente cada una antes de desplegar la respuesta.

💡 P1. ¿Qué intervalo es cuál?

Un selector quiere conocer el salario *medio* de todos los trabajadores de la población que comparten el perfil del candidato. El intervalo relevante es:

- A. El intervalo de predicción al 95 % para y_0 .
- B. El intervalo de confianza al 95 % para $\mathbb{E}[y \mid x_0]$.
- C. El intervalo de confianza al 95 % para la pendiente β_1 .
- D. El residuo MCO.

Respuesta: B. El IC para $\mathbb{E}[y \mid x_0]$ tiene como objetivo la media condicional y es el más estrecho de los dos. El IP de la opción A sería la elección correcta para «¿qué salario podría ganar realmente *este* candidato?».

💡 P2. ¿Por qué el IP es más ancho que el IC?

El intervalo de predicción al 95 % para y_0 es más ancho que el intervalo de confianza al 95 % para $\mathbb{E}[y \mid x_0]$ porque:

- A. El intervalo de predicción usa un valor crítico t_c más grande.
- B. El intervalo de predicción incluye la varianza del nuevo error u_0 , la parte irreducible de la nueva extracción.
- C. El IC ignora por completo la varianza de las estimaciones MCO.
- D. El IP se construye con un tamaño muestral menor.

Respuesta: B. Ambos intervalos usan el mismo t_c . El IP añade un «1» dentro del corchete de la fórmula de la varianza, lo que captura $\text{Var}(u_0) = \sigma^2$ —algo que los datos no pueden predecir nunca—.

💡 P3. ¿Dónde son más anchos los intervalos?

Manteniendo la muestra fija, tanto el IC para la media como el IP para un individuo son *más anchos* cuando:

- A. x_0 coincide con la media muestral del regresor.
- B. El tamaño muestral es muy grande.
- C. x_0 está lejos de la media muestral del regresor.
- D. La varianza residual es cero.

Respuesta: C. Ambas varianzas contienen el término $(x_0 - \bar{x})^2 / \text{SCT}_x$, que crece a medida que x_0 se aleja de $\bar{x}$. Las predicciones son más precisas cerca del centro de los datos y menos precisas en los extremos; extrapolar fuera del soporte de los datos es peligroso.

💡 P4. R^2 ajustado y un regresor de ruido

Añadir un regresor de puro ruido a un modelo MCO:

- A. Aumenta estrictamente R^2 y aumenta estrictamente $\bar{R}^2$.
- B. No puede reducir R^2 , pero puede reducir $\bar{R}^2$.
- C. Siempre reduce R^2 porque el nuevo regresor no es informativo.
- D. No tiene efecto sobre ninguno de los dos criterios.

Respuesta: B. R^2 nunca cae al añadir un regresor. $\bar{R}^2$ penaliza la complejidad mediante la corrección por grados de libertad, así que un regresor irrelevante puede reducirlo. AIC y BIC también empeorarán.

💡 P5. Comparar AIC entre modelos

El criterio de Akaike puede usarse legítimamente para comparar:

- A. Dos modelos estimados en submuestras distintas de los datos.
- B. Una regresión de **wage** sobre **educ** frente a una regresión de **log(wage)** sobre **educ**.
- C. Dos modelos con la misma variable dependiente, los mismos datos y distintos conjuntos de regresores.
- D. Modelos estimados por métodos distintos (MCO, VI, GMM) sobre los mismos datos.

Respuesta: C. AIC (y BIC) solo son comparables cuando la variable dependiente, la muestra y el método de estimación son los mismos; en caso contrario, las log-verosimilitudes están en escalas distintas. La misma advertencia se aplica a R^2 y $\bar{R}^2$.

💡 P6. Causalidad vs. predicción

El modelo con el menor AIC es necesariamente el mejor para:

- A. La predicción y la identificación causal de los coeficientes individuales.
- B. La predicción de y dado x —pero no necesariamente para identificar el efecto causal de un regresor concreto—.
- C. Solo para la identificación causal.
- D. Para ninguno de los dos, pues el AIC siempre induce a error.

Respuesta: B. El AIC es un criterio predictivo. La identificación causal depende del supuesto $\mathbb{E}[u \mid x] = 0$, que es una afirmación sobre el diseño (asignación aleatoria, un instrumento, un argumento creíble), no sobre el ajuste del modelo. Un modelo excelente desde el punto de vista predictivo puede seguir sufriendo sesgo por variable omitida.

Ejercicios

Ejercicio 5.1 — Los dos intervalos a mano. Suponga que ha ajustado $\hat{y} = 2,0 + 0,7x$ sobre una muestra con $n = 100$, $\bar{x} = 12$, $SCT_x = 200$ y $\hat{\sigma}^2 = 4$. Tome $x_0 = 16$ y use $t_c = 1,98$.

- (a) Calcule la predicción puntual $\hat{y}_0$.
- (b) Calcule el intervalo de confianza al 95 % para $\mathbb{E}[y \mid x_0]$.
- (c) Calcule el intervalo de predicción al 95 % para y_0 .
- (d) Comente brevemente cuál de los dos intervalos citaría un *selector* y por qué.

💡 Mostrar respuesta

- (a) $\hat{y}_0 = 2,0 + 0,7 \times 16 = 13,2$.
- (b) $ee(\hat{y}_0) = 2\sqrt{1/100 + 16/200} = 2\sqrt{0,09} = 0,6$, así que $IC = 13,2 \pm 1,98 \times 0,6 = [12,01, 14,39]$.

- (c) $ee(f) = 2\sqrt{1+0,09} = 2\sqrt{1,09} \approx 2,088$, así que $IP = 13,2 \pm 1,98 \times 2,088 = [9,06, 17,34]$.
- (d) Ambos. El IC responde a «¿cuál es el salario *medio* de los trabajadores con el perfil del candidato?» —útil para planificar la compensación agregada—. El IP responde a «¿qué salario podría ganar realmente *este* candidato?» —útil para una oferta individual—. Comunicar solo uno de los dos resulta engañoso.

Ejercicio 5.2 — Lectura de una tabla de selección. Usando `wage1`, estime los cuatro modelos anidados de la práctica y presente una tabla 4×4 con R^2 , $\bar{R}^2$, AIC y BIC. ¿Qué modelo gana bajo cada criterio? ¿Coinciden los cuatro?

 Mostrar respuesta

En `wage1` los cuatro criterios coinciden en el orden: R^2 y $\bar{R}^2$ son máximos para `modelo4`; AIC y BIC son mínimos para `modelo4`. Cuando los cuatro coinciden, la elección es sencilla. Cuando el BIC selecciona un modelo menor que el AIC (lo que puede ocurrir con muestras grandes), la diferencia refleja la penalización más fuerte del BIC ($\ln n > 2$); la elección depende entonces de si se prioriza la precisión predictiva (AIC) o la parsimonia (BIC).

Ejercicio 5.3 — Un trabajador con 12 años y otro con 20 años. Usando `modelo4` de la práctica, calcule el intervalo de predicción al 95 % para dos perfiles: (i) `educ = 12`, `exper = 10`, `tenure = 5`, `female = 0`, `married = 1` y (ii) `educ = 20`, `exper = 10`, `tenure = 5`, `female = 0`, `married = 1`. ¿Es el segundo intervalo más ancho, más estrecho o igual de ancho que el primero? ¿Por qué?

 Mostrar respuesta

El segundo intervalo es más ancho. Veinte años de educación está lejos de la media muestral de `educ` en `wage1` (en torno a 12{,}5 años), de modo que el término $(x_0 - \bar{x})'(X'X)^{-1}(x_0 - \bar{x})$ de la fórmula de la varianza es mayor. Esta es la advertencia contra la extrapolación: cuanto más se aleje x_0 del centro de los datos, más anchos se vuelven ambos intervalos, y en algún punto se hacen tan anchos que la predicción deja de ser informativa.

Ejercicio 5.4 — Una variable basura en sus propios datos. Tome cualquier conjunto de datos a su elección (real o simulado). Ajuste un modelo base con uno o dos regresores genuinos e indique R^2 , $\bar{R}^2$, AIC y BIC. Añada cinco regresores de puro ruido gaussiano (`rnorm(n)`), reestime y vuelva a indicar los cuatro números. ¿Cuánto cambia cada uno? ¿Qué criterio se deja engañar y cuál no?

La solución completa figura en la Edición del Profesor.

Ejercicio 5.5 — Causalidad vs. predicción con un confusor. Suponga que y es la nota real, x son las horas de estudio y z es la habilidad innata. Horas y habilidad están positivamente correlacionadas. Estima dos modelos sobre una muestra grande: (a) $y \sim x$, (b) $y \sim x + z$. Razone, informalmente, que:

- (I) El modelo (b) tiene mayor R^2 y mayor $\bar{R}^2$ —es el mejor *predictor*—.
- (II) El modelo (a) ofrece una estimación causal *sesgada* del efecto de las horas sobre la nota; el modelo (b) no.
- (III) AIC y BIC preferirán ambos al modelo (b).

¿Qué conclusión extrae sobre el uso de AIC/BIC para elegir un modelo *causal*?

La solución completa figura en la Edición del Profesor.

Ejercicio 5.6 — **Predicción fuera de muestra.** Divida `wage1` en un conjunto de entrenamiento (las primeras 400 observaciones) y un conjunto de prueba (las 126 restantes). Estime `modelo1`–`modelo4` sobre el conjunto de entrenamiento. Para cada modelo, calcule (i) el R^2 dentro de muestra sobre el conjunto de entrenamiento, y (ii) el error cuadrático medio fuera de muestra sobre el conjunto de prueba: $\frac{1}{n_{\text{prueba}}} \sum_{i \in \text{prueba}} (y_i - \hat{y}_i)^2$. ¿Qué modelo gana en R^2 dentro de muestra? ¿Cuál gana en ECM fuera de muestra? Comente la relación entre $\bar{R}^2$ /AIC/BIC calculados en la muestra de entrenamiento y el ECM fuera de muestra.

La solución completa figura en la Edición del Profesor.

Relaciones No Lineales e Información Cualitativa

Objetivos

Al terminar este capítulo, el lector debería ser capaz de:

- Reconocer cuándo un modelo lineal en parámetros puede acomodar una relación no lineal en las variables, y elegir entre especificaciones cuadráticas y logarítmicas.
- Calcular efectos parciales y puntos de inflexión en modelos cuadráticos, y juzgar si el punto crítico es económicamente relevante.
- Interpretar coeficientes en modelos nivel-nivel, log-nivel, nivel-log y log-log en términos de pendientes, semi-elasticidades y elasticidades.
- Construir e interpretar términos de interacción, tanto entre dos variables continuas como entre una continua y una ficticia (ficticias de pendiente).
- Usar variables ficticias para información cualitativa binaria, nominal y ordinal, evitando la trampa de la ficticia.
- Contrastar un cambio estructural entre dos submuestras mediante el test F de Chow, calculado a mano y vía `anova()`.

Pregunta motivadora

¿Cada año adicional de experiencia incrementa siempre los salarios en la misma cuantía? ¿Y el rendimiento de la experiencia, o el de la apariencia, es el mismo para mujeres que para hombres?

Una regresión lineal del salario sobre la experiencia supone implícitamente que el décimo año de experiencia paga exactamente lo mismo que el primero. El sentido común y décadas de evidencia empírica en economía laboral sugieren lo contrario: el perfil salario-experiencia es *cóncavo*. De manera análoga, un único coeficiente sobre `female` recoge una brecha media en los interceptos pero nada dice acerca de si el *rendimiento* de la experiencia difiere por género. Las herramientas de este capítulo — cuadráticos, logaritmos, interacciones, ficticias y el test de Chow — permiten responder preguntas de este tipo sin abandonar MCO.

6.1. Relaciones no lineales en un modelo lineal

MUCHAS relaciones económicas no son líneas rectas. Los rendimientos decrecientes de la experiencia, las curvas de Kuznets en forma de U invertida, las curvas de coste medio en forma de U y las curvas de demanda de elasticidad constante violan todas la linealidad estricta en las variables. Por suerte, el modelo de referencia de este curso solo exige linealidad en los **parámetros**. Una especificación como

$$y = \beta_0 + \beta_1 x + \beta_2 x^2 + \varepsilon$$

es *no lineal* en x pero *lineal* en $\beta_0, \beta_1, \beta_2$, por lo que puede estimarse por MCO exactamente igual que la regresión múltiple del Capítulo 3, sin más que añadir x^2 como un regresor adicional. Lo mismo ocurre con $\ln(y)$, $\ln(x)$, $x_1 \cdot x_2$, $1/x$ y cualquier otra transformación de las variables que pueda calcularse antes de correr la regresión.

De aquí se siguen dos lecciones prácticas.

- *La especificación es una decisión de modelización.* La teoría, la evidencia empírica previa y un diagrama de dispersión deben guiar la elección entre una cuadrática, un logaritmo, una interacción o alguna combinación.
- *La interpretación cambia.* Una vez transformadas las variables, los coeficientes dejan de tener la lectura simple de “incremento de una unidad en x ”. Buena parte del capítulo trata precisamente de fijar esas interpretaciones.

i Definición: lineal en parámetros

Un modelo de regresión es *lineal en parámetros* si puede escribirse como $y = \beta_0 + \beta_1 g_1(\mathbf{x}) + \dots + \beta_k g_k(\mathbf{x}) + \varepsilon$, donde $g_1, \dots, g_k$ son funciones conocidas de los regresores. Las funciones g_j pueden ser muy no lineales (cuadrados, logaritmos, interacciones, ratios), pero cada una entra multiplicada por un único coeficiente desconocido. La estimación por MCO, el teorema de Gauss-Markov y la maquinaria inferencial de los Capítulos 3-5 son todos aplicables.

6.2. Modelos cuadráticos

La forma más sencilla de captar una relación no lineal consiste en añadir el cuadrado de un regresor:

$$y = \beta_0 + \beta_1 x + \beta_2 x^2 + \varepsilon.$$

Ahora el efecto parcial de x sobre y deja de ser constante:

$$\frac{\partial y}{\partial x} = \beta_1 + 2\beta_2 x.$$

El efecto marginal depende del *punto* del eje x en que lo evaluemos. Los signos de β_1 y β_2 determinan la forma de la relación:

- $\beta_1 > 0$, $\beta_2 < 0$: creciente y luego decreciente — U invertida con máximo en $x^* = -\beta_1/(2\beta_2)$.
- $\beta_1 < 0$, $\beta_2 > 0$: decreciente y luego creciente — forma de U con mínimo en x^* .
- $\beta_1 > 0$, $\beta_2 > 0$: creciente a tasa creciente (convexa, con pendiente positiva).
- $\beta_1 < 0$, $\beta_2 < 0$: decreciente a tasa creciente (descenso acelerado).

Igualando a cero el efecto parcial y despejando se obtiene el **punto de inflexión**

$$x^* = -\frac{\beta_1}{2\beta_2}.$$

Que x^* sea un máximo o un mínimo se lee directamente del signo de β_2 (negativo para un máximo, positivo para un mínimo).

Derivación del punto de inflexión

Partimos de la condición de primer orden $\partial y / \partial x = 0$:

$$\beta_1 + 2\beta_2 x = 0 \implies x^* = -\frac{\beta_1}{2\beta_2}.$$

La condición de segundo orden es $\partial^2 y / \partial x^2 = 2\beta_2$. Si $\beta_2 < 0$, la segunda derivada es negativa y x^* es un máximo; si $\beta_2 > 0$, la segunda derivada es positiva y x^* es un mínimo. La fórmula es la misma; el signo de β_2 decide la naturaleza del óptimo.

Ejemplo: salario y edad

Un estudio estima

$$\widehat{\text{wage}} = -10 + 1,5 \text{ age} - 0,02 \text{ age}^2.$$

El efecto marginal de la edad es $1,5 - 0,04 \text{ age}$.

- A los 20 años: $1,5 - 0,04(20) = 0,7$ euros por año de edad.
- A los 30 años: $1,5 - 0,04(30) = 0,3$ euros por año.
- A los 40 años: $1,5 - 0,04(40) = -0,1$ euros por año.

El punto de inflexión es $\text{age}^* = 1,5 / (2 \cdot 0,02) = 37,5$ años. Antes de los 37,5 un año más de edad aumenta el salario predicho; después, lo reduce.

Error frecuente: anunciar un punto de inflexión fuera de los datos

La fórmula $x^* = -\beta_1 / (2\beta_2)$ existe siempre, pero el punto de inflexión solo es económicamente significativo si cae dentro del rango muestral de x . Si x^* es, por ejemplo, 75 años de experiencia y nadie en la muestra supera los 50, el “punto crítico” es una extrapolación y no debería venderse como evidencia de rendimientos decrecientes entre los trabajadores con más experiencia — los datos simplemente no cubren esa zona.

En R, el término cuadrático se incluye con `I(exper^2)`. El envoltorio `I()` (de “as is”, *tal cual*) protege al operador `^` de ser interpretado por el lenguaje de fórmulas de R como cruce de efectos.

6.3. Transformaciones logarítmicas

Tomar el logaritmo natural de uno o de ambos lados de la ecuación de regresión cambia la interpretación del coeficiente. Los cuatro casos de uso habitual se resumen abajo, con β_1 denotando la pendiente sobre el regresor (posiblemente transformado).

Modelo	Dependiente	Independiente	Interpretación de β_1
Nivel-nivel	y	x	$\uparrow$ una unidad de $x \Rightarrow \Delta y \approx \beta_1$ unidades
Log-nivel	$\ln(y)$	x	$\uparrow$ una unidad de $x \Rightarrow y$ cambia $\approx 100 \beta_1 \%$ (semi-elasticidad)
Nivel-log	y	$\ln(x)$	$\uparrow 1\%$ en $x \Rightarrow \Delta y \approx \beta_1/100$ unidades
Log-log	$\ln(y)$	$\ln(x)$	$\uparrow 1\%$ en $x \Rightarrow y$ cambia $\approx \beta_1 \%$ (elasticidad)

Hay tres razones prácticas para tomar logaritmos de una variable estrictamente positiva como el salario o la renta: reducir la asimetría a la derecha, estabilizar la varianza (un remedio parcial frente a ciertas formas de heterocedasticidad; véase el Capítulo 7) y dar a los coeficientes una lectura en porcentaje. La especificación log-log es especialmente habitual cuando la teoría económica predice elasticidad constante (por ejemplo, funciones de producción Cobb-Douglas o demandas isoelásticas).

Ejemplo: ecuación de salario log-nivel

Si la ecuación estimada es

$$\ln(\widehat{\text{wage}}) = 1,5 + 0,02 \text{ age},$$

entonces un año adicional de edad se asocia con aproximadamente un $0,02 \times 100 = 2\%$ de aumento en el salario, manteniendo el resto constante. La aproximación $\% \Delta y \approx 100 \beta_1$ es precisa para β_1 pequeño; para coeficientes grandes el cambio porcentual exacto es $100(e^{\beta_1} - 1)$.

Error frecuente: tomar logaritmos de ceros o negativos

El logaritmo natural no está definido en cero ni en números negativos. Antes de logaritmar una variable, comprueba que todas las observaciones son estrictamente positivas. Para variables con muchos ceros (horas trabajadas, donaciones, exportaciones), $\ln$ no es una opción sin más; las alternativas incluyen $\ln(1 + x)$, el seno hiperbólico inverso o un modelo en dos partes. En este capítulo nos ceñimos a variables estrictamente positivas.

6.4. Términos de interacción

Un **término de interacción** permite que un regresor module el efecto parcial de otro. Con dos regresores continuos x_1 y x_2 ,

$$y = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \beta_3 (x_1 \cdot x_2) + \varepsilon,$$

el efecto parcial de x_1 sobre y es

$$\frac{\partial y}{\partial x_1} = \beta_1 + \beta_3 x_2.$$

Pasa ahora a depender del nivel de x_2 . Simétricamente, el efecto parcial de x_2 depende de x_1 . El coeficiente β_3 del producto nos dice cuánto varía la pendiente de x_1 cuando x_2 aumenta en una unidad (y viceversa).

La misma idea se aplica cuando una de las dos variables es una ficticia (Sección 6.5.2) o cuando ambas lo son. Una interacción significativa indica que el efecto de una variable sobre y es *heterogéneo* en la otra — una propiedad de enorme relevancia para la política económica: un

tratamiento con efecto *medio* positivo puede perjudicar a subgrupos concretos si la interacción es suficientemente grande en la dirección equivocada.

⚠ Error frecuente: omitir los efectos principales al incluir una interacción

Un modelo que contiene $x_1 \cdot x_2$ pero omite x_1 y/o x_2 por separado obliga al efecto parcial del término omitido a pasar por cero. Salvo que exista una razón teórica muy fuerte, *incluye siempre los efectos principales cuando incluyas su interacción*. En R, la sintaxis `x1*x2` se expande automáticamente a `x1 + x2 + x1:x2`, lo que evita este error.

6.5. Variables ficticias

La información cualitativa — género, estado civil, región, sector, estación — entra en una regresión mediante **variables ficticias** (también llamadas *indicadoras* o *binarias*). Una ficticia toma el valor 1 cuando la característica de interés está presente y 0 en caso contrario:

$$D = \begin{cases} 1 & \text{si la característica está presente,} \\ 0 & \text{en caso contrario.} \end{cases}$$

En trabajo aplicado son típicos tres tipos de variables cualitativas.

- *Binaria*: dos categorías, codificadas con una sola ficticia. Ejemplo: `female` = 1 si mujer, 0 si hombre.
- *Nominal*: más de dos, sin orden. Ejemplo: una variable `platform` con valores Instagram, TikTok, X. No hay ordenación numérica natural ni una noción de “más” o “menos”.
- *Ordinal*: más de dos, ordenadas. Ejemplo: la variable `looks` del dataset `beauty`, codificada de 1 (por debajo de la media) a 5 (por encima de la media).

Para una variable ordinal existe una disyuntiva. Puede tratarse como continua e incluir un único coeficiente de pendiente (asumiendo que el efecto de pasar de 2 a 3 es igual al de pasar de 4 a 5), o puede convertirse en un conjunto de ficticias y dejar que los datos decidan si los escalones están equispaciados. La práctica del §6.8 hace las dos cosas para comparar.

6.5.1. La trampa de la ficticia

Si una variable cualitativa tiene J categorías, en una regresión que contenga intercepto pueden incluirse a lo sumo $J - 1$ ficticias. Incluir las J generaría multicolinealidad perfecta con la constante: las J ficticias suman una columna de unos, que es exactamente la columna del intercepto. MCO no puede entonces identificar los coeficientes individuales — la matriz $X'X$ es singular — y cualquier software descartará automáticamente una de las ficticias o se negará a calcular. La categoría descartada se llama categoría de **referencia** o **base**, y cada uno de los demás coeficientes de ficticia se interpreta como una *diferencia respecto a ella*.

i Ejemplo: ficticia de intercepto por género

Supongamos

$$\widehat{\text{wage}} = 20 - 5 \text{ female} + 2 \text{ age}.$$

- Para los hombres (`female` = 0): $\widehat{\text{wage}} = 20 + 2 \text{ age}$.
- Para las mujeres (`female` = 1): $\widehat{\text{wage}} = 15 + 2 \text{ age}$.

La ficticia desplaza la recta de regresión *hacia abajo* en 5 euros para las mujeres, pero deja la *pendiente* sobre la edad inalterada. Hombres y mujeres ganan los mismos 2 euros por año de edad; solo difiere el intercepto.

6.5.2. Ficticias de pendiente (interacciones con una ficticia)

Para permitir que *tanto* el intercepto *como* la pendiente difieran entre grupos, interactúa la ficticia con un regresor continuo. El modelo

$$y = \beta_0 + \beta_1 D + \beta_2 x + \beta_3 (D \cdot x) + \varepsilon$$

tiene efecto parcial $\partial y / \partial x = \beta_2 + \beta_3 D$, que vale β_2 en el grupo de referencia ($D = 0$) y $\beta_2 + \beta_3$ en el grupo indicado ($D = 1$). El coeficiente β_3 de la interacción es exactamente la *diferencia de pendientes* entre los dos grupos, y un test t sobre β_3 es un contraste de igualdad de pendientes.

i Ejemplo: rendimientos distintos de la edad por género

Ecuación estimada:

$$\widehat{\text{wage}} = 20 - 5 \text{ female} + 2 \text{ age} - 1 (\text{female} \cdot \text{age}).$$

- Hombres: $\widehat{\text{wage}} = 20 + 2 \text{ age}$. Cada año añade 2 euros.
- Mujeres: $\widehat{\text{wage}} = 15 + 1 \text{ age}$. Cada año añade 1 euro.

La ficticia de intercepto (-5) y la de pendiente (-1) capturan dos formas distintas de desigualdad: las mujeres parten más abajo *y* además ganan menos con la edad.

6.6. Test de Chow

Supongamos que sospechamos que la *regresión completa* — intercepto y todas las pendientes — difiere entre dos grupos (hombres vs. mujeres, antes vs. después de una reforma, regiones tratadas vs. control). El **test de Chow** es el test F de la hipótesis nula conjunta

$$H_0 : \text{ todos los coeficientes son iguales en los dos grupos.}$$

Compara la suma de cuadrados de residuos de una regresión **agrupada** (una ecuación sobre la muestra completa) con la suma de las sumas de cuadrados de residuos de **dos regresiones separadas** (una por grupo).

Sean SCR_P la SCR agrupada y SCR_1, SCR_2 las SCR de las dos regresiones por grupo. Con k coeficientes de pendiente en la especificación (común) y $n = n_1 + n_2$ observaciones,

$$F = \frac{(SCR_P - SCR_1 - SCR_2)/(k+1)}{(SCR_1 + SCR_2)/(n - 2(k+1))} \sim F_{k+1, n-2(k+1)} \text{ bajo } H_0.$$

Los grados de libertad del numerador, $k+1$, cuentan los coeficientes que la hipótesis nula restringe a ser iguales (el intercepto más las k pendientes). Los grados de libertad del denominador, $n - 2(k+1)$, provienen de correr dos regresiones separadas, cada una con $k+1$ parámetros.

Algebraicamente, el mismo test puede hacerse agrupando los datos, interactuando completamente la ficticia de grupo con todos los regresores y usando `anova()` para comparar el modelo restringido con el irrestricto. La práctica del §6.8 verifica que ambos enfoques dan idéntico estadístico F y mismo p -valor.

⚠ Error frecuente: olvidar que Chow exige varianzas de error iguales

El estadístico F de Chow se deriva bajo el supuesto de que la varianza del error es la misma en los dos grupos. Si las dos submuestras presentan varianzas residuales muy diferentes, el test puede ser engañoso. La solución más limpia es un test de Wald con errores estándar robustos a heterocedasticidad sobre la regresión totalmente interactuada (Capítulo 7). Tomar logaritmos de la variable dependiente a veces también reduce la heterogeneidad de varianzas, pero *no* es un sustituto: cambia la pregunta que se contrasta — pasas a contrastar la igualdad de las ecuaciones de *log-salario*, no de las ecuaciones de *salario*, y los dos resultados del test no tienen por qué coincidir.

6.7. Práctica A: formas no lineales en *beauty* (Tutorial 6)

El dataset *beauty* del paquete **wooldridge** contiene salarios por hora, años de educación y de experiencia, una puntuación ordinal de apariencia (*looks*) de 1 a 5, y ficticias de género y estado civil. Lo usamos para ajustar una base lineal, añadir un término cuadrático en experiencia, tomar logaritmo del salario y, por último, introducir una interacción entre apariencia y educación.

```
library(wooldridge)
data("beauty")
# Renombramos al castellano para alinear con los apuntes.
beauty$salario <- beauty$wage
beauty$apariencia <- beauty$looks
beauty$mujer <- beauty$female
beauty$casado <- beauty$married
```

6.7.1. Una base lineal

```
modelo_lin <- lm(salario ~ apariencia + educ + exper, data = beauty)
summary(modelo_lin)
```

Call:

```
lm(formula = salario ~ apariencia + educ + exper, data = beauty)
```

Residuals:

Min	1Q	Median	3Q	Max
-8.248	-2.263	-0.821	1.272	71.925

Coefficients:

	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	-2.82166	0.85684	-3.293	0.00102 **
apariencia	0.41300	0.18318	2.255	0.02433 *
educ	0.45703	0.04807	9.508	< 2e-16 ***
exper	0.11374	0.01055	10.785	< 2e-16 ***

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

```
Residual standard error: 4.361 on 1256 degrees of freedom
Multiple R-squared:  0.1265,    Adjusted R-squared:  0.1244
F-statistic: 60.62 on 3 and 1256 DF,  p-value: < 2.2e-16
```

La base muestra los signos habituales: educación y apariencia se asocian con salarios más altos, también la experiencia. Pero la especificación lineal obliga a que el rendimiento marginal de la experiencia sea el mismo en el año 1 que en el año 30 — una restricción fuerte.

6.7.2. Añadiendo un término cuadrático en experiencia

```
modelo_quad <- lm(salario ~ apariencia + educ + exper + I(exper^2),
                  data = beauty)
summary(modelo_quad)
```

Call:

```
lm(formula = salario ~ apariencia + educ + exper + I(exper^2),
    data = beauty)
```

Residuals:

```
      Min       1Q   Median       3Q      Max
-8.164 -2.276 -0.694  1.200 71.927
```

Coefficients:

	Estimate	Std. Error	t value	Pr(> t)	
(Intercept)	-3.795520	0.872656	-4.349	1.48e-05	***
apariencia	0.436807	0.181628	2.405	0.0163	*
educ	0.422904	0.048156	8.782	< 2e-16	***
exper	0.299390	0.039670	7.547	8.53e-14	***
I(exper^2)	-0.004327	0.000892	-4.851	1.38e-06	***

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

```
Residual standard error: 4.323 on 1255 degrees of freedom
Multiple R-squared:  0.1426,    Adjusted R-squared:  0.1398
F-statistic: 52.17 on 4 and 1255 DF,  p-value: < 2.2e-16
```

El coeficiente de `exper` debería ser positivo y el de `I(exper^2)` negativo — el clásico perfil cóncavo salario-experiencia. El efecto marginal $\partial \text{salario} / \partial \text{exper} = \hat{\beta}_3 + 2\hat{\beta}_4 \text{exper}$ puede evaluarse en varios niveles de experiencia:

```
b3 <- coef(modelo_quad)["exper"]
b4 <- coef(modelo_quad)["I(exper^2)"]

# Rango de experiencia en la muestra
range(beauty$exper)
```

```
[1] 0 48
```

```
# Efecto marginal en exper = 10, 20, 30, 40
sapply(c(10, 20, 30, 40), function(x) b3 + 2 * b4 * x)
```

```
      exper      exper      exper      exper
0.21284197 0.12629376 0.03974555 -0.04680266
```

El rendimiento marginal se va reduciendo a medida que se acumula experiencia. El **punto de inflexión** es

```
exp_star <- -b3 / (2 * b4)
exp_star
```

```
      exper
34.5923
```

Siempre que `exp_star` caiga dentro del rango observado de `exper`, la parábola tiene un máximo significativo: a partir de ese punto, el salario predicho empieza a caer. Si queda fuera, lo único que podemos afirmar es que los rendimientos son decrecientes en todo el tramo observado.

6.7.3. Logaritmo del salario

Para pasar a una interpretación de semi-elasticidad, tomamos logaritmos en el lado izquierdo:

```
modelo_logq <- lm(log(salario) ~ apariencia + educ + exper + I(exper^2),
                  data = beauty)
summary(modelo_logq)
```

Call:

```
lm(formula = log(salario) ~ apariencia + educ + exper + I(exper^2),
    data = beauty)
```

Residuals:

```
      Min      1Q   Median      3Q      Max
-1.62220 -0.31622  0.02116  0.31609  2.78775
```

Coefficients:

```
      Estimate Std. Error t value Pr(>|t|)
(Intercept)  0.0462774   0.1053330   0.439  0.66049
apariencia    0.0620681   0.0219232   2.831  0.00471 **
educ          0.0683689   0.0058127  11.762 < 2e-16 ***
exper         0.0487326   0.0047884  10.177 < 2e-16 ***
I(exper^2)   -0.0006985   0.0001077  -6.487 1.26e-10 ***
---
```

```
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

Residual standard error: 0.5217 on 1255 degrees of freedom
Multiple R-squared: 0.2323, Adjusted R-squared: 0.2298
F-statistic: 94.91 on 4 and 1255 DF, p-value: < 2.2e-16

El coeficiente de `educ` se lee ahora como “un año más de educación se asocia con un aumento de $100 \cdot \hat{\beta}_{educ}$ por ciento en el salario por hora, manteniendo constante la apariencia y la experiencia”. El efecto marginal **porcentual** de un año más de experiencia en un nivel dado x es aproximadamente $100 (\hat{\beta}_{exper} + 2\hat{\beta}_{exper^2} x)$:

```
b31 <- coef(modelo_logq)["exper"]
b41 <- coef(modelo_logq)["I(exper^2)"]
sapply(c(10, 30), function(x) 100 * (b31 + 2 * b41 * x))
```

```
      exper      exper
3.4763529 0.6825305
```

Un trabajador con 10 años de experiencia gana un *porcentaje* distinto por año adicional que uno con 30.

6.7.4. Interacción: apariencia × educación

¿La prima salarial asociada a una mejor apariencia depende del nivel educativo del trabajador? La forma abreviada `apariciencia * educ` se expande a `apariciencia + educ + apariciencia:educ`:

```
modelo_int <- lm(log(salario) ~ apariciencia * educ + exper + I(exper^2),
                 data = beauty)
summary(modelo_int)
```

Call:

```
lm(formula = log(salario) ~ apariciencia * educ + exper + I(exper^2),
    data = beauty)
```

Residuals:

```
      Min       1Q   Median       3Q      Max
-1.62325 -0.31741  0.02058  0.31601  2.78849
```

Coefficients:

```
              Estimate Std. Error t value Pr(>|t|)
(Intercept) -0.0870703   0.3103984  -0.281   0.77913
apariciencia  0.1053823   0.0973400   1.083   0.27918
educ         0.0790930   0.0241898   3.270   0.00111 **
exper        0.0487614   0.0047903  10.179 < 2e-16 ***
I(exper^2)   -0.0006988   0.0001077  -6.488 1.25e-10 ***
apariciencia:educ -0.0034672  0.0075915  -0.457   0.64795
---
```

```
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

Residual standard error: 0.5219 on 1254 degrees of freedom

Multiple R-squared: 0.2324, Adjusted R-squared: 0.2293
 F-statistic: 75.92 on 5 and 1254 DF, p-value: < 2.2e-16

El efecto marginal de `apariencia` sobre $\ln(\text{salario})$ es $\hat{\beta}_{\text{apariencia}} + \hat{\beta}_{\text{apariencia:educ}} \cdot \text{educ}$. Multiplicado por 100 es el cambio porcentual del salario por una unidad más de `apariencia`:

```
b_apariencia <- coef(modelo_int)["apariencia"]
b_int        <- coef(modelo_int)["apariencia:educ"]
me <- function(e) 100 * (b_apariencia + b_int * e)
sapply(c(12, 16), me)
```

```
apariencia apariencias
6.377586    4.990705
```

Un sencillo test t sobre el coeficiente de la interacción (la fila `apariencia:educ` del resumen) indica si la prima varía genuinamente con la educación o si es estadísticamente indistinguible de una constante.

6.8. Práctica B: ficticias y test de Chow (Tutorial 7)

Esta práctica retoma la pregunta de género que abrió el capítulo. Usamos los mismos datos `beauty`, construimos ficticias categóricas a partir de la `apariencia` ordinal y cerramos con un test de Chow manual.

```
library(wooldridge)
data("beauty")
beauty$salario <- beauty$wage
beauty$apariencia <- beauty$looks
beauty$mujer <- beauty$female
beauty$casado <- beauty$married
table(beauty$mujer)
```

```
0 1
824 436
```

```
table(beauty$casado)
```

```
0 1
389 871
```

```
table(beauty$apariencia)
```

```
1 2 3 4 5
13 142 722 364 19
```

6.8.1. Ficticias de intercepto: género y estado civil

```
modelo_d <- lm(salario ~ apariencia + educ + exper + mujer + casado,
               data = beauty)
summary(modelo_d)
```

Call:

```
lm(formula = salario ~ apariencia + educ + exper + mujer + casado,
    data = beauty)
```

Residuals:

Min	1Q	Median	3Q	Max
-7.520	-2.190	-0.599	1.149	72.998

Coefficients:

	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	-1.66350	0.86433	-1.925	0.0545 .
apariencia	0.39694	0.17618	2.253	0.0244 *
educ	0.44112	0.04623	9.542	< 2e-16 ***
exper	0.08280	0.01065	7.778	1.53e-14 ***
mujer	-2.37281	0.26662	-8.899	< 2e-16 ***
casado	0.69044	0.27502	2.511	0.0122 *

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 4.192 on 1254 degrees of freedom

Multiple R-squared: 0.1944, Adjusted R-squared: 0.1912

F-statistic: 60.52 on 5 and 1254 DF, p-value: < 2.2e-16

El coeficiente de `mujer` es la brecha salarial estimada entre mujeres y hombres, manteniendo constantes `apariencia`, `educación` y `experiencia`; el coeficiente de `casado` es la prima por estar casado/a. Ambos desplazamientos afectan solo al intercepto — las pendientes sobre los regresores continuos quedan restringidas a ser iguales en los dos grupos.

6.8.2. Ficticia de pendiente: ¿el rendimiento de la apariencia difiere por género?

```
modelo_pend <- lm(salario ~ apariencia * mujer + educ + exper + casado,
                  data = beauty)
summary(modelo_pend)
```

Call:

```
lm(formula = salario ~ apariencia * mujer + educ + exper + casado,
    data = beauty)
```

Residuals:

```

      Min       1Q   Median       3Q      Max
-7.483 -2.200 -0.582  1.135 72.936

```

Coefficients:

```

      Estimate Std. Error t value Pr(>|t|)
(Intercept)   -1.52087    0.95946  -1.585   0.1132
apariencia     0.35024    0.22272   1.573   0.1161
mujer         -2.76205    1.16595  -2.369   0.0180 *
educ           0.44150    0.04626   9.544 < 2e-16 ***
exper          0.08270    0.01065   7.764 1.71e-14 ***
casado         0.69404    0.27531   2.521   0.0118 *
apariencia:mujer 0.12209    0.35602   0.343   0.7317
---

```

```

Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

```

Residual standard error: 4.193 on 1253 degrees of freedom

Multiple R-squared: 0.1945, Adjusted R-squared: 0.1906

F-statistic: 50.41 on 6 and 1253 DF, p-value: < 2.2e-16

```

b_apariencia <- coef(modelo_pend)["apariencia"]
b_int        <- coef(modelo_pend)["apariencia:mujer"]
me_hombres   <- b_apariencia
me_mujeres   <- b_apariencia + b_int
c(hombres = me_hombres, mujeres = me_mujeres)

```

```

hombres.apariencia mujeres.apariencia
      0.3502386      0.4723292

```

El coeficiente `apariencia:mujer` es la diferencia de pendiente de `apariencia` entre mujeres y hombres. Un test t sobre ese único coeficiente es exactamente el contraste de igualdad de pendientes; si es pequeño en valor absoluto, el rendimiento marginal de la apariencia es estadísticamente el mismo en ambos grupos.

6.8.3. Ficticias categóricas a partir de la apariencia ordinal

Tratar `apariencia` como continua impone equiespaciado entre categorías adyacentes. Un enfoque más flexible consiste en construir ficticias para las categorías y dejar que los datos hablen. Colapsamos `apariencia` en tres bloques — por debajo de la media (≤ 2), media ($= 3$) y por encima de la media (≥ 4) — y usamos `media` como referencia omitida:

```

beauty$bajo_media <- ifelse(beauty$apariencia <= 2, 1, 0)
beauty$alto_media <- ifelse(beauty$apariencia >= 4, 1, 0)
# 'media' (apariencia == 3) es la categoría de referencia y queda omitida.

modelo_cat <- lm(salario ~ bajo_media + alto_media + educ + exper +
                 mujer + casado, data = beauty)
summary(modelo_cat)

```

Call:

```
lm(formula = salario ~ bajo_media + alto_media + educ + exper +
    mujer + casado, data = beauty)
```

Residuals:

```
      Min       1Q   Median       3Q      Max
-7.351 -2.198 -0.551  1.188 73.141
```

Coefficients:

```
              Estimate Std. Error t value Pr(>|t|)
(Intercept) -0.31216    0.69931  -0.446   0.6554
bajo_media   -0.87991    0.37197  -2.366   0.0182 *
alto_media    0.07682    0.26956   0.285   0.7757
educ          0.44377    0.04618   9.610 < 2e-16 ***
exper         0.08113    0.01066   7.614 5.21e-14 ***
mujer        -2.36363    0.26669  -8.863 < 2e-16 ***
casado        0.67890    0.27499   2.469   0.0137 *
```

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 4.191 on 1253 degrees of freedom

Multiple R-squared: 0.1952, Adjusted R-squared: 0.1914

F-statistic: 50.65 on 6 and 1253 DF, p-value: < 2.2e-16

El coeficiente de `bajo_media` es la brecha salarial (en USD por hora de 1976) entre los trabajadores con apariencia “por debajo de la media” y el grupo omitido de apariencia “media”, manteniendo todo lo demás constante. El de `alto_media` es la brecha análoga para “por encima de la media”. Si las dos brechas son aproximadamente simétricas en torno a cero — $\hat{\beta}_{\text{bajo_media}} \approx -\hat{\beta}_{\text{alto_media}}$ —, la especificación continua era una simplificación razonable; si no, las ficticias revelan asimetría.

6.8.4. Test de Chow para cambio estructural por género

Preguntamos ahora si la ecuación salarial *completa* difiere entre hombres y mujeres, no solo el intercepto ni la pendiente de un único regresor. El test de Chow compara una regresión agrupada en la muestra completa con dos regresiones separadas, una por género. Obsérvese que `mujer` se elimina de las regresiones por subgrupo porque es constante dentro de cada submuestra:

```
# Regresión agrupada (muestra completa)
modelo_p <- lm(salario ~ bajo_media + alto_media + educ + exper +
               mujer + casado, data = beauty)

# Regresiones por subgrupo
modelo_f <- lm(salario ~ bajo_media + alto_media + educ + exper + casado,
               data = beauty, subset = mujer == 1)
modelo_m <- lm(salario ~ bajo_media + alto_media + educ + exper + casado,
               data = beauty, subset = mujer == 0)

SCR_P <- sum(residuals(modelo_p)^2)
SCR_F <- sum(residuals(modelo_f)^2)
```



```
SCR_M <- sum(residuals(modelo_m)^2)

n <- nrow(beauty)
k <- length(coef(modelo_p)) - 1 # n° de pendientes en el modelo agrupado

F_chow <- ((SCR_P - (SCR_F + SCR_M)) / (k + 1)) /
           ((SCR_F + SCR_M) / (n - 2 * (k + 1)))
p_valor <- 1 - pf(F_chow, df1 = k + 1, df2 = n - 2 * (k + 1))

c(F = F_chow, gl1 = k + 1, gl2 = n - 2 * (k + 1), p_valor = p_valor)
```

F	gl1	gl2	p_valor
1.4767802	7.0000000	1246.0000000	0.1713911

Si F_{chow} supera el valor crítico (equivalentemente, si p_{valor} cae por debajo del nivel de significación elegido), rechazamos H_0 y concluimos que la ecuación salarial no es la misma para hombres y mujeres — alguna combinación de intercepto y pendientes difiere.

6.8.5. Chow mediante anova()

El mismo test puede hacerse sobre la muestra agrupada interactuando `mujer` con cada uno de los demás regresores y comparando el modelo restringido con el irrestricto vía `anova()`:

```
mR <- lm(salario ~ bajo_media + alto_media + educ + exper + casado + mujer,
        data = beauty)
mU <- lm(salario ~ mujer * (bajo_media + alto_media + educ + exper + casado),
        data = beauty)
anova(mR, mU)
```

Analysis of Variance Table

```
Model 1: salario ~ bajo_media + alto_media + educ + exper + casado + mujer
Model 2: salario ~ mujer * (bajo_media + alto_media + educ + exper + casado)
  Res.Df  RSS Df Sum of Sq    F Pr(>F)
1    1253 22009
2    1248 21828  5    181.09 2.0708 0.06657 .
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

El estadístico F , los grados de libertad y el p -valor coinciden con el cálculo manual. Esta segunda forma suele ser más cómoda, porque admite de manera natural errores estándar robustos (Capítulo 7) y contrastes de cambio estructural parcial (cuando solo algunos coeficientes pueden diferir).

Auto-evaluación

Seis preguntas breves de opción múltiple. Intenta cada una antes de desplegar la respuesta.

💡 P1. Efecto marginal en un modelo cuadrático

En el modelo $y = \beta_0 + \beta_1 x + \beta_2 x^2 + \varepsilon$, el efecto marginal de x sobre y es:

- A. β_1 , constante.
- B. β_2 , constante.
- C. $\beta_1 + 2\beta_2 x$ — depende de x .
- D. Siempre positivo.

Respuesta: C. Derivando el modelo respecto a x se obtiene $\partial y / \partial x = \beta_1 + 2\beta_2 x$. El efecto marginal varía con el nivel en que se evalúe, que es precisamente lo que motiva la especificación cuadrática para captar rendimientos decrecientes (o acelerados).

💡 P2. Interpretación de un coeficiente log-nivel

En una regresión $\ln(y) = \beta_0 + \beta_1 x + \varepsilon$, el coeficiente β_1 es aproximadamente:

- A. El cambio en y por una unidad de x .
- B. El cambio porcentual en y por una unidad de x (en torno a $100\beta_1$ por ciento).
- C. La elasticidad de y respecto a x .
- D. El cambio en nivel en y cuando x se duplica.

Respuesta: B. Un coeficiente log-nivel es una **semi-elasticidad**: un aumento unitario de x se asocia con aproximadamente un $100\beta_1$ por ciento de cambio en y . Las elasticidades (opción C) corresponden a especificaciones log-log.

💡 P3. ¿Por qué es útil tomar logaritmos?

Una razón habitual para tomar logaritmos de una variable estrictamente positiva como el salario es:

- A. Violar a propósito los supuestos de Gauss-Markov.
- B. Porque R^2 siempre es mayor en modelos en logaritmos.
- C. Reducir la asimetría a la derecha, estabilizar parcialmente la varianza y obtener coeficientes con interpretación porcentual.
- D. Lograr que el regresor se distribuya normalmente.

Respuesta: C. Las tres motivaciones importan en trabajo aplicado. El logaritmo suele acercar a la simetría una distribución salarial sesgada, amortigua la varianza creciente con el nivel y ofrece semi-elasticidades o elasticidades fáciles de comunicar.

💡 P4. Interpretación de una interacción

Si $\hat{\beta}_3$ en el modelo $y = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \beta_3 (x_1 \cdot x_2) + \varepsilon$ es estadísticamente significativo, entonces:

- A. El efecto de x_1 sobre y es el mismo para cualquier valor de x_2 .
- B. x_1 y x_2 no tienen efectos separados.
- C. El efecto de x_1 sobre y *no* es constante: varía con x_2 .
- D. MCO pasa a ser sesgado.

Respuesta: C. Una interacción significativa implica pendientes heterogéneas. El efecto parcial de x_1 es $\beta_1 + \beta_3 x_2$ y depende del nivel de x_2 . En lenguaje causal, esto es exactamente la idea de *efectos de tratamiento heterogéneos*.

💡 P5. La trampa de la ficticia

Una variable categórica tiene 4 categorías. Incluyendo intercepto, debes añadir:

- A. 4 ficticias, una por categoría.
- B. 3 ficticias; la cuarta categoría queda como referencia omitida.
- C. 2 ficticias.
- D. 1 ficticia.

Respuesta: B. Con $J = 4$ categorías, incluir las cuatro ficticias junto al intercepto genera multicolinealidad perfecta: las cuatro suman la columna de unos. Hay que descartar una para que sirva de referencia y leer las tres restantes como diferencias respecto a ella.

💡 P6. ¿Qué contrasta el test de Chow?

El test de Chow para cambio estructural entre dos grupos contrasta la hipótesis nula:

- A. Todos los coeficientes (intercepto y pendientes) son iguales en los dos grupos.
- B. Solo difiere el intercepto.
- C. Solo difiere la pendiente de un regresor.
- D. Las dos varianzas del error son iguales.

Respuesta: A. El estadístico F de Chow compara la SCR agrupada con la suma de las SCR por subgrupo. Bajo H_0 , todos los coeficientes — intercepto y las k pendientes — son iguales en los dos grupos. Rechazar H_0 dice únicamente que *alguno* difiere; no precisa cuál.

La versión interactiva en `learnr`, con doce preguntas y código R en vivo, está en `LEARNR/06_nonlinear_and_qualitative.Rmd`.

Ejercicios

Ejercicio 6.1 — Efecto marginal y punto de inflexión. Con `wage1` del paquete `wooldridge`, estima

$$\ln(\text{wage}) = \beta_0 + \beta_1 \text{educ} + \beta_2 \text{exper} + \beta_3 \text{exper}^2 + \varepsilon.$$

- (a) Reporta $\hat{\beta}_2$, $\hat{\beta}_3$ y sus errores estándar.
- (b) Calcula el rendimiento marginal *porcentual* de la experiencia en `exper = 5, 15, 25`.
- (c) Halla el nivel x^* que maximiza el logaritmo del salario predicho y comprueba que cae dentro del rango muestral.

Solución completa en la edición del docente.

Ejercicio 6.2 — ¿Cuántas ficticias? Una variable categórica `region` toma los valores Norte, Sur, Este, Oeste.

- (a) ¿Cuántas ficticias deberías incluir en una regresión que contenga intercepto? ¿Por qué?
- (b) Escribe el modelo con intercepto y $J - 1$ ficticias y explica cómo interpretar cada coeficiente.

6. Relaciones No Lineales e Información Cualitativa

- (c) Describe en una frase qué cambiaría si, en su lugar, eliminaras el intercepto e incluyeras las cuatro ficticias.

Solución completa en la edición del docente.

Ejercicio 6.3 — Test de Chow para casados vs. solteros. Con `wage1`, realiza un test de Chow para determinar si la ecuación

$$\ln(\text{wage}) = \beta_0 + \beta_1 \text{educ} + \beta_2 \text{exper} + \beta_3 \text{tenure} + \varepsilon$$

difiere entre trabajadores casados y no casados. Reporta (i) las tres SCR, (ii) el estadístico F con sus dos grados de libertad y (iii) el p -valor. Verifica el cálculo manual frente a `anova()` sobre el modelo equivalente totalmente interactuado.

Solución completa en la edición del docente.

Ejercicio 6.4 — Ficticia de pendiente por género. Con `wage1`, estima

$$\ln(\text{wage}) = \beta_0 + \beta_1 \text{female} + \beta_2 \text{educ} + \beta_3 (\text{female} \cdot \text{educ}) + \varepsilon.$$

- (a) Interpreta $\hat{\beta}_3$ en lenguaje llano.
- (b) ¿Cuál es el rendimiento porcentual estimado de un año más de educación para los hombres? ¿Y para las mujeres?
- (c) Contrasta $H_0 : \beta_3 = 0$ al 5 % y enuncia la conclusión económica.

Solución completa en la edición del docente.

Ejercicio 6.5 — Ordinal como continua frente a ficticias. Con `beauty`:

- (a) Estima $\text{wage} = \beta_0 + \beta_1 \text{looks} + \beta_2 \text{educ} + \beta_3 \text{exper} + \varepsilon$, tratando `looks` como continua.
- (b) Re-estima el mismo modelo sustituyendo `looks` por las ficticias `bajo_media` y `alto_media` definidas en §6.8.
- (c) Compara las brechas implícitas (por debajo de la media vs. media; por encima de la media vs. media). ¿Son aproximadamente simétricas en torno a cero? ¿Qué dice eso sobre el supuesto de linealidad implícito en (a)?

Solución completa en la edición del docente.

Ejercicio 6.6 — Por qué ambas formas del Chow coinciden. Demuestra algebraicamente que correr dos regresiones separadas sobre las submuestras de hombres y mujeres da exactamente los mismos valores ajustados, residuos y SCR que correr la regresión agrupada con `mujer` interactuada por completo con todos los regresores. Usa ese hecho para argumentar que el estadístico F de Chow manual (tres SCR) y el de `anova()` deben ser numéricamente idénticos.

Solución completa en la edición del docente.

Heterocedasticidad

Objetivos

Al finalizar este capítulo el lector debería ser capaz de:

- Enunciar el supuesto de homocedasticidad RLM.5 en la notación de Wooldridge y reconocer cuándo es probable que falle en datos de sección cruzada.
- Explicar por qué la heterocedasticidad deja a MCO insesgado y consistente, pero destruye su eficiencia e invalida los errores estándar, los contrastes t y los contrastes F habituales.
- Detectar la heterocedasticidad de manera informal con gráficos de residuos y de manera formal con los tests de Goldfeld–Quandt y Breusch–Pagan.
- Corregir la heterocedasticidad mediante Mínimos Cuadrados Ponderados (MCP) cuando la forma de la varianza condicional es conocida.
- Calcular y reportar errores estándar robustos a la heterocedasticidad (White / HC1) cuando la forma es desconocida.
- Construir una tabla comparativa de errores estándar MCO frente a errores estándar robustos e interpretar el cociente entre ellos.

Pregunta motivadora

¿Por qué los intervalos de confianza MCO convencionales subestiman la incertidumbre real en una regresión salarial donde los salarios altos están muy dispersos — y qué deberíamos hacer al respecto?

Una regresión del salario por hora sobre los años de educación entrega una estimación puntual limpia del rendimiento de la escolarización. Pero la dispersión de los salarios alrededor de la recta de regresión **no** es la misma para quienes abandonan la secundaria y para los doctorados: los graduados se reparten en un rango salarial mucho más amplio. La fórmula MCO de manual para el error estándar de $\hat{\beta}_1$ supone que la dispersión es constante. Cuando no lo es, los errores estándar reportados son incorrectos, los estadísticos t son incorrectos y las recomendaciones de política construidas sobre ellos son incorrectas. Este capítulo muestra cómo diagnosticar el problema y cómo arreglarlo.

7.1. Introducción

EN el Capítulo 4 enumeramos los supuestos RLM.1–RLM.6 del modelo de regresión lineal múltiple que justifican MCO. El supuesto de **homocedasticidad** RLM.5 establece que la varianza del error es la misma para cualquier valor de los regresores:

7. Heterocedasticidad

$$\text{Var}(u_i | \mathbf{x}_i) = \sigma^2, \quad i = 1, \dots, n.$$

Cuando RLM.5 falla, la varianza condicional depende de $\mathbf{x}_i$:

$$\text{Var}(u_i | \mathbf{x}_i) = \sigma_i^2,$$

y se dice que el error es **heterocedástico**. La raíz griega ayuda a recordarlo: *homo-cedástico* significa «misma dispersión»; *hetero-cedástico* significa «dispersión distinta».

Ejemplo: variabilidad salarial y educación

Los trabajadores con solo educación primaria en un mercado laboral europeo típico ganan entre aproximadamente 15.000 y 25.000 euros anuales — un rango estrecho. Los graduados universitarios ganan entre 20.000 y 200.000 euros — un rango mucho más amplio. La varianza condicional de los salarios crece claramente con la educación. El término de error en una ecuación salarial $\text{salario}_i = \beta_0 + \beta_1 \text{educ}_i + u_i$ exhibe por tanto heterocedasticidad: $\text{Var}(u_i | \text{educ}_i)$ crece con **educ**.

La heterocedasticidad **no** es un problema de identificación. Mientras se mantenga $\mathbb{E}[u_i | \mathbf{x}_i] = 0$ (supuesto RLM.4), el *significado* de β_j como efecto *ceteris paribus* sobrevive. Lo que la heterocedasticidad rompe es la **inferencia** — la maquinaria que convierte una estimación puntual $\hat{\beta}_j$ en un intervalo de confianza o un contraste de hipótesis.

Error frecuente: confundir heterocedasticidad con sesgo por omisión de variables

La heterocedasticidad afecta a $\text{Var}(u_i | \mathbf{x}_i)$; el sesgo por omisión de variables afecta a $\mathbb{E}[u_i | \mathbf{x}_i]$. El primero deja $\hat{\beta}_j$ insesgado y solo daña los errores estándar. El segundo sesga el propio $\hat{\beta}_j$. Los dos problemas requieren herramientas distintas, y un mismo conjunto de datos puede sufrir uno, otro, ambos o ninguno.

Dónde aparece típicamente la heterocedasticidad

La heterocedasticidad es **la regla, no la excepción**, en los datos microeconómicos de sección cruzada, al menos por tres razones:

- **Efectos de escala.** Las unidades más grandes tienen más espacio para variar. El gasto de las empresas grandes varía más en términos absolutos que el de las pequeñas.
- **Resultados discretos y acotados.** Una variable dependiente binaria tiene mecánicamente $\text{Var}(y | \mathbf{x}) = p(\mathbf{x})[1 - p(\mathbf{x})]$, que no es constante.
- **Agregación.** Las medias calculadas sobre grupos de distinto tamaño tienen varianzas proporcionales a $1/n_g$, generando heterocedasticidad por construcción.

Estas son precisamente las estructuras de datos con las que trabajan los economistas aplicados, lo que explica por qué los errores estándar robustos se han convertido en la práctica por defecto en la econometría moderna.

7.2. Consecuencias de la heterocedasticidad

Supongamos que RLM.1–RLM.4 se mantienen y que solo RLM.5 falla. Tres enunciados resumen las consecuencias:

1. **MCO sigue siendo insesgado y consistente.** La insesgadez de $\hat{\beta}_j$ requiere solamente RLM.1–RLM.4. La heterocedasticidad no entra en la demostración.
2. **MCO ya no es ELIO.** El teorema de Gauss–Markov requiere homocedasticidad. Bajo heterocedasticidad, *otros* estimadores lineales e insesgados pueden tener varianza menor que MCO. Veremos uno de ellos, MCP, en el §7.4.
3. **Los errores estándar MCO habituales son incorrectos.** La fórmula de manual $\widehat{\text{Var}}(\hat{\beta}_j) = \hat{\sigma}^2(\mathbf{X}'\mathbf{X})_{jj}^{-1}$ supone que la matriz de varianzas y covarianzas del error es $\sigma^2\mathbf{I}_n$. Cuando no lo es, esta fórmula es sesgada. En el caso más habitual — varianza que *crece* con los regresores, la típica forma de «abanico» ilustrada arriba — los errores estándar MCO son *demasiado pequeños* y los estadísticos *t* *demasiado grandes*, de modo que los intervalos de confianza resultan demasiado estrechos y rechazamos la hipótesis nula con más frecuencia de la que deberíamos. La dirección contraria también es posible: cuando las observaciones de alta varianza tienen *poco apalancamiento* sobre la pendiente, los errores estándar robustos pueden salir *más pequeños* que los MCO. Es menos común en la práctica, pero conviene saberlo para que el diagnóstico sea «la fórmula MCO es incorrecta» y no «la fórmula MCO es siempre optimista».

i La varianza correcta (sándwich) bajo heterocedasticidad

Si recogemos las varianzas condicionales en la diagonal de una matriz $\Omega = \text{diag}(\sigma_1^2, \dots, \sigma_n^2)$, la varianza condicional *correcta* del estimador MCO es

$$\text{Var}(\hat{\beta} | \mathbf{X}) = (\mathbf{X}'\mathbf{X})^{-1} \mathbf{X}'\Omega\mathbf{X} (\mathbf{X}'\mathbf{X})^{-1}.$$

El «pan» $(\mathbf{X}'\mathbf{X})^{-1}$ rodea a la «carne» $\mathbf{X}'\Omega\mathbf{X}$ — y por eso esta forma se conoce universalmente como estimador **sándwich**. La fórmula MCO habitual simplemente sustituye Ω por $\sigma^2\mathbf{I}_n$ y colapsa el sándwich en una sola loncha. El estimador White / HC1 que usamos en el §7.4 estima Ω por $\text{diag}(\hat{u}_1^2, \dots, \hat{u}_n^2)$, con una corrección de grados de libertad para muestras finitas.

En resumen: la heterocedasticidad es un problema de los *errores estándar*, no de los *coeficientes*. La solución pasa por reparar la maquinaria inferencial (errores estándar robustos) o, si nos podemos permitir el modelado adicional, por usar un estimador que explote la estructura de varianzas (MCP).

7.3. Detección de la heterocedasticidad

Describimos un diagnóstico informal y dos contrastes formales. El gráfico informal es barato y debería ser lo primero que se mira; los contrastes formales proporcionan una regla de decisión estructurada.

7.3.1. Detección informal: gráficos de residuos

Después de estimar el modelo por MCO, se calculan los residuos $\hat{u}_i = y_i - \hat{y}_i$ y se representan frente a los valores ajustados $\hat{y}_i$ o frente a cada regresor x_j . La huella visual de la heterocedasticidad es

7. Heterocedasticidad

una forma de **abanico** o **cuña**: la dispersión vertical de la nube de residuos se ensancha (o se estrecha) a medida que avanzamos por el eje horizontal. Los residuos al cuadrado $\hat{u}_i^2$ frente a x_j hacen el patrón aún más obvio, porque ya no importa el signo del residuo.

Si la nube parece una banda horizontal de espesor aproximadamente constante, la homocedasticidad es plausible. Si se abre — como típicamente ocurre cuando x_j es renta, tamaño de la empresa o cualquier otra variable de «escala» — la heterocedasticidad es la sospechosa natural.

7.3.2. El test de Goldfeld–Quandt

El test de Goldfeld–Quandt (GQ) es apropiado cuando se sospecha que la heterocedasticidad está impulsada por **un** regresor concreto. La idea es simple: dividir la muestra en un grupo de x bajo y un grupo de x alto, y comparar las varianzas residuales de las dos submuestras.

Pasos.

1. Ordenar las observaciones por la variable sospechosa x .
2. Opcionalmente, descartar las m observaciones centrales (a menudo $m \approx n/3$) para acentuar el contraste.
3. Estimar el modelo por separado en el grupo bajo (submuestra 1) y en el grupo alto (submuestra 2). Obtener las sumas de cuadrados de los residuos SCR_1 y SCR_2 , con grados de libertad gl_1 y gl_2 .
4. Calcular

$$F = \frac{SCR_2 / gl_2}{SCR_1 / gl_1} \sim F_{gl_2, gl_1} \quad \text{bajo } H_0.$$

Hipótesis. H_0 : homocedasticidad. H_1 : $\text{Var}(u)$ crece con x (la alternativa más habitual). Se rechaza H_0 cuando F excede el valor crítico de la cola superior de la distribución F .

El test GQ fue históricamente popular en muestras pequeñas y resulta intuitivo, pero exige al analista *comprometerse* con una única variable de ordenación y con una regla de partición de la muestra. El test de Breusch–Pagan, que presentamos a continuación, prescinde de ambos compromisos.

7.3.3. El test de Breusch–Pagan

El test de Breusch–Pagan (BP) detecta heterocedasticidad relacionada con **cualquiera** de los regresores. Es el contraste formal de cabecera en el trabajo aplicado moderno.

Pasos.

1. Estimar el modelo original por MCO y guardar los residuos $\hat{u}_i$.
2. Correr la **regresión auxiliar** de los residuos al cuadrado sobre todos los regresores originales:

$$\hat{u}_i^2 = \gamma_0 + \gamma_1 x_{1i} + \gamma_2 x_{2i} + \cdots + \gamma_k x_{ki} + v_i.$$

3. Calcular el estadístico BP

$$BP = n \cdot R_{\text{aux}}^2 \sim \chi_k^2 \quad \text{bajo } H_0,$$

donde R_{aux}^2 es el coeficiente de determinación de la regresión auxiliar y k es el número de coeficientes pendiente de esa regresión.

Hipótesis. $H_0 : \gamma_1 = \gamma_2 = \dots = \gamma_k = 0$ (homocedasticidad). Se rechaza cuando $BP > \chi_{k,\alpha}^2$.

La intuición es directa: si el residuo al cuadrado se explica *sistemáticamente* por los regresores, entonces $\text{Var}(u | \mathbf{x})$ varía con $\mathbf{x}$, que es la definición de heterocedasticidad. Un primo cercano — el **test de White** — añade cuadrados y productos cruzados de los regresores a la regresión auxiliar y detecta así formas más generales de heterocedasticidad, a costa de grados de libertad.

 Error frecuente: encadenar tests hasta que uno rechace

No conviene ejecutar GQ, luego BP, luego White, y reportar el que rechaza «primero». Es una forma de *p-hacking*. Elige un test basándote en lo que sospechas *antes* de mirar los residuos, o — siguiendo la práctica moderna — omite directamente la fase de contraste y reporta errores estándar robustos por defecto.

7.4. Soluciones

Existen dos soluciones principales, adaptadas a dos estados distintos del conocimiento.

7.4.1. Mínimos Cuadrados Ponderados (MCP)

Supongamos que conocemos (o estamos dispuestos a modelar) la forma de la varianza condicional:

$$\text{Var}(u_i | \mathbf{x}_i) = \sigma^2 h(\mathbf{x}_i),$$

donde $h(\mathbf{x}_i) > 0$ es una función conocida de los regresores. Un ejemplo típico es $h(\mathbf{x}_i) = x_i$ cuando la varianza es proporcional a una variable de escala como la renta.

Dividamos cada término de la regresión por $\sqrt{h(\mathbf{x}_i)}$:

$$\frac{y_i}{\sqrt{h(\mathbf{x}_i)}} = \beta_0 \frac{1}{\sqrt{h(\mathbf{x}_i)}} + \beta_1 \frac{x_i}{\sqrt{h(\mathbf{x}_i)}} + \frac{u_i}{\sqrt{h(\mathbf{x}_i)}}.$$

El nuevo error $u_i^* = u_i / \sqrt{h(\mathbf{x}_i)}$ tiene varianza constante:

$$\text{Var}(u_i^*) = \frac{\sigma^2 h(\mathbf{x}_i)}{h(\mathbf{x}_i)} = \sigma^2.$$

Aplicar MCO al modelo transformado equivale a aplicar **mínimos cuadrados ponderados**: minimizar

$$\sum_{i=1}^n \frac{1}{h(\mathbf{x}_i)} (y_i - \beta_0 - \beta_1 x_i - \dots)^2.$$

7. Heterocedasticidad

Cada observación recibe un peso $w_i = 1/h(\mathbf{x}_i)$. Las observaciones con varianza alta reciben *menos* peso; las observaciones con varianza baja reciben *más*. Cuando los pesos están correctamente especificados, MCP es ELIO: tiene menor varianza que MCO sin dejar de ser insesgado.

⚠ Error frecuente: forzar MCP cuando no se conoce $h(\mathbf{x})$

MCP solo es ELIO bajo pesos *correctamente especificados*. Con pesos equivocados puede ser *menos* eficiente que MCO, y sus errores estándar vuelven a ser incorrectos. Si solo se tiene una idea vaga de la estructura de varianzas, conviene preferir errores estándar robustos.

7.4.2. Errores estándar robustos a la heterocedasticidad

Cuando se desconoce la forma de $h(\mathbf{x})$, la solución más segura es mantener MCO para las estimaciones puntuales y calcular **errores estándar consistentes a la heterocedasticidad (HC)**, también llamados **robustos** o **de White**, en honor a (White 1980).

En el caso de regresión simple, con $\hat{u}_i$ el residuo MCO,

$$ee_{\text{robusto}}(\hat{\beta}_1) = \sqrt{\frac{\sum_{i=1}^n (x_i - \bar{x})^2 \hat{u}_i^2}{\left[\sum_{i=1}^n (x_i - \bar{x})^2\right]^2}}.$$

La expresión matricial general es el estimador sándwich del §7.2 con Ω reemplazada por $\text{diag}(\hat{u}_1^2, \dots, \hat{u}_n^2)$. Existen varias variantes (HC0, HC1, HC2, HC3) que difieren en su corrección de grados de libertad para muestras finitas; **HC1** es la opción por defecto de la orden , **robust** de Stata y es la habitual en el trabajo aplicado publicado.

Los errores estándar robustos dejan inalteradas las estimaciones puntuales $\hat{\beta}_j$. Solo se corrige la varianza — y por tanto los estadísticos t , los p -valores y los intervalos de confianza.

i Cuándo usar cada cosa

- **Estructura de varianzas conocida y fiable** $\Rightarrow$ MCP (ELIO, errores estándar menores).
- **Estructura de varianzas desconocida** $\Rightarrow$ MCO con errores estándar robustos (coeficientes insesgados, inferencia válida, errores estándar mayores).
- **En la duda** $\Rightarrow$ reportar errores estándar robustos. En la econometría aplicada moderna, los errores estándar robustos se han convertido en la opción por defecto, no en un plan B. Muchas revistas los esperan por construcción.

7.5. Práctica: Heterocedasticidad en R

Esta práctica corresponde a la Práctica 8 del curso. El conjunto de datos `het_datos.xlsx` es una sección cruzada propia de consumo y renta a nivel de hogar, dividida en tres tramos de renta (`grupo` $\in \{1, 2, 3\}$, de bajo a alto). Estimamos una regresión simple de tipo curva de Engel del consumo sobre la renta, detectamos heterocedasticidad y a continuación la corregimos por dos vías — primero por MCP y después con errores estándar robustos.

Usamos tres paquetes: `readxl` para leer el fichero Excel, `lmtest` para los tests de Breusch–Pagan y Goldfeld–Quandt y para `coeftest()`, y `sandwich` para la matriz de varianzas–covarianzas robusta.

```
library(readxl)
library(lmtest)
library(sandwich)
```

7.5.1. Carga de los datos

La práctica original utiliza una ruta relativa (`read_excel("het_datos.xlsx")`) tras hacer `setwd()` en la carpeta de la Práctica 8. Para que el libro sea portable mantenemos ese estilo pero documentamos la ruta absoluta utilizada en tiempo de compilación. Adapta la ruta a tu equipo.

```
het_path <- file.path(
  "..", "..", "..", "..", "SPANISH", "Practicas", "2025", "Tutorial 8", "het_datos.xlsx"
)
het_datos <- read_excel(het_path)

# Construimos un indicador de tercil de renta para la división de Goldfeld-Quandt:
# grupo == 1 = tercio bajo, 2 = tercio medio, 3 = tercio alto.
het_datos$grupo <- as.integer(cut(het_datos$renta,
                                breaks = quantile(het_datos$renta,
                                                    probs = c(0, 1/3, 2/3, 1)),
                                include.lowest = TRUE))
str(het_datos)
```

```
tibble [30 x 4] (S3: tbl_df/tbl/data.frame)
 $ id      : num [1:30] 1 2 3 4 5 6 7 8 9 10 ...
 $ consumo: num [1:30] 433 663 690 727 800 ...
 $ renta   : num [1:30] 649 939 956 1067 1071 ...
 $ grupo   : int [1:30] 1 1 1 1 1 1 1 1 1 1 ...
```

```
head(het_datos)
```

```
# A tibble: 6 x 4
   id consumo renta grupo
<dbl> <dbl> <dbl> <int>
1     1    433.  649.     1
2     2    663.  939.     1
3     3    690.  956.     1
4     4    727. 1067.     1
5     5    800. 1071.     1
6     6    777. 1215.     1
```

El `xlsx` original incluye `renta` y `consumo`. Añadimos una variable derivada `grupo` igual al tercil de la renta (1 = bajo, 2 = medio, 3 = alto) para que el test de Goldfeld–Quandt pueda dividir la muestra a continuación.

7.5.2. Paso 1. MCO de referencia y gráfico de residuos

```
modelo1 <- lm(consumo ~ renta, data = het_datos)
summary(modelo1)
```

Call:

```
lm(formula = consumo ~ renta, data = het_datos)
```

Residuals:

Min	1Q	Median	3Q	Max
-280.684	-52.408	2.257	58.517	234.525

Coefficients:

	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	13.94848	70.77718	0.197	0.845
renta	0.65532	0.03864	16.961	2.91e-16 ***

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 117.5 on 28 degrees of freedom

Multiple R-squared: 0.9113, Adjusted R-squared: 0.9081

F-statistic: 287.7 on 1 and 28 DF, p-value: 2.91e-16

El coeficiente pendiente $\hat{\beta}_1$ es la propensión marginal media a consumir sobre la renta. Para comprobar la homocedasticidad de forma informal, representamos los residuos MCO frente a renta:

```
plot(het_datos$renta, resid(modelo1),
     xlab = "Renta",
     ylab = "Residuos",
     main = "Residuos frente a renta",
     pch = 16,
     col = rgb(0, 0, 1, 0.4))
abline(h = 0, lty = 2, col = "red")
```




Figure 7.1.: Residuos de consumo ~ renta frente a renta. Una nube que se ensancha sugiere heterocedasticidad.

La nube se abre al crecer la renta: los residuos forman un abanico. Es exactamente la forma de cuña que avisamos en el §7.3.1.

7.5.3. Paso 2. Test de Goldfeld–Quandt a mano

Estimamos el modelo por separado en las submuestras de renta baja (`grupo == 1`) y de renta alta (`grupo == 3`), y comparamos las dos varianzas residuales.

```
modelo_bajo <- lm(consumo ~ renta, data = het_datos, subset = grupo == 1)
modelo_alto <- lm(consumo ~ renta, data = het_datos, subset = grupo == 3)

SCR_bajo <- sum(residuals(modelo_bajo)^2)
SCR_alto <- sum(residuals(modelo_alto)^2)

n_bajo <- nobs(modelo_bajo)
n_alto <- nobs(modelo_alto)
k      <- length(coef(modelo_bajo))      # constante + pendiente

gl_bajo <- n_bajo - k
gl_alto <- n_alto - k

F_GQ    <- (SCR_alto / gl_alto) / (SCR_bajo / gl_bajo)
```

7. Heterocedasticidad

```
F_crit <- qf(0.95, gl_alto, gl_bajo)
p_gq    <- 1 - pf(F_GQ, gl_alto, gl_bajo)

c(F = F_GQ, F_crit_5pct = F_crit, p_valor = p_gq)
```

```
      F F_crit_5pct      p_valor
9.582976952 3.438101233 0.002205927
```

Si F_{GQ} está bastante por encima de F_{crit_5pct} — o, equivalentemente, si el p -valor está por debajo de 0,05 — rechazamos la homocedasticidad en favor de «la varianza crece con la renta».

7.5.4. Paso 3. Test de Breusch–Pagan (a mano y con `bptest()`)

La regresión auxiliar de los residuos al cuadrado sobre la renta nos da R_{aux}^2 ; el estadístico BP es $n \cdot R_{aux}^2$ y sigue una χ_1^2 bajo H_0 (hay un único regresor, *renta*).

```
res    <- residuals(modelo1)
res_sq <- res^2
aux     <- lm(res_sq ~ renta, data = het_datos)

n        <- nobs(modelo1)
R2_aux   <- summary(aux)$r.squared
BP_stat  <- n * R2_aux
chi_crit <- qchisq(0.95, df = 1)
p_bp     <- 1 - pchisq(BP_stat, df = 1)

c(BP_manual = BP_stat, chi2_1_5pct = chi_crit, p_valor = p_bp)
```

```
BP_manual chi2_1_5pct      p_valor
4.86609184  3.84145882  0.02738946
```

La versión del paquete entrega la misma respuesta en una línea:

```
bptest(modelo1)
```

studentized Breusch-Pagan test

```
data:  modelo1
BP = 4.8661, df = 1, p-value = 0.02739
```

Un p -valor pequeño (por debajo de 0,05) significa que rechazamos la homocedasticidad. Los dos cálculos deberían coincidir salvo redondeo.

7.5.5. Paso 4. Corrección por MCP

Supongamos $\text{Var}(u_i \mid \text{renta}_i) \propto \text{renta}_i$, de modo que $h(\text{renta}_i) = \text{renta}_i$. Los pesos MCP son $w_i = 1/\text{renta}_i$.

```
mcp <- lm(consumo ~ renta, data = het_datos, weights = 1 / renta)
summary(mcp)
```

Call:

```
lm(formula = consumo ~ renta, data = het_datos, weights = 1/renta)
```

Weighted Residuals:

Min	1Q	Median	3Q	Max
-6.4405	-1.1894	0.0547	1.3568	4.7847

Coefficients:

	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	34.45170	55.08024	0.625	0.537
renta	0.64357	0.03354	19.185	<2e-16 ***

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 2.607 on 28 degrees of freedom

Multiple R-squared: 0.9293, Adjusted R-squared: 0.9268

F-statistic: 368.1 on 1 and 28 DF, p-value: < 2.2e-16

Para comprobar si los pesos fueron bien elegidos, repetimos el test de heterocedasticidad sobre el ajuste MCP:

```
bptest(mcp)
```

studentized Breusch-Pagan test

data: mcp

BP = 0.0056423, df = 1, p-value = 0.9401

Si el test BP ya no rechaza (p -valor grande), la estructura de varianzas supuesta era aproximadamente correcta y MCP ha cumplido su función.

7.5.6. Paso 5. Errores estándar robustos (HC1)

La solución más segura — válida incluso cuando no se tiene idea de la forma de $h(\mathbf{x})$ — consiste en mantener las estimaciones MCO y recalcular los errores estándar con `vcovHC()`:

```
coeftest(modelo1, vcov = vcovHC(modelo1, type = "HC1"))
```

7. Heterocedasticidad

t test of coefficients:

```
              Estimate Std. Error t value Pr(>|t|)
(Intercept) 13.948477  49.970518  0.2791  0.7822
renta        0.655317   0.035729 18.3411 <2e-16 ***
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

Las estimaciones puntuales son idénticas a las de `summary(modelo1)`. Solo cambian los errores estándar, los estadísticos t y los p -valores.

7.5.7. Paso 6. Tabla comparativa: errores MCO frente a robustos

Una forma limpia de comunicar el resultado es poner los dos errores estándar lado a lado y reportar su cociente.

```
ee_ols    <- summary(modelo1)$coefficients[, "Std. Error"]
ee_robust <- sqrt(diag(vcovHC(modelo1, type = "HC1")))

comparacion <- data.frame(
  EE_MCO    = round(ee_ols, 4),
  EE_Robust = round(ee_robust, 4),
  Ratio     = round(ee_robust / ee_ols, 3)
)
comparacion
```

```
              EE_MCO EE_Robust Ratio
(Intercept) 70.7772  49.9705 0.706
renta        0.0386   0.0357 0.925
```

Si el cociente de la última columna es claramente mayor que 1, los errores estándar MCO estaban infraestimando la incertidumbre — exactamente el diagnóstico que dimos en el §7.2.

Leer la tabla comparativa

La finalidad de esta tabla no es «elegir» una columna sobre la otra — los coeficientes son los mismos en ambas. La tabla indica *cuánto* ha distorsionado la heterocedasticidad al error estándar MCO. Un cociente próximo a 1,0 significa que MCO estaba bien aun cuando RLM.5 técnicamente fallara; un cociente por encima de 1,5 significa que MCO habría llevado a sobre-rechazar la nula. En cualquiera de los dos casos, los errores robustos son ahora la columna estándar a reportar.

Auto-evaluación

Seis preguntas cortas de opción múltiple. Intenta cada una antes de abrir la respuesta.

💡 P1. Definición

La heterocedasticidad en un modelo de regresión lineal significa:

- A. $\mathbb{E}[u | x] \neq 0$.
- B. $\text{Var}(u | x)$ depende de x — no es constante.
- C. El error u está correlacionado entre observaciones.
- D. x es colineal con otro regresor.

Respuesta: B. La heterocedasticidad es, por definición, el fallo de RLM.5: la varianza condicional de u varía con los regresores. Las otras opciones describen RLM.4, autocorrelación y multicolinealidad respectivamente.

💡 P2. Consecuencias

Bajo heterocedasticidad (manteniéndose RLM.1–RLM.4), MCO es:

- A. Sesgado en muestras finitas.
- B. Inconsistente.
- C. Sigue siendo insesgado y consistente, pero ya no es ELIO, y los errores estándar habituales son incorrectos.
- D. Sigue siendo ELIO.

Respuesta: C. La insesgadez y la consistencia de $\hat{\beta}_j$ no requieren RLM.5. Sí la requieren la eficiencia (ELIO) y la validez de la fórmula de manual del error estándar.

💡 P3. Identificación frente a inferencia

¿Por qué decimos que la heterocedasticidad es un problema de *inferencia* y no de *identificación*?

- A. Porque la heterocedasticidad sesga $\hat{\beta}_j$ pero deja intactos los errores estándar.
- B. Porque $\hat{\beta}_j$ deja de ser consistente para la pendiente poblacional.
- C. Porque, si RLM.4 sigue manteniéndose, $\hat{\beta}_j$ continúa estimando el efecto *ceteris paribus*; solo los errores estándar son incorrectos.
- D. Porque la heterocedasticidad es lo mismo que el sesgo por omisión de variables.

Respuesta: C. La interpretación causal de $\hat{\beta}_j$ sobrevive a la heterocedasticidad. Lo que falla es la maquinaria que convierte la estimación en un contraste t o un intervalo de confianza.

💡 P4. Breusch–Pagan

El test de Breusch–Pagan corre una regresión auxiliar de:

- A. $\hat{u}$ sobre los regresores y usa el estadístico F resultante.
- B. $\hat{u}^2$ sobre los regresores y usa $n \cdot R^2$ como un estadístico χ^2 .
- C. y sobre $\hat{u}^2$ y usa un estadístico t .
- D. x sobre $\hat{u}$ y usa la pendiente como estadístico de contraste.

Respuesta: B. El test BP regresa los residuos al cuadrado sobre los regresores; bajo

7. Heterocedasticidad

H_0 de homocedasticidad, nR_{aux}^2 es asintóticamente χ_k^2 .

💡 P5. Goldfeld–Quandt

El test de Goldfeld–Quandt compara:

- A. Las dos pendientes estimadas.
- B. Las varianzas residuales de dos submuestras (típicamente valores bajos frente a valores altos de un regresor).
- C. Los R^2 de dos modelos.
- D. Dos constantes.

Respuesta: B. GQ parte la muestra según la variable sospechosa, ajusta la regresión en cada mitad y usa el cociente de las medias de los cuadrados de los residuos como estadístico F .

💡 P6. MCP frente a errores robustos

¿Cuándo conviene preferir Mínimos Cuadrados Ponderados a MCO con errores estándar robustos?

- A. Cuando la forma de $\text{Var}(u \mid \mathbf{x})$ es conocida y se desea ganar eficiencia.
- B. Cada vez que el test de Breusch–Pagan rechaza, independientemente de lo que se sepa.
- C. Cuando la muestra es pequeña y no se pueden calcular errores robustos.
- D. Nunca — los errores robustos siempre dominan a MCP.

Respuesta: A. MCP solo es ELIO bajo pesos correctamente especificados. Con una estructura de varianzas desconocida, MCO más errores robustos es la opción por defecto más segura; con un modelo creíble para $h(\mathbf{x})$, MCP compra eficiencia.

Ejercicios

Ejercicio 7.1 — Detectar heterocedasticidad. Para cada una de las siguientes regresiones, predice si el término de error será probablemente heterocedástico y explica el motivo en una frase.

- Gasto anual en alimentación regresado sobre la renta del hogar en una muestra de 4.000 hogares.
- Número de hijos regresado sobre la edad de la madre, en una muestra restringida a mujeres de 30–35 años.
- Gasto en I+D a nivel de empresa regresado sobre las ventas de la empresa, en una muestra que mezcla pequeñas *startups* y empresas del Fortune 500.
- Un modelo lineal de probabilidad donde la variable dependiente es un indicador 0/1 de estar empleado.

💡 Ver respuesta

- (a) Sí — los hogares más ricos tienen más gasto discrecional y por tanto una variación absoluta más amplia en el gasto en alimentación. (b) Probablemente no de forma marcada — la muestra es estrecha en edad, así que los efectos de escala son pequeños. (c) Sí, intensamente — el tamaño de las empresas abarca varios órdenes de magnitud. (d) Sí, por construcción — $\text{Var}(y \mid \mathbf{x}) = p(\mathbf{x})[1 - p(\mathbf{x})]$ depende de $\mathbf{x}$ siempre que $p(\mathbf{x})$ dependa de $\mathbf{x}$.

Ejercicio 7.2 — Leer una salida BP. Un estudiante ejecuta `bptest(lm(consumo ~ renta, data = het_datos))` y obtiene un estadístico de aproximadamente 9,8 con 1 grado de libertad y p -valor $\approx 0,002$.

- (a) Plantea la hipótesis nula y la alternativa del contraste. (b) ¿Cuál es la conclusión al nivel del 5 %? (c) ¿Debería el estudiante (i) mantener los errores estándar MCO, (ii) pasar a errores estándar robustos, o (iii) re-estimar por MCP? Justifica brevemente.

💡 Ver respuesta

- (a) H_0 : homocedasticidad ($\gamma_1 = 0$ en la regresión auxiliar de $\hat{u}^2$ sobre la renta); H_1 : $\text{Var}(u \mid \text{renta})$ depende de la renta. (b) Se rechaza H_0 al nivel del 5 %: el p -valor está muy por debajo de 0,05. (c) Como mínimo, pasar a errores estándar robustos (opción ii). MCP (opción iii) es viable *si* el estudiante confía en que la varianza sea proporcional a la renta; en otro caso, la vía robusta es más segura.

Ejercicio 7.3 — Goldfeld–Quandt a mano. Supón que para una regresión de consumo sobre renta obtienes $\text{SCR}_{\text{bajo}} = 120$ con $\text{gl}_{\text{bajo}} = 28$ observaciones en la submuestra de renta baja, y $\text{SCR}_{\text{alto}} = 540$ con $\text{gl}_{\text{alto}} = 28$ en la submuestra de renta alta. El valor crítico al 5 % de $F_{28,28}$ es aproximadamente 1,88.

- (a) Calcula el estadístico F de Goldfeld–Quandt. (b) Enuncia tu conclusión al nivel del 5 %. (c) ¿Qué historia económica explicaría un resultado de este tipo?

La respuesta completa se ofrece en la Edición del Instructor.

Ejercicio 7.4 — Por qué el sándwich. Demuestra que bajo homocedasticidad ($\Omega = \sigma^2 \mathbf{I}_n$), la varianza sándwich

$$(\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}'\Omega\mathbf{X}(\mathbf{X}'\mathbf{X})^{-1}$$

se reduce a la varianza MCO habitual $\sigma^2(\mathbf{X}'\mathbf{X})^{-1}$. Usa este resultado para argumentar, en un párrafo, que el error estándar robusto *nunca es peor asintóticamente* que el error estándar MCO.

La respuesta completa se ofrece en la Edición del Instructor.

Ejercicio 7.5 — MCP como MCO transformado. Considera el modelo de regresión simple $y_i = \beta_0 + \beta_1 x_i + u_i$ con $\text{Var}(u_i \mid x_i) = \sigma^2 x_i$ (siendo $x_i > 0$).

- (a) Escribe el modelo transformado tras dividir por $\sqrt{x_i}$. (b) Demuestra que el error del modelo transformado tiene varianza constante igual a σ^2 .

7. Heterocedasticidad

- (c) Concluye que MCO sobre el modelo transformado es ELIO para (β_0, β_1) , y escribe el criterio MCP equivalente en términos de pesos w_i .

La respuesta completa se ofrece en la Edición del Instructor.

Ejercicio 7.6 — **Extensión de la práctica.** Usando `het_datos.xlsx` de la Práctica 8:

- (a) Reproduce la tabla comparativa de errores estándar MCO y errores robustos HC1. Reporta el cociente para el coeficiente pendiente sobre **renta**.
- (b) Re-estima el modelo por MCP con pesos $w_i = 1/\text{renta}_i^2$ (varianza proporcional a renta_i^2 en lugar de a renta_i). Aplica el test BP al ajuste MCP resultante. ¿Funciona este segundo esquema de ponderación mejor que el esquema $w_i = 1/\text{renta}_i$ del §7.5?
- (c) Supón que el test BP sigue rechazando tras aplicar MCP. ¿En cuál de las dos soluciones — MCP o errores robustos — conviene confiar más, y por qué?

La respuesta completa se ofrece en la Edición del Instructor.

Autocorrelación

Objetivos

Al finalizar este capítulo el lector debería ser capaz de:

- Explicar por qué la **autocorrelación** (o **correlación serial**) es el análogo en series temporales de la heterocedasticidad, y articular qué efecto tiene —y cuál *no* tiene— sobre el insesgamiento, la eficiencia y los errores estándar del estimador MCO.
- Escribir el modelo AR(1) para los errores, $u_t = \rho u_{t-1} + \varepsilon_t$, enunciar la condición de estacionariedad $|\rho| < 1$ y derivar la media, la varianza y las autocovarianzas estacionarias.
- Detectar autocorrelación de primer orden de manera visual (gráfico temporal de residuos, gráfico de retardos $\hat{u}_t$ frente a $\hat{u}_{t-1}$) y formal (contraste de **Durbin-Watson**), utilizando las cotas d_L y d_U de las tablas y reconociendo las regiones de indeterminación.
- Reconocer las situaciones en las que el test de Durbin-Watson **no es válido** (presencia de retardos de la variable dependiente entre los regresores) y aplicar el **h-test de Durbin** como alternativa.
- Aplicar el procedimiento iterativo de **Cochrane-Orcutt** para obtener estimaciones eficientes por MCG factibles bajo errores AR(1), y comprender el papel de la modificación de **Prais-Winsten** para la primera observación.
- Implementar el flujo de trabajo completo en R con `lmtest::dwtest()` y `orcutt::cochrane.orcutt()`, contrastando los resultados de MCO con los corregidos sobre una regresión trimestral simulada de ventas frente a publicidad.

Pregunta motivadora

¿Por qué las regresiones trimestrales de ventas sobre publicidad casi siempre producen estadísticos t demasiado optimistas?

Imaginemos a un analista de marketing que regresa las ventas trimestrales sobre el gasto en publicidad y una tendencia temporal, obtiene un estadístico t de 7,4 sobre el coeficiente de publicidad y reporta con orgullo un efecto “altamente significativo”. El consejo de administración aprueba un aumento del presupuesto del 30 % y, al año siguiente, las ventas decepcionan. ¿Qué ha fallado? Muy a menudo, la respuesta es **autocorrelación**: los errores en el trimestre t están correlacionados con los errores en $t - 1$, los errores estándar de MCO son demasiado pequeños y el estadístico t está inflado. Este capítulo trata precisamente de cómo diagnosticar y corregir ese problema.

8.1. Contexto: del corte transversal a la serie temporal

EN los capítulos 1-7 cada observación era un **individuo** (un trabajador, una empresa, un hogar, una provincia) muestreado en un único momento del tiempo. Indexábamos las observaciones por $i = 1, \dots, n$. Las series temporales son distintas: hay una sola unidad —un país, una empresa, un mercado— observada repetidamente a lo largo de períodos discretos. Sustituimos el índice i por $t = 1, \dots, n$ y el modelo poblacional se convierte en

$$y_t = \beta_0 + \beta_1 x_{1t} + \beta_2 x_{2t} + \dots + \beta_k x_{kt} + u_t.$$

En forma matricial, $\mathbf{Y} = \mathbf{X}\beta + \mathbf{u}$, exactamente como antes —solo cambia el índice—. Un ejemplo típico es una serie mensual de datos de una empresa:

Mes	Ventas y_t	Publicidad x_t
Ene 2020	120	15
Feb 2020	135	18
Mar 2020	128	10
$\vdots$	$\vdots$	$\vdots$
Nov 2020	175	24
Dic 2020	190	30

Desde el punto de vista mecánico, casi todo lo aprendido en los capítulos 2-6 se traslada sin cambios: MCO sigue resolviendo $\min_{\beta} \sum_t (y_t - \mathbf{x}'_t \beta)^2$; la interpretación por partialling-out es la misma; los regresores no lineales y cualitativos se comportan igual. Lo que cambia es la **estructura del error**. Dos errores u_t y u_s se refieren a la *misma* unidad económica observada en *momentos distintos*, y en general no hay razón para que sean incorrelados.

i Recordatorio del supuesto RLM.2 (muestra aleatoria) en contexto temporal

El supuesto RLM.2 en datos de corte transversal exigía que la muestra constara de n extracciones *independientes*: para todo par $i \neq j$, $\mathbb{E}[u_i u_j] = 0$. El mecanismo que garantizaba RLM.2 era el muestreo aleatorio de una población fija: conocer u_i no aportaba información sobre u_j .

En una serie temporal no hay muestreo aleatorio entre unidades. Los errores sucesivos u_t y u_{t+1} son generados por el *mismo* proceso que se despliega en el tiempo, y lo natural es que estén relacionados. Cuando $\mathbb{E}[u_t u_s] \neq 0$ para algún $t \neq s$ decimos que los errores están **autocorrelacionados** (o presentan **correlación serial**). ¿Influirá el shock no observado de demanda de enero sobre febrero? Casi con seguridad, sí —y esa es la definición operativa de autocorrelación.

El contraste con el capítulo 7 es útil. La **heterocedasticidad** es una patología transversal en la que $\text{Var}(u_i)$ depende de los regresores, pero los errores entre unidades son independientes. La **autocorrelación** es su prima temporal: los elementos *fuera de la diagonal* de la matriz de varianzas-covarianzas del error son no nulos, mientras que la diagonal puede o no permanecer constante. Ambas dejan a MCO insesgado, pero invalidan sus errores estándar.

8.2. Definición, estructura AR(1) y consecuencias

8.2.1. Definición

i Definición (autocorrelación)

Diremos que las perturbaciones u_t presentan **autocorrelación** (o **correlación serial**) cuando

$$\text{Cov}(u_t, u_s) \neq 0 \quad \text{para algún } t \neq s.$$

La matriz de varianzas-covarianzas del vector $\mathbf{u} = (u_1, \dots, u_n)'$ es entonces

$$\text{Var}(\mathbf{u}) = \begin{pmatrix} \sigma^2 & \gamma_1 & \gamma_2 & \cdots & \gamma_{n-1} \\ \gamma_1 & \sigma^2 & \gamma_1 & \cdots & \gamma_{n-2} \\ \gamma_2 & \gamma_1 & \sigma^2 & \cdots & \gamma_{n-3} \\ \vdots & \vdots & \vdots & \ddots & \vdots \\ \gamma_{n-1} & \gamma_{n-2} & \gamma_{n-3} & \cdots & \sigma^2 \end{pmatrix},$$

con al menos un elemento fuera de la diagonal $\gamma_k = \text{Cov}(u_t, u_{t-k}) \neq 0$.

Bajo los supuestos clásicos del modelo de regresión lineal con datos transversales, los elementos fuera de la diagonal son todos nulos y $\text{Var}(\mathbf{u}) = \sigma^2 \mathbf{I}_n$. La autocorrelación rompe esa simplificación.

8.2.2. El modelo AR(1): el caballo de batalla

A lo largo de todo el capítulo —y de la inmensa mayoría del trabajo aplicado de grado— utilizaremos un modelo concreto para la dependencia serial: el proceso **autorregresivo de primer orden** o **AR(1)**:

$$u_t = \rho u_{t-1} + \varepsilon_t, \quad |\rho| < 1,$$

donde ε_t es un **ruido blanco**: $\mathbb{E}[\varepsilon_t] = 0$, $\text{Var}(\varepsilon_t) = \sigma_\varepsilon^2$ constante, $\text{Cov}(\varepsilon_t, \varepsilon_s) = 0$ para $t \neq s$ y (habitualmente) $\varepsilon_t \sim \mathcal{N}(0, \sigma_\varepsilon^2)$. La condición $|\rho| < 1$ garantiza la **estacionariedad** del proceso, es decir, que su media, varianza y autocovarianzas no dependan del tiempo.

Un único parámetro ρ resume toda la estructura de dependencia. Bajo estacionariedad puede demostrarse:

$$\mathbb{E}[u_t] = 0, \quad \text{Var}(u_t) = \frac{\sigma_\varepsilon^2}{1 - \rho^2}, \quad \text{Cov}(u_t, u_{t-k}) = \rho^k \cdot \frac{\sigma_\varepsilon^2}{1 - \rho^2}.$$

De modo que $\gamma_k = \rho^k \sigma^2$ con $\sigma^2 = \sigma_\varepsilon^2 / (1 - \rho^2)$: las autocovarianzas **decaen geométricamente** en el retardo k . El signo de ρ clasifica el patrón:

- $\rho > 0$ (**autocorrelación positiva**). Los errores del mismo signo se agrupan. Un shock positivo persiste, y se atenúa suavemente: largas rachas de residuos positivos, seguidas de largas rachas de residuos negativos. Es con diferencia el caso más frecuente en datos macroeconómicos y empresariales.

8. Autocorrelación

- $\rho < 0$ (**autocorrelación negativa**). Los errores alternan en signo: cada shock positivo es seguido, con probabilidad desproporcionada, por uno negativo. Menos habitual, pero aparece en series de inventarios y en modelos donde el ajuste sobre-reacciona.
- $\rho = 0$ (**sin autocorrelación**). $u_t = \varepsilon_t$ y los errores son ruido blanco: se recupera el caso transversal por defecto.

Los procesos de orden superior (AR(2), AR(p), ARMA, ...) existen y se estudian en Econometría II; para nuestros propósitos el AR(1) basta para fijar las ideas y motivar los diagnósticos y correcciones que siguen.

8.2.3. Consecuencias para MCO

¿Qué efecto tiene la autocorrelación sobre el estimador MCO $\hat{\beta}$?

1. **MCO sigue siendo insesgado y consistente** —siempre que la esperanza condicional esté correctamente especificada, esto es, $\mathbb{E}[u_t | \mathbf{x}_t] = 0$ —. La autocorrelación afecta a los elementos *fuera de la diagonal* de $\text{Var}(\mathbf{u})$ y no desplaza la media del estimador respecto a β . Las estimaciones puntuales no son el problema.
2. **MCO ya no es ELIO (BLUE)**. Pierde la propiedad de óptimalidad: ya no es el estimador lineal e insesgado de mínima varianza. Existe un estimador alternativo, el de **Mínimos Cuadrados Generalizados (MCG)**, que sí lo es (§8.4).
3. **Los errores estándar habituales de MCO son incorrectos**. La fórmula de manual $\text{Var}(\hat{\beta}) = \sigma^2(\mathbf{X}'\mathbf{X})^{-1}$ presupone $\text{Var}(\mathbf{u}) = \sigma^2\mathbf{I}_n$, supuesto que falla. Bajo autocorrelación **positiva**, los errores estándar reportados por MCO típicamente *infravaloran* la variabilidad muestral verdadera: los estadísticos t resultan demasiado grandes, los p -valores demasiado pequeños y los intervalos de confianza demasiado estrechos. Los “estadísticos t optimistas” de la pregunta motivadora son exactamente este artefacto.

⚠ Causalidad frente a eficiencia: la trampa del retardo de la variable dependiente

Existe un caso en el que la autocorrelación va más allá de inflar los t : destruye la identificación. Si la regresión incluye un **retardo de la variable dependiente** y_{t-1} y los errores son AR(1),

$$y_t = \alpha y_{t-1} + \beta_0 + \beta_1 x_t + u_t, \quad u_t = \rho u_{t-1} + \varepsilon_t,$$

entonces y_{t-1} depende de u_{t-1} , y u_{t-1} está correlacionado con u_t a través de ρ . El regresor queda correlacionado con el error, $\mathbb{E}[u_t | y_{t-1}] \neq 0$, y MCO ya no es solo ineficiente: se vuelve **sesgado e inconsistente**. El coeficiente causal β_1 deja de estar identificado. Es el primo temporal del sesgo de variable omitida del capítulo 3.

La intuición de por qué la autocorrelación positiva hace que los errores estándar de MCO sean demasiado pequeños merece reflexión: si los errores sucesivos contienen información sobre los siguientes, n observaciones correlacionadas aportan *menos información independiente* que n observaciones incorreladas. El **tamaño muestral efectivo** es menor que el nominal n , pero la fórmula de MCO trata cada observación como si fuese una extracción fresca. La precisión reportada está, por tanto, exagerada.

8.3. Detección

Disponemos de dos cajas de herramientas complementarias: **gráfica** (rápida e intuitiva) y **analítica** (contrastes formales). El flujo de trabajo recomendado es mirar primero y contrastar después.

8.3.1. Métodos gráficos

Gráfico temporal de los residuos. Representamos $\hat{u}_t$ frente a t . Si los errores están incorrelados, los residuos deberían dispersarse aleatoriamente alrededor de cero —sin patrón visible, sin agrupamientos, sin ciclos manifiestos—. Si observamos **rachas largas** de residuos del mismo signo (muchos positivos consecutivos, luego muchos negativos), esa es la firma visual de $\rho > 0$. Si los residuos alternan en un patrón de diente de sierra, indica $\rho < 0$.

Gráfico de retardos. Representamos $\hat{u}_t$ en el eje vertical frente a $\hat{u}_{t-1}$ en el horizontal. Bajo $\rho = 0$ la nube no tiene pendiente; bajo $\rho > 0$ se inclina hacia arriba a la derecha (asociación lineal positiva); bajo $\rho < 0$ se inclina hacia abajo. Mecánicamente, esta es la imagen de la regresión MCO $\hat{u}_t = \rho \hat{u}_{t-1} + (\text{ruido})$, cuya pendiente es exactamente el estimador de ρ que utilizaremos a continuación.

Las tres formas de referencia son: una nube sin estructura ($\rho \approx 0$), una recta de pendiente positiva ($\rho > 0$) y una recta de pendiente negativa ($\rho < 0$). En la práctica del §8.5 veremos las tres.

8.3.2. El contraste de Durbin-Watson

El estadístico de **Durbin-Watson (DW)** es el contraste formal por excelencia para la autocorrelación de primer orden.

i Definición (estadístico de Durbin-Watson)

$$DW = \frac{\sum_{t=2}^n (\hat{u}_t - \hat{u}_{t-1})^2}{\sum_{t=1}^n \hat{u}_t^2}.$$

El contraste es de $H_0 : \rho = 0$ (incorrelación) frente a $H_1 : \rho \neq 0$ (autocorrelación), o bien frente a una alternativa unilateral.

Por qué $DW \approx 2(1 - \hat{\rho})$. Desarrollamos el cuadrado del numerador:

$$\sum_{t=2}^n (\hat{u}_t - \hat{u}_{t-1})^2 = \sum_{t=2}^n \hat{u}_t^2 - 2 \sum_{t=2}^n \hat{u}_t \hat{u}_{t-1} + \sum_{t=2}^n \hat{u}_{t-1}^2.$$

Si la muestra es suficientemente grande, $\sum_{t=2}^n \hat{u}_t^2 \simeq \sum_{t=2}^n \hat{u}_{t-1}^2 \simeq \sum_{t=1}^n \hat{u}_t^2$ (las tres sumas difieren a lo sumo en una observación). Dividiendo:

$$DW \approx \frac{2 \sum_{t=2}^n \hat{u}_t^2 - 2 \sum_{t=2}^n \hat{u}_t \hat{u}_{t-1}}{\sum_{t=1}^n \hat{u}_t^2} = 2 \left(1 - \frac{\sum_{t=2}^n \hat{u}_t \hat{u}_{t-1}}{\sum_{t=1}^n \hat{u}_t^2} \right) = 2(1 - \hat{\rho}),$$

donde $\hat{\rho} = \sum_{t=2}^n \hat{u}_t \hat{u}_{t-1} / \sum_{t=1}^n \hat{u}_t^2$ es la autocorrelación muestral de primer orden de los residuos. Puesto que $\rho \in [-1, 1]$, el estadístico vive en el intervalo $[0, 4]$:

8. Autocorrelación

- $DW \simeq 0 \Leftrightarrow \hat{\rho} \simeq +1$ (autocorrelación positiva fuerte).
- $DW \simeq 2 \Leftrightarrow \hat{\rho} \simeq 0$ (incorrelación).
- $DW \simeq 4 \Leftrightarrow \hat{\rho} \simeq -1$ (autocorrelación negativa fuerte).

Cotas y regla de decisión. La distribución exacta de DW depende de la matriz de diseño $\mathbf{X}$, de modo que Durbin y Watson tabularon una **cota inferior** d_L y una **cota superior** d_U (funciones de n , del número de regresores k y del nivel de significación). La regla de decisión, para el contraste con alternativa unilateral $H_1 : \rho > 0$, es:

Región	Conclusión
$0 < DW < d_L$	Se rechaza H_0 : autocorrelación positiva .
$d_L < DW < d_U$	Zona de indeterminación.
$d_U < DW < 4 - d_U$	No se rechaza H_0 : incorrelación.
$4 - d_U < DW < 4 - d_L$	Zona de indeterminación.
$4 - d_L < DW < 4$	Se rechaza H_0 : autocorrelación negativa .

Las dos zonas de indeterminación son inevitables: son el precio que se paga por no tener que asumir una matriz de diseño concreta. En software moderno (`lmtest::dwtest()` en R, por ejemplo), el contraste devuelve un p -valor exacto calculado para la $\mathbf{X}$ observada, evitando el manejo de tablas. Las cotas se utilizan en ejercicios a mano; el p -valor, en el laboratorio.

Ejemplo resuelto: cálculo manual de DW (accidentes y coches)

Una ciudad registra durante 10 años el número de pequeños accidentes Y_t y el número de coches matriculados X_t :

Y	25	27	28	32	33	36	38	40	41	45
X	510	520	528	540	590	650	700	760	800	870

La estimación MCO del modelo $Y_t = \beta_1 + \beta_2 X_t + u_t$ es

$$\hat{Y}_t = 2,5676 + 0,04937 X_t, \quad R^2 = 0,942.$$

Construimos la tabla de residuos y sus diferencias:

Y	$\hat{Y}$	$\hat{u}_t$	$\hat{u}_{t-1}$	$(\hat{u}_t - \hat{u}_{t-1})^2$	$\hat{u}_t^2$
25	27{,}7462	-2,7462	—	—	7{,}5416
27	28{,}2399	-1,2399	-2,7462	2{,}2689	1{,}5374
28	28{,}6349	-0,6349	-1,2399	0{,}3661	0{,}4030
32	29{,}2273	2,7727	-0,6349	11{,}6115	7{,}6879
33	31{,}6958	1,3042	2,7727	2{,}1565	1{,}7010
36	34{,}6580	1,3420	1,3042	0{,}0014	1{,}8010
38	37{,}1265	0,8735	1,3420	0{,}2195	0{,}7630
40	40{,}0887	-0,0887	0,8735	0{,}9258	0{,}0079
41	42{,}0635	-1,0635	-0,0887	0{,}9502	1{,}1310
45	45{,}5194	-0,5194	-1,0635	0{,}2961	0{,}2697
				18{,}7960	22{,}8435

El estadístico vale

$$DW = \frac{18,7960}{22,8435} \approx 0,823.$$

Para $n = 10$ y $k = 1$, las cotas al 5% son $d_L = 0,879$ y $d_U = 1,320$. Como $DW < d_L$, **se rechaza** H_0 y se concluye que existe autocorrelación positiva. Usaremos este mismo ejemplo en §8.4 para ilustrar Cochrane-Orcutt.

8.3.3. Cuando DW falla: el h-test de Durbin

El contraste de DW descansa sobre dos hipótesis que a menudo quedan implícitas: el proceso del error es AR(1) y la regresión **no** incluye un retardo de la variable dependiente. El caso del retardo —discutido en el recuadro de advertencia del §8.2.3— es precisamente aquel en el que MCO se vuelve inconsistente, y en el que DW pasa a estar fuertemente sesgado hacia 2 (hacia la hipótesis nula de no autocorrelación), que es el peor comportamiento posible para un contraste diagnóstico.

Para modelos de la forma

$$y_t = \alpha y_{t-1} + \beta_0 + \beta_1 x_{1t} + \cdots + \beta_k x_{kt} + u_t, \quad u_t = \rho u_{t-1} + \varepsilon_t,$$

Durbin propuso el **estadístico** h :

$$h = \hat{\rho} \sqrt{\frac{n}{1 - n \widehat{\text{Var}}(\hat{\alpha})}} \sim \mathcal{N}(0, 1) \quad \text{bajo } H_0 : \rho = 0,$$

donde $\hat{\alpha}$ es el coeficiente MCO sobre y_{t-1} y $\widehat{\text{Var}}(\hat{\alpha})$ es la varianza MCO habitual (la “incorrecta”). Suele utilizarse $\hat{\rho} \approx 1 - DW/2$. Se rechaza H_0 al nivel α si $|h| > z_{1-\alpha/2}$.

 Ejemplo resuelto: h-test de Durbin

Sea la estimación MCO con $n = 21$ observaciones:

$$\widehat{Y}_t = 1,3 + 0,97 Y_{t-1} + 2,31 X_t, \quad \text{se}(\hat{\alpha}) = 0,07, \quad DW = 1,21.$$

Entonces $\hat{\rho} \approx 1 - 1,21/2 = 0,395$, $\widehat{\text{Var}}(\hat{\alpha}) = 0,07^2 = 0,0049$ y

$$h = 0,395 \cdot \sqrt{\frac{21}{1 - 21 \cdot 0,0049}} = 0,395 \cdot 4,838 \approx 1,91.$$

Al 5 % el valor crítico es $z_{0,975} = 1,96$. Como $|h| = 1,91 < 1,96$, **no se rechaza** H_0 : no hay evidencia estadística de autocorrelación de primer orden. Una lectura ingenua del DW de 1,21 podría haber sugerido lo contrario, pero DW está sesgado en este modelo.

Existen otros contrastes —la prueba LM de **Breusch-Godfrey**, válida para órdenes superiores; la prueba portmanteau de **Ljung-Box**— que se cubren en Econometría II. Para esta asignatura, DW (o el h de Durbin cuando proceda) es la herramienta estándar.

8.4. Corrección: de MCG a Cochrane-Orcutt

Si MCO es ineficiente bajo $\text{AR}(1)$, ¿qué debemos hacer? La respuesta es **Mínimos Cuadrados Generalizados (MCG)**: transformar el modelo de modo que los errores transformados sean ruido blanco, y entonces aplicar MCO al modelo transformado.

8.4.1. La cuasi-diferenciación de MCG

Partimos del modelo y de su retardo multiplicado por ρ :

$$y_t = \beta_0 + \beta_1 x_t + u_t, \quad \rho y_{t-1} = \rho \beta_0 + \rho \beta_1 x_{t-1} + \rho u_{t-1}.$$

Restando la segunda ecuación de la primera:

$$y_t - \rho y_{t-1} = \beta_0(1 - \rho) + \beta_1(x_t - \rho x_{t-1}) + (u_t - \rho u_{t-1}).$$

Por el supuesto $\text{AR}(1)$, $u_t - \rho u_{t-1} = \varepsilon_t$, que es ruido blanco. Definimos las variables **cuasi-diferenciadas**:

$$y_t^* = y_t - \rho y_{t-1}, \quad x_t^* = x_t - \rho x_{t-1}, \quad \beta_0^* = \beta_0(1 - \rho).$$

La regresión transformada

$$y_t^* = \beta_0^* + \beta_1 x_t^* + \varepsilon_t$$

tiene errores homocedásticos e incorrelados —se recuperan los supuestos clásicos del modelo de regresión—, y MCO sobre el modelo transformado es el **estimador MCG**, que es óptimo (BLUE).

La primera observación. La transformación tal como está escrita pierde la observación $t = 1$. Para conservarla, la **modificación de Prais-Winsten** la reescala de modo distinto:

$$y_1^* = \sqrt{1 - \rho^2} y_1, \quad x_1^* = \sqrt{1 - \rho^2} x_1, \quad \text{cte}_1^* = \sqrt{1 - \rho^2}.$$

El factor $\sqrt{1 - \rho^2}$ es justamente el que hace que $\text{Var}(u_1^*) = \sigma_\varepsilon^2$, igualándola al resto. En muestras pequeñas esto importa; en muestras grandes, descartar la observación 1 (“Cochrane-Orcutt en dos etapas”) es prácticamente equivalente.

En forma matricial, la transformación MCG se escribe de forma compacta como

$$\mathbf{Y}^* = \begin{pmatrix} \sqrt{1 - \rho^2} y_1 \\ y_2 - \rho y_1 \\ \vdots \\ y_n - \rho y_{n-1} \end{pmatrix}, \quad \mathbf{X}^* = \begin{pmatrix} \sqrt{1 - \rho^2} & \sqrt{1 - \rho^2} x_{21} & \cdots & \sqrt{1 - \rho^2} x_{k1} \\ 1 - \rho & x_{22} - \rho x_{21} & \cdots & x_{k2} - \rho x_{k1} \\ \vdots & \vdots & \ddots & \vdots \\ 1 - \rho & x_{2n} - \rho x_{2,n-1} & \cdots & x_{kn} - \rho x_{k,n-1} \end{pmatrix}.$$

Aplicando MCO a $(\mathbf{Y}^*, \mathbf{X}^*)$ se obtiene $\hat{\beta}_{\text{MCG}}$.

8.4.2. El procedimiento iterativo de Cochrane-Orcutt

La pega: ρ es desconocido. Hay que estimarlo. El procedimiento de **Cochrane-Orcutt (CO)** es el algoritmo de MCG factibles más sencillo: alternar entre estimar ρ a partir de los residuos y reestimar β sobre los datos cuasi-diferenciados, hasta que ρ se estabilice.

i Algoritmo: procedimiento iterativo de Cochrane-Orcutt

1. Estimar el modelo original $y_t = \beta_0 + \beta_1 x_t + \cdots + u_t$ por MCO y obtener los residuos $\hat{u}_t$.
2. Estimar ρ regresando $\hat{u}_t$ sobre $\hat{u}_{t-1}$ (sin término constante):

$$\hat{\rho} = \frac{\sum_{t=2}^n \hat{u}_t \hat{u}_{t-1}}{\sum_{t=2}^n \hat{u}_{t-1}^2}.$$

3. Construir las variables cuasi-diferenciadas $y_t^* = y_t - \hat{\rho} y_{t-1}$ y $x_t^* = x_t - \hat{\rho} x_{t-1}$ (y, en la variante Prais-Winsten, la primera observación reescalada por $\sqrt{1 - \hat{\rho}^2}$).
4. Aplicar MCO sobre (y_t^*, x_t^*) para obtener nuevos coeficientes $\hat{\beta}^{(2)}$ y nuevos residuos $\hat{u}_t^{(2)}$.
5. Volver al paso 2 con $\hat{u}_t^{(2)}$ y actualizar $\hat{\rho}$.
6. Iterar hasta que $\hat{\rho}$ converja (la variación entre iteraciones sea despreciable).

El vector final de coeficientes es la estimación MCG factible de Cochrane-Orcutt; los errores estándar reportados son los de MCO en la *regresión transformada*, que son válidos bajo AR(1).

Existen alternativas —el procedimiento CO en dos etapas (una sola iteración), la búsqueda en rejilla de Hildreth-Lu sobre ρ , el método de Durbin en dos etapas, Prais-Winsten con mínimos cuadrados restringidos— pero todas comparten la misma idea de fondo: estimar ρ , cuasi-diferenciar y aplicar MCO para recuperar un estimador eficiente.

 Ejemplo resuelto: Cochrane-Orcutt sobre los datos de accidentes

Retomamos el ejemplo accidentes-vs-coches del §8.3.2. Como $DW = 0,823$ y $n = 10$ es pequeño, aplicamos la variante de Prais-Winsten.

Paso 1 (MCO): $\hat{Y}_t = 2,568 + 0,0494 X_t$.

Paso 2 ($\hat{\rho}$ a partir de los residuos): la regresión $\hat{u}_t = \rho \hat{u}_{t-1} + \varepsilon_t$ da

$$\hat{\rho} = \frac{\sum \hat{u}_t \hat{u}_{t-1}}{\sum \hat{u}_{t-1}^2} = 0,4226.$$

Paso 3 (transformación). Para $t > 1$:

$$Y_t^* = Y_t - 0,4226 Y_{t-1}, \quad X_t^* = X_t - 0,4226 X_{t-1};$$

y para $t = 1$, multiplicamos por $\sqrt{1 - 0,4226^2} \approx 0,9063$. La tabla resultante es:

Y^*	cte*	X^*
22{,}659	0{,}9063	462{,}220
16{,}435	0{,}5774	304{,}471
16{,}590	0{,}5774	308{,}245
20{,}167	0{,}5774	316{,}864
19{,}477	0{,}5774	361{,}793
22{,}054	0{,}5774	400{,}662
22{,}786	0{,}5774	425{,}306
23{,}941	0{,}5774	464{,}176
24{,}096	0{,}5774	478{,}819
27{,}673	0{,}5774	531{,}915

Paso 4 (MCO sobre las variables transformadas): $\hat{Y}_t^* = 2,111 + 0,0498 X_t^*$.

La pendiente apenas se mueve —MCO era insesgado desde el principio—, pero el nuevo DW sobre los residuos transformados es 1,52, holgadamente dentro de la región de no autocorrelación. Los errores estándar del paso 4 son los válidos.

Nota. Como $\hat{\rho}$ es una estimación, en principio deberíamos iterar el procedimiento hasta convergencia. En la práctica, con esta muestra tan pequeña una sola iteración ya elimina el problema.

La moraleja: en el mundo AR(1), MCO entrega las estimaciones *puntuales* correctas (en promedio), pero con una *incertidumbre* equivocada; Cochrane-Orcutt arregla la incertidumbre sin alterar apenas el punto.

8.5. Práctica: Autocorrelación en R

La práctica sigue el flujo del Tutorial 9 (`autocorr_datos.xlsx`): regresamos ventas trimestrales sobre publicidad y una tendencia temporal, diagnosticamos autocorrelación visual y formalmente con Durbin-Watson, y corregimos con Cochrane-Orcutt. Para que el capítulo sea autocontenido y reproducible sin necesidad del fichero `.xlsx` externo, generamos una versión sintética del tutorial con la misma estructura (ventas dependientes de publicidad más una tendencia, errores AR(1) con ρ conocido). El tutorial interactivo `LEARNR/08_autocorrelation.Rmd` utiliza la misma simulación.

```
library(lmtest)
library(orcutt)

set.seed(2026)
n          <- 120                                # ~30 años trimestrales
tiempo     <- 1:n
publicidad <- 5 + 0.5 * tiempo + rnorm(n, 0, 3)    # gasto en publicidad
rho_true   <- 0.7                                # parámetro AR(1)
u          <- numeric(n); u[1] <- rnorm(1, 0, 2)
for (t in 2:n) u[t] <- rho_true * u[t-1] + rnorm(1, 0, 2)
ventas     <- 10 + 0.8 * publicidad + 0.3 * tiempo + u
autocorr_demo <- data.frame(tiempo = tiempo,
                             publicidad = publicidad,
                             ventas = ventas)
head(autocorr_demo)
```

```
      tiempo publicidad  ventas
1          1  7.0617672 19.76182
2          2  2.7609277 19.74102
3          3  6.9177143 21.74968
4          4  6.7457536 22.11135
5          5  5.5000812 16.28280
6          6  0.4517329 13.36700
```

El proceso generador de datos tiene pendiente 0.8 sobre publicidad, coeficiente de tendencia 0.3 y errores AR(1) con $\rho = 0,7$ (autocorrelación positiva fuerte). Un analista real no conocería ninguno de estos valores.

8.5.1. MCO y primer vistazo a los residuos

```
fit <- lm(ventas ~ publicidad + tiempo, data = autocorr_demo)
summary(fit)
```

Call:

```
lm(formula = ventas ~ publicidad + tiempo, data = autocorr_demo)
```

Residuals:

```
      Min       1Q   Median       3Q      Max
-4.9456 -1.6830  0.1018  1.4430  7.2580
```

Coefficients:

```
              Estimate Std. Error t value Pr(>|t|)
(Intercept) 12.03424    0.55212  21.796 < 2e-16 ***
publicidad   0.79301    0.07210  10.999 < 2e-16 ***
tiempo       0.28555    0.03669   7.782 3.13e-12 ***
---

```

```
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

8. Autocorrelación

Residual standard error: 2.399 on 117 degrees of freedom
Multiple R-squared: 0.9902, Adjusted R-squared: 0.99
F-statistic: 5895 on 2 and 117 DF, p-value: < 2.2e-16

El coeficiente sobre `publicidad` está en el orden correcto (alrededor de 0,8), la tendencia también (alrededor de 0,3), y los estadísticos t son espectaculares. ¿Son creíbles? Representemos los residuos a lo largo del tiempo:

```
plot(ts(resid(fit)),  
      ylab = "Residuos",  
      main = "Residuos a lo largo del tiempo")  
abline(h = 0, lty = 2)
```




Figure 8.1.: Residuos MCO frente al tiempo. Las rachas largas de mismo signo son la firma visual de autocorrelación positiva.

Los residuos trazan excursiones largas y suaves por encima y por debajo de cero: la imagen exacta de $\rho > 0$. La comparación con una serie de residuos incorrelados (una nube sin estructura alrededor de cero) hace evidente la diferencia.

8.5.2. Gráfico de retardos


```
e <- resid(fit)
plot(head(e, -1), tail(e, -1),
     xlab = expression(hat(u)[t-1]),
     ylab = expression(hat(u)[t]),
     main = "Residuos vs. residuos retardados",
     pch = 16,
     col = rgb(0, 0, 1, 0.4))
abline(0, 1, lty = 3)
```




Figure 8.2.: Gráfico de retardos de los residuos MCO: $\hat{u}_t$ frente a $\hat{u}_{t-1}$. La inclinación positiva confirma autocorrelación positiva de primer orden.

La pendiente de la nube es la estimación de ρ . Podemos calcularla directamente:

```
e_lag <- c(NA, head(e, -1))
rho_hat <- coef(lm(e ~ e_lag - 1))[1]
rho_hat
```

```
e_lag
0.623818
```

```
2 * (1 - rho_hat) # aproximación al DW
```

8. Autocorrelación

```
e_lag  
0.752364
```

La autocorrelación residual $\hat{\rho}$ debería estar cerca del verdadero 0,7, y $2(1 - \hat{\rho})$ aporta una aproximación rápida al valor que devolverá el contraste de Durbin-Watson.

8.5.3. Durbin-Watson

```
dwtest(fit)
```

Durbin-Watson test

```
data: fit  
DW = 0.75392, p-value = 1.519e-12  
alternative hypothesis: true autocorrelation is greater than 0
```

El estadístico DW queda bien por debajo de 2, el p -valor es minúsculo y rechazamos $H_0 : \rho = 0$ a favor de autocorrelación positiva. Compárese DW con $2(1 - \hat{\rho})$ del chunk anterior: deben coincidir salvo redondeo.

8.5.4. Corrección de Cochrane-Orcutt

```
co <- cochrane.orcutt(fit)  
summary(co)
```

Call:

```
lm(formula = ventas ~ publicidad + tiempo, data = autocorr_demo)
```

	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	11.660805	0.984502	11.844	< 2.2e-16 ***
publicidad	0.808566	0.045719	17.686	< 2.2e-16 ***
tiempo	0.282872	0.026587	10.639	< 2.2e-16 ***

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 1.8894 on 116 degrees of freedom
Multiple R-squared: 0.9618 , Adjusted R-squared: 0.9612
F-statistic: 1462.1 on 2 and 116 DF, p-value: < 5.37e-83

Durbin-Watson statistic

```
(original): 0.75392 , p-value: 1.519e-12  
(transformed): 1.88504 , p-value: 2.5e-01
```

`cochrane.orcutt()` itera el algoritmo del §8.4.2 hasta convergencia y muestra los coeficientes corregidos, la $\hat{\rho}$ iterada y un estadístico DW calculado sobre los residuos transformados.

i Una nota sobre `cochrane.orcutt()` frente a Prais-Winsten

El álgebra del §8.4.1 derivó una transformación de Prais-Winsten que *reescala* la primera observación por $\sqrt{1-\rho^2}$ para conservarla. La función `cochrane.orcutt()` del paquete **orcutt** implementa, en cambio, la variante en dos etapas de Cochrane-Orcutt, que *descarta* la primera observación. Con $n = 120$ como en nuestra muestra, ambas son esencialmente equivalentes; en muestras pequeñas el reescalado sí importa y conviene recurrir a `prais::prais_winsten()` para un ajuste de Prais-Winsten propiamente dicho. Aquí nos quedamos con la variante que descarta la primera observación para mantener la coherencia con la descripción algorítmica del §8.4.1.

Comparamos resultados MCO y CO lado a lado:

```
cat("--- Coeficientes MCO ---\n")
```

```
--- Coeficientes MCO ---
```

```
print(round(coef(fit), 4))
```

```
(Intercept)  publicidad      tiempo
      12.0342      0.7930      0.2855
```

```
cat("\n--- Coeficientes Cochrane-Orcutt ---\n")
```

```
--- Coeficientes Cochrane-Orcutt ---
```

```
print(round(co$coefficients, 4))
```

```
(Intercept)  publicidad      tiempo
      11.6608      0.8086      0.2829
```

```
cat("\nRho estimado:      ", round(co$rho, 4),
    "(rho verdadero = ", rho_true, ")\n")
```

```
Rho estimado:      0.6256 (rho verdadero = 0.7 )
```

```
cat("DW tras la correccion:", round(co$DW[1], 4), "\n")
```

```
DW tras la correccion: 0.7539
```

Hay tres observaciones típicas de esta corrección:

1. Las **estimaciones puntuales** de las pendientes apenas cambian. MCO era insesgado: lo único que iba mal era la incertidumbre.

2. Los **errores estándar** en la salida de CO son mayores que los de MCO. Los t de MCO estaban inflados; los corregidos son más honestos. Hipótesis “altamente significativas” pueden quedar meramente significativas, o incluso dejar de rechazar.
3. El DW sobre los residuos transformados está cerca de 2, indicando que la corrección $AR(1)$ ha cumplido su función. Si el nuevo DW siguiera lejos de 2, los residuos podrían seguir un proceso más rico ($AR(2)$, p. ej.), fuera del alcance del capítulo.

8.5.5. Una Cochrane-Orcutt manual en un paso

Para ver exactamente qué hace `cochrane.orcutt()` por dentro, replicamos el algoritmo manualmente en una sola iteración:

```
y <- autocorr_demo$ventas
x1 <- autocorr_demo$publicidad
x2 <- autocorr_demo$tiempo

# Paso 2: rho a partir de los residuos (ya calculado como rho_hat)
# Paso 3: variables cuasi-diferenciadas
y_q <- y[-1] - rho_hat * y[-n]
x1_q <- x1[-1] - rho_hat * x1[-n]
x2_q <- x2[-1] - rho_hat * x2[-n]

# Paso 4: MCO sobre el modelo transformado
fit_q <- lm(y_q ~ x1_q + x2_q)
summary(fit_q)$coefficients
```

	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	4.3873595	0.36859583	11.90290	7.792453e-22
x1_q	0.8085333	0.04575909	17.66935	1.093286e-34
x2_q	0.2828550	0.02657178	10.64494	7.106661e-19

```
# Recuperar el intercepto en la escala original
beta0_escala_original <- coef(fit_q)["(Intercept)"] / (1 - rho_hat)
beta0_escala_original
```

```
(Intercept)
11.66286
```

```
dwtest(fit_q) # DW debería estar cerca de 2
```

Durbin-Watson test

```
data: fit_q
DW = 1.8817, p-value = 0.2441
alternative hypothesis: true autocorrelation is greater than 0
```

Una sola iteración ya recoge la mayor parte del beneficio. La función `cochrane.orcutt()` completamente iterada pule $\hat{\rho}$ hasta convergencia; en la práctica, unas pocas iteraciones bastan.

⚠ El problema no es el sesgo, es la incertidumbre

El coeficiente MCO sobre **publicidad** era insesgado, incluso con $\rho = 0,7$. El problema era que su error estándar era *demasiado pequeño*. Si hubieras tomado el t de MCO al pie de la letra y construido un intervalo de confianza para una predicción, tu intervalo habría infracubierto la verdad: precisamente la advertencia de la pregunta motivadora.

Auto-evaluación

Siete preguntas cortas de elección múltiple. Intenta responder antes de desplegar la respuesta.

💡 P1. ¿Qué es la autocorrelación?

La autocorrelación (correlación serial) significa que:

- A. $\text{Var}(u_t)$ depende de los regresores x_t .
- B. $\text{Cov}(u_t, u_s) \neq 0$ para algún $t \neq s$ —los errores están correlacionados entre períodos.
- C. x_t está correlacionado con u_t .
- D. $\mathbb{E}[u_t] \neq 0$.

Respuesta: B. La autocorrelación es una propiedad de los elementos *fuera de la diagonal* de la matriz de varianzas-covarianzas del error. (A) es heterocedasticidad, (C) es endogeneidad, (D) es violación de media cero.

💡 P2. Consecuencias para MCO

Bajo errores AR(1) y con $\mathbb{E}[u_t | x_t] = 0$, el estimador MCO es:

- A. Siempre sesgado.
- B. Siempre inconsistente.
- C. Aún insesgado y consistente, pero ya no es ELIO (BLUE), y los errores estándar habituales son incorrectos.
- D. Sigue siendo ELIO.

Respuesta: C. MCO conserva las propiedades puntuales pero pierde eficiencia y los errores estándar habituales no son válidos. (B) es correcta solo en el caso particular de retardo de la variable dependiente.

💡 P3. El proceso AR(1)

En el modelo $u_t = \rho u_{t-1} + \varepsilon_t$ con $|\rho| < 1$ y ε_t ruido blanco, la autocorrelación es:

- A. Positiva cuando $\rho > 0$, negativa cuando $\rho < 0$; las autocovarianzas decaen geométricamente.
- B. Siempre positiva.
- C. Independiente de ρ .
- D. Equivalente a la heterocedasticidad.

Respuesta: A. El signo de ρ fija el patrón y $\text{Cov}(u_t, u_{t-k}) = \rho^k \sigma^2$ decae geométricamente con el retardo.

💡 P4. Lectura del gráfico temporal de residuos

Un gráfico de residuos MCO contra el tiempo muestra largas rachas de residuos positivos seguidas de largas rachas de residuos negativos. Esto sugiere:

- A. Autocorrelación positiva.
- B. Autocorrelación negativa.
- C. Heterocedasticidad.
- D. Ausencia de patrón sistemático.

Respuesta: A. Las rachas persistentes del mismo signo son la firma visual de $\rho > 0$. Patrones de diente de sierra (signos alternados) sugieren $\rho < 0$.

💡 P5. El estadístico de Durbin-Watson

Para n grande, el estadístico de Durbin-Watson satisface:

- A. $DW = \hat{\rho}$.
- B. $DW = 1 + \hat{\rho}$.
- C. $DW \approx 2(1 - \hat{\rho})$.
- D. $DW = 2\hat{\rho}$.

Respuesta: C. Desarrollando el cuadrado del numerador y usando $\sum \hat{u}_t^2 \approx \sum \hat{u}_{t-1}^2$ para n grande se obtiene $DW \approx 2(1 - \hat{\rho})$.

💡 P6. Cuándo DW no es válido

El contraste de Durbin-Watson **no** es válido cuando:

- A. Los errores son normales.
- B. La muestra es grande.
- C. Hay muchos regresores.
- D. La regresión incluye un retardo de la variable dependiente.

Respuesta: D. Un retardo de la variable dependiente induce correlación entre regresor y error, sesga DW hacia 2 (hacia la nula) y arruina el contraste. Hay que usar la h de Durbin.

💡 P7. Tras Cochrane-Orcutt

Después de una corrección de Cochrane-Orcutt exitosa, el estadístico DW sobre la regresión transformada debería:

- A. Estar próximo a 0.
- B. Estar próximo a 4.
- C. Coincidir con $\hat{\rho}$.
- D. Estar próximo a 2.

Respuesta: D. Una corrección AR(1) exitosa “blanquea” los residuos, de modo que $\hat{\rho}^*$ sobre el modelo transformado está próximo a 0 y $DW^* \approx 2(1 - 0) = 2$. Si DW sigue lejos de 2, la hipótesis AR(1) no es la adecuada.

El conjunto completo (doce preguntas, incluyendo ejercicios de simulación) está en `LEARNR/08_autocorrelation.Rmd`.

Ejercicios

Ejercicio 8.1 — Lectura de un Durbin-Watson. Una regresión de ventas trimestrales sobre gasto en publicidad y tendencia temporal utiliza $n = 80$ trimestres y $k = 2$ regresores. La salida de MCO reporta $DW = 0,94$. Las cotas relevantes al 5 % son $d_L = 1,59$ y $d_U = 1,69$. Enuncia tu conclusión y explica qué implica para los estadísticos t de la regresión.

💡 Ver respuesta

Como $0 < DW < d_L$ (es decir, $0,94 < 1,59$), se rechaza $H_0 : \rho = 0$ a favor de $H_1 : \rho > 0$: hay autocorrelación positiva de primer orden. La $\hat{\rho}$ implícita es $\approx 1 - DW/2 = 0,53$. Los errores estándar de MCO son entonces demasiado pequeños, los t estarán inflados, y cualquier coeficiente “significativo” debería re-contrastarse mediante Cochrane-Orcutt o un estimador HAC tipo Newey-West.

Ejercicio 8.2 — Signo de la autocorrelación a partir del gráfico de retardos. Un diagrama de dispersión de $\hat{u}_t$ frente a $\hat{u}_{t-1}$ presenta una nube con pendiente claramente *negativa*, con la mayoría de los puntos en los cuadrantes superior-izquierdo e inferior-derecho. ¿Cuál es el signo aproximado de ρ ? ¿Qué valor aproximado tendrá el DW ?

💡 Ver respuesta

Pendiente negativa $\Rightarrow \hat{\rho} < 0$: autocorrelación **negativa**. Con (por ejemplo) $\hat{\rho} \approx -0,5$, $DW \approx 2(1 - (-0,5)) = 3$, holgadamente por encima de 2.

Ejercicio 8.3 — DW a partir de una tabla de residuos. Con los datos del ejemplo de §8.3.2: $\sum_{t=2}^n (\hat{u}_t - \hat{u}_{t-1})^2 = 18,796$ y $\sum_{t=1}^n \hat{u}_t^2 = 22,844$.

- Calcula el estadístico DW y el $\hat{\rho}$ implícito.
- Para $n = 10$ y $k = 1$, las cotas al 5 % son $d_L = 0,879$ y $d_U = 1,320$. ¿Cuál es tu conclusión?
- Explica brevemente por qué las cotas dependen de n y k .

💡 Ver respuesta

- $DW = 18,796/22,844 \approx 0,823$ y $\hat{\rho} \approx 1 - DW/2 \approx 0,589$. (b) Como $DW < d_L$, se rechaza H_0 : autocorrelación positiva. (c) La distribución exacta de DW depende de $\mathbf{X}'\mathbf{X}$; Durbin y Watson la acotaron con dos cotas que dependen solo de (n, k) , dejando dos zonas de indeterminación.

Ejercicio 8.4 — h-test de Durbin. Una regresión MCO con $n = 21$ produce

$$\hat{Y}_t = 1,3 + 0,97 Y_{t-1} + 2,31 X_t, \quad \text{se}(\hat{\alpha}) = 0,07, \quad DW = 1,21.$$

Calcula el estadístico h de Durbin y decide al 5 % si hay autocorrelación. ¿Por qué DW por sí solo sería engañoso?

💡 Ver respuesta

$$\hat{\rho} \approx 1 - 1,21/2 = 0,395; \widehat{\text{Var}}(\hat{\alpha}) = 0,07^2 = 0,0049;$$

$$h = 0,395 \cdot \sqrt{21/(1 - 21 \cdot 0,0049)} \approx 1,91.$$

Como $z_{0,975} = 1,96$ y $|h| < 1,96$, **no se rechaza** H_0 . El DW de 1,21 está sesgado hacia 2 (la nula) por la presencia de Y_{t-1} ; usarlo sin más habría llevado a falsificar la presencia de autocorrelación.

Ejercicio 8.5 — **Por qué la autocorrelación positiva subestima los errores estándar (esquema).** En un párrafo, explica —usando la idea de *tamaño muestral efectivo*— por qué la autocorrelación positiva hace que el error estándar habitual de $\hat{\beta}_1$ en $y_t = \beta_0 + \beta_1 x_t + u_t$ sea demasiado pequeño. No es necesario derivar fórmulas: basta con una intuición basada en el contenido informativo de n observaciones correlacionadas.

La respuesta completa se proporciona en la Edición del Profesor.

Ejercicio 8.6 — **Cochrane-Orcutt en un paso, a mano.** Una muestra pequeña arroja $\hat{\rho} = 0,4226$ a partir de los residuos MCO de $Y_t = \beta_0 + \beta_1 X_t + u_t$ con $n = 10$ observaciones.

- Escribe las fórmulas de las variables cuasi-diferenciadas Y_t^* , X_t^* y el término constante transformado, *incluyendo* el tratamiento de Prais-Winsten para $t = 1$.
- Explica por qué el error estándar de $\hat{\beta}_1$ sobre (Y_t^*, X_t^*) es el que debe reportarse, y no el de MCO sobre la regresión *original*.
- Tras la MCO sobre (Y_t^*, X_t^*) , el nuevo DW vale 1,52. Con $n = 9$, $k = 1$, $d_L = 0,824$ y $d_U = 1,320$, ¿iterarías de nuevo o pararías?

La respuesta completa se proporciona en la Edición del Profesor.

Prerrequisitos matemáticos y estadísticos

Este apéndice recoge, en formato de referencia rápida, las herramientas matemáticas y estadísticas que el libro asume conocidas. No pretende sustituir un curso de cálculo, probabilidad o álgebra lineal; el objetivo es **fijar la notación** —la de Wooldridge (2020)— y **recordar las propiedades** que se usan a lo largo del texto: el logaritmo en las elasticidades del Capítulo 6, las condiciones de primer orden en la derivación de MCO del Capítulo 2, las propiedades de la varianza y la covarianza en la fórmula del estimador, la distribución muestral del Capítulo 4 y la forma matricial del Capítulo 3.

Se incluye también un bloque práctico sobre **R y RStudio**: cómo instalar el software, cargar los paquetes que usaremos y dar los primeros pasos con un conjunto de datos reales.

Objetivos

- **Manejar** las propiedades del logaritmo natural y de los exponentes que aparecen en las formas funcionales del libro.
- **Calcular** derivadas y derivadas parciales sencillas, y plantear la **condición de primer orden (CPO)** de un problema de optimización.
- **Aplicar** las reglas de la esperanza, la varianza y la covarianza para variables aleatorias.
- **Identificar** las distribuciones muestrales que se usan en inferencia (t , F , χ^2) y reconocer dónde aparece el **teorema central del límite (TCL)**.
- **Operar** con vectores y matrices al nivel necesario para entender la forma matricial de MCO.
- **Instalar** R y RStudio, cargar el paquete `wooldridge` y producir los primeros descriptivos y gráficos.

A.1. A.1 Repaso de álgebra

A.1.1. A.1.1 Funciones y exponentes

Una **función** f asigna a cada valor x del dominio un único valor $y = f(x)$. En el libro trabajaremos sobre todo con tres familias:

- **Lineal:** $f(x) = a + bx$. La pendiente b es constante.
- **Cuadrática:** $f(x) = a + bx + cx^2$. La pendiente $b + 2cx$ depende de x (rendimientos decrecientes o crecientes).

- **Exponencial / logarítmica:** $f(x) = e^x$ y su inversa $f(x) = \ln(x)$.

Recordamos las reglas básicas de los **exponentes**. Para todo $a > 0$ y cualesquiera reales m, n :

$$a^m \cdot a^n = a^{m+n}, \quad \frac{a^m}{a^n} = a^{m-n}, \quad (a^m)^n = a^{mn}, \quad a^0 = 1, \quad a^{-n} = \frac{1}{a^n}.$$

(Las mismas identidades valen para cualquier real $a \neq 0$ cuando m, n son enteros; la restricción $a > 0$ pasa a ser importante en cuanto admitimos exponentes fraccionarios —por ejemplo, la raíz cuadrada $\sqrt{a} = a^{1/2}$ solo está definida para $a \geq 0$.)

A.1.2. A.1.2 Logaritmos

El **logaritmo natural** $\ln(x) = \log_e(x)$ es la inversa de la función exponencial e^x :

$$\ln(e^x) = x, \quad e^{\ln(x)} = x \quad (x > 0).$$

Las cuatro propiedades que usaremos sistemáticamente —sobre todo en el Capítulo 6, al interpretar modelos log-lineales como **elasticidades**— son:

$$\ln(xy) = \ln(x) + \ln(y), \quad \ln\left(\frac{x}{y}\right) = \ln(x) - \ln(y),$$

$$\ln(x^a) = a \ln(x), \quad \ln(1) = 0.$$

Aproximación $\log \approx$ tasa de crecimiento

Para variaciones pequeñas, $\ln(x_1) - \ln(x_0) \approx (x_1 - x_0)/x_0$. Es decir: la **diferencia de logaritmos** aproxima la **tasa de crecimiento**. Por eso, en un modelo del tipo $\ln(\text{salario}) = \beta_0 + \beta_1 \text{educ} + u$, el coeficiente β_1 se interpreta como el cambio **proporcional** en el salario asociado a un año adicional de educación (un retorno aproximado a la educación). Volveremos sobre esto con detalle en el Capítulo 6.

Error frecuente

$\ln(x + y) \neq \ln(x) + \ln(y)$. La regla del logaritmo del producto vale para $\ln(xy)$, no para $\ln(x + y)$. Confundirlas es uno de los errores algebraicos más habituales al manipular modelos log-lineales.

A.1.3. A.1.3 Sumatorios

El símbolo de sumatorio $\sum$ es una notación abreviada de la que no podemos prescindir:

$$\sum_{i=1}^n x_i = x_1 + x_2 + \cdots + x_n.$$

Dos propiedades que se usan constantemente:

$$\sum_{i=1}^n (ax_i + by_i) = a \sum_{i=1}^n x_i + b \sum_{i=1}^n y_i, \quad \sum_{i=1}^n c = n c.$$

La media muestral es $\bar{x} = \frac{1}{n} \sum_{i=1}^n x_i$, y una propiedad que utilizaremos en la derivación de MCO es $\sum_{i=1}^n (x_i - \bar{x}) = 0$.

A.2. A.2 Repaso de cálculo

A.2.1. A.2.1 Derivada de una función

La **derivada** $f'(x) = \frac{df}{dx}$ mide la pendiente de f en el punto x . Las reglas que necesitaremos son:

Función	Derivada
$f(x) = c$ (constante)	$f'(x) = 0$
$f(x) = x^n$	$f'(x) = n x^{n-1}$
$f(x) = e^x$	$f'(x) = e^x$
$f(x) = \ln(x)$	$f'(x) = 1/x$
$f(x) = a g(x) + b h(x)$	$f'(x) = a g'(x) + b h'(x)$
$f(x) = g(x) h(x)$	$f'(x) = g'(x) h(x) + g(x) h'(x)$
$f(x) = g(h(x))$ (regla de la cadena)	$f'(x) = g'(h(x)) h'(x)$

A.2.2. A.2.2 Derivadas parciales

Cuando f depende de varias variables, $f(x_1, x_2, \dots, x_k)$, la **derivada parcial** respecto de x_j se obtiene tratando las demás variables como constantes:

$$\frac{\partial f}{\partial x_j}.$$

En el Capítulo 3 (regresión múltiple), el coeficiente β_j del modelo $y = \beta_0 + \beta_1 x_1 + \dots + \beta_k x_k + u$ se interpreta como:

$$\beta_j = \frac{\partial \mathbb{E}[y \mid x_1, \dots, x_k]}{\partial x_j},$$

es decir, el cambio esperado en y ante un aumento unitario de x_j **manteniendo constantes** las demás regresoras (interpretación *ceteris paribus*).

A.2.3. A.2.3 Optimización por condición de primer orden

Si f es suave y alcanza un máximo o mínimo interior en x^* , entonces

$$f'(x^*) = 0.$$

Esta es la **condición de primer orden (CPO)**. Para verificar que se trata de un mínimo, una condición *suficiente* es $f''(x^*) > 0$; la condición *necesaria* de segundo orden es la más débil $f''(x^*) \geq 0$. La distinción importa porque casos como $f(x) = x^4$ tienen un mínimo en $x = 0$ con $f''(0) = 0$.

En el caso multivariante, la CPO de $f(x_1, \dots, x_k)$ es

$$\frac{\partial f}{\partial x_j} = 0 \quad \text{para } j = 1, 2, \dots, k.$$

Este es el aparato que utilizaremos en §2.4 para derivar el estimador de **Mínimos Cuadrados Ordinarios (MCO)**: la suma de cuadrados de los residuos $\text{SCR}(\beta_0, \beta_1) = \sum_i (y_i - \beta_0 - \beta_1 x_i)^2$ se minimiza imponiendo $\partial \text{SCR} / \partial \beta_0 = 0$ y $\partial \text{SCR} / \partial \beta_1 = 0$.

Ejemplo: CPO de una parábola

Sea $f(x) = (x - 3)^2 + 5$. Su derivada es $f'(x) = 2(x - 3)$. Imponiendo $f'(x) = 0$ se obtiene $x^* = 3$. Como $f''(x) = 2 > 0$, es un mínimo. El valor mínimo de la función es $f(3) = 5$. La misma lógica, aplicada a una suma de cuadrados con dos parámetros, conduce a las fórmulas de MCO.

A.3. A.3 Repaso de probabilidad

A.3.1. A.3.1 Variable aleatoria

Una **variable aleatoria** X es una función que asigna un número real a cada resultado de un experimento aleatorio. Distinguimos dos tipos:

- **Discretas**: toman un conjunto finito o numerable de valores (número de hijos, sector de actividad codificado, dummy 0/1).
- **Continuas**: toman valores en un intervalo de $\mathbb{R}$ (salario, altura, tipo de interés).

A.3.2. A.3.2 Esperanza

La **esperanza** de X —su valor medio poblacional— se denota:

$$\mathbb{E}[X] = \mu.$$

Las propiedades fundamentales son:

$$\mathbb{E}[c] = c, \quad \mathbb{E}[aX + b] = a \mathbb{E}[X] + b,$$

$$\mathbb{E}[aX_1 + bX_2] = a \mathbb{E}[X_1] + b \mathbb{E}[X_2],$$

$$\mathbb{E}\left[\sum_{i=1}^N a_i X_i\right] = \sum_{i=1}^N a_i \mathbb{E}[X_i].$$

Esta última propiedad —la **linealidad de la esperanza**— vale **siempre**, con independencia de que las X_i estén correlacionadas o no.

A.3.3. A.3.3 Varianza

La **varianza** mide la dispersión de X en torno a su media:

$$\text{Var}(X) = \sigma^2 = \mathbb{E}[(X - \mathbb{E}[X])^2] = \mathbb{E}[(X - \mu)^2].$$

Equivalentemente, usando la fórmula computacional:

$$\text{Var}(X) = \mathbb{E}[X^2] - \mathbb{E}[X]^2.$$

Propiedades:

$$\text{Var}(c) = 0, \quad \text{Var}(aX) = a^2 \text{Var}(X), \quad \text{Var}(aX + b) = a^2 \text{Var}(X).$$

La **desviación típica** $\sigma = \sqrt{\text{Var}(X)}$ se expresa en las mismas unidades que X .

A.3.4. A.3.4 Covarianza y correlación

La **covarianza** mide la asociación lineal entre dos variables:

$$\text{Cov}(X, Y) = \mathbb{E}[(X - \mathbb{E}[X])(Y - \mathbb{E}[Y])] = \mathbb{E}[XY] - \mathbb{E}[X] \mathbb{E}[Y].$$

Si $\mathbb{E}[X] = 0$ o $\mathbb{E}[Y] = 0$, la fórmula se simplifica a $\text{Cov}(X, Y) = \mathbb{E}[XY]$.

Propiedades:

$$\text{Cov}(aX, bY) = ab \text{Cov}(X, Y), \quad \text{Cov}(X, X) = \text{Var}(X).$$

Si X e Y son **independientes**, entonces $\text{Cov}(X, Y) = 0$. El recíproco no es cierto en general: covarianza nula solo descarta asociación **lineal**.

La **correlación** es la covarianza normalizada y vive en $[-1, 1]$:

$$\text{Corr}(X, Y) = \frac{\text{Cov}(X, Y)}{\sqrt{\text{Var}(X) \text{Var}(Y)}} = \frac{\text{Cov}(X, Y)}{\sigma_X \sigma_Y}.$$

A.3.5. A.3.5 Varianza de una suma

Combinando varianza y covarianza:

$$\text{Var}(aX + bY) = a^2 \text{Var}(X) + b^2 \text{Var}(Y) + 2ab \text{Cov}(X, Y).$$

Si $\text{Cov}(X, Y) = 0$ —en particular, si X e Y son independientes—:

$$\text{Var}(X + Y) = \text{Var}(X) + \text{Var}(Y).$$

Error frecuente

La fórmula $\text{Var}(X + Y) = \text{Var}(X) + \text{Var}(Y)$ **solo** vale cuando la covarianza entre X e Y es cero. Cuando hay correlación, hay que añadir el término cruzado $2 \text{Cov}(X, Y)$. Olvidarlo es uno de los errores más habituales al calcular varianzas de estimadores.

A.3.6. A.3.6 Esperanza condicional

La **esperanza condicional** $\mathbb{E}[Y | X]$ es la media de Y dado un valor de X . Es una función de X y juega un papel central en econometría: el modelo de regresión es, en esencia, una forma funcional para $\mathbb{E}[Y | X]$.

Propiedades:

$$\mathbb{E}[X | X] = X, \quad \mathbb{E}[a g(X) Y + b h(X) | X] = a g(X) \mathbb{E}[Y | X] + b h(X).$$

Si X e Y son independientes, $\mathbb{E}[Y | X] = \mathbb{E}[Y]$.

La **ley de las esperanzas iteradas** (o esperanza anidada) afirma que:

$$\mathbb{E}[\mathbb{E}[Y | X]] = \mathbb{E}[Y].$$

Es decir, la media de las medias condicionales es la media incondicional. Es la herramienta clave para mostrar, en el Capítulo 3, que bajo el supuesto de exogeneidad estricta $\mathbb{E}[u | x_1, \dots, x_k] = 0$, el estimador MCO es insesgado.

A.4. A.4 Repaso de inferencia estadística

A.4.1. A.4.1 Estimadores y distribución muestral

Dada una muestra aleatoria $\{Y_1, Y_2, \dots, Y_n\}$ de una población, un **estimador** $\hat{\theta}$ es una función de los datos que aproxima un parámetro poblacional θ . La **distribución muestral** de $\hat{\theta}$ —la distribución que se obtendría repitiendo el muestreo infinitas veces— describe su comportamiento. Dos rasgos de esa distribución determinan la calidad del estimador:

- La **media**: $\hat{\theta}$ es *insesgado* para θ si $\mathbb{E}[\hat{\theta}] = \theta$. Diremos además que es **consistente** si converge a θ cuando $n \rightarrow \infty$.

- La **varianza**: entre los estimadores *lineales* insesgados, el de menor varianza es el más *eficiente*. El teorema de Gauss–Markov del Capítulo 3 formaliza esta comparación para MCO (de ahí el acrónimo **ELIO**: Estimador Lineal Insesgado Óptimo). El calificativo “lineal” es decisivo: estimadores no lineales (ridge, LASSO, regresión cuantílica) pueden batir a MCO en error cuadrático medio aceptando un pequeño sesgo a cambio de una reducción grande de la varianza.

A.4.2. A.4.2 Teorema central del límite

Si $\{Y_1, \dots, Y_n\}$ es una muestra i.i.d. con media μ y varianza $\sigma^2 < \infty$, la media muestral $\bar{Y} = \frac{1}{n} \sum_i Y_i$ cumple, para n grande:

$$\frac{\bar{Y} - \mu}{\sigma/\sqrt{n}} \stackrel{a}{\sim} N(0, 1).$$

Este es el **teorema central del límite (TCL)**. Es la razón por la que la **distribución normal** aparece de forma sistemática en inferencia: aunque la población no sea normal, las medias y los estimadores MCO basados en sumas se aproximan a una normal cuando la muestra es suficientemente grande.

A.4.3. A.4.3 Distribuciones t , F y χ^2

Tres distribuciones aparecen una y otra vez en los Capítulos 4 y 5:

- **Chi-cuadrado** χ_q^2 : si $Z_1, \dots, Z_q \sim N(0, 1)$ son independientes, entonces $\sum_{i=1}^q Z_i^2 \sim \chi_q^2$. Sus grados de libertad son q y su media es q .
- **t de Student** t_q : si $Z \sim N(0, 1)$ y $W \sim \chi_q^2$ son independientes, entonces $Z/\sqrt{W/q} \sim t_q$. Es simétrica en torno a 0 y, para q grande, se aproxima a la $N(0, 1)$.
- **F de Snedecor** F_{q_1, q_2} : si $W_1 \sim \chi_{q_1}^2$ y $W_2 \sim \chi_{q_2}^2$ son independientes, entonces $(W_1/q_1)/(W_2/q_2) \sim F_{q_1, q_2}$. Solo toma valores positivos.

En los contrastes del libro, los **valores críticos** —los percentiles 0,95 o 0,99 de estas distribuciones— se leen de una tabla o se calculan en R con `qt()`, `qf()` y `qchisq()`. La regla práctica: la t aparece en contrastes sobre **un solo** coeficiente (§4.3); la F , en contrastes de **restricciones múltiples** (§4.4).

Definición: p -valor

El p -valor de un contraste es la probabilidad, bajo la hipótesis nula, de observar un estadístico de contraste al menos tan extremo como el obtenido. Un p -valor pequeño constituye evidencia en contra de la nula. Los umbrales convencionales son 1 %, 5 % y 10 %, pero lo que conviene reportar es el propio p -valor —no solo “rechazada” o “no rechazada”.

A.4.4. A.4.4 Intervalos de confianza

Un **intervalo de confianza** al $(1 - \alpha)$ para un parámetro θ es un intervalo aleatorio que, en muestras repetidas, contiene al verdadero θ con probabilidad $1 - \alpha$. Para un estimador $\hat{\theta}$ con distribución muestral aproximadamente normal y error estándar $ee(\hat{\theta})$, el intervalo estándar al 95 % es $\hat{\theta} \pm 1,96 \cdot ee(\hat{\theta})$. El Capítulo 4 construye intervalos de confianza para los coeficientes individuales de MCO exactamente con esta forma.

A.5. A.5 Repaso de álgebra lineal

El libro recurre a la **forma matricial** de MCO de forma sistemática a partir de §3.4. Aquí fijamos lo imprescindible.

A.5.1. A.5.1 Vectores y matrices

Un **vector columna** de dimensión n se escribe

$$\mathbf{y} = \begin{pmatrix} y_1 \\ y_2 \\ \vdots \\ y_n \end{pmatrix}.$$

Una **matriz** A de dimensión $n \times k$ tiene n filas y k columnas; sus elementos se denotan a_{ij} , con i índice de fila y j índice de columna.

A.5.2. A.5.2 Operaciones básicas

- **Suma:** dos matrices del mismo tamaño se suman elemento a elemento.
- **Producto por escalar:** $(\alpha A)_{ij} = \alpha a_{ij}$.
- **Producto matricial:** si A es $n \times k$ y B es $k \times m$, entonces AB es $n \times m$ con $(AB)_{ij} = \sum_{\ell=1}^k a_{i\ell} b_{\ell j}$. El producto **no** es conmutativo: en general $AB \neq BA$.

A.5.3. A.5.3 Traspuesta

La **traspuesta** A' (también escrita A') intercambia filas y columnas: si A es $n \times k$, A' es $k \times n$ y $(A')_{ij} = a_{ji}$. Propiedades:

$$(A')' = A, \quad (A + B)' = A' + B', \quad (AB)' = B' A'.$$

Una matriz es **simétrica** si $A = A'$.

A.5.4. A.5.4 Inversa y rango

Una matriz cuadrada A de dimensión $k \times k$ es **invertible** (o no singular) si existe A^{-1} tal que $AA^{-1} = A^{-1}A = I_k$, donde I_k es la matriz identidad de tamaño k . Propiedades:

$$(A^{-1})^{-1} = A, \quad (AB)^{-1} = B^{-1} A^{-1}, \quad (A^{-1})' = (A')^{-1}.$$

El **rango** de una matriz A es el número de columnas (o filas) **linealmente independientes**. Una matriz cuadrada $k \times k$ es invertible si y solo si tiene rango k (rango pleno).

En el Capítulo 3, el estimador MCO en forma matricial es

$$\hat{\beta} = (X'X)^{-1} X' \mathbf{y},$$

donde X es la matriz $n \times k$ de regresoras (con una columna de unos para el intercepto). El supuesto de **rango pleno** —que las columnas de X sean linealmente independientes— es lo que garantiza que $X'X$ sea invertible. Su violación es justamente la **multicolinealidad perfecta** del Capítulo 3.

A.6. A.6 Configurar R y RStudio

Todo el libro emplea **R** —y, como interfaz gráfica, **RStudio**— para la práctica. Ambos son gratuitos y multiplataforma.

1. Descargar e instalar **R** desde <https://cran.r-project.org/>.
2. Descargar e instalar **RStudio Desktop** desde <https://posit.co/download/rstudio-desktop/>.
3. Abrir RStudio. En la consola, instalar de una sola vez los paquetes que usaremos a lo largo del curso:

```
install.packages(c("wooldridge", "readxl", "lmtest", "sandwich", "orcutt"))
```

La instalación se realiza **una sola vez** por equipo. En cada sesión nueva, los paquetes se cargan con `library()`.

```
library(wooldridge)
data("wage1")
```

Estos paquetes cubren, respectivamente: los conjuntos de datos del libro de Wooldridge (`wooldridge`), la lectura de archivos Excel (`readxl`), contrastes de hipótesis sobre coeficientes (`lmtest`), errores estándar robustos a heterocedasticidad (`sandwich`) y la corrección de Cochrane–Orcutt para autocorrelación (`orcutt`).

Lectura desde Excel

Para leer un archivo `.xlsx` propio (por ejemplo, los datos de la Práctica 0):

```
library(readxl)
datos_notas <- read_excel("ruta/al/archivo/datos_notas.xlsx")
```

Hay que usar **barras inclinadas** / en la ruta —incluso en Windows— o duplicar las barras invertidas (\\).

A.6.1. Primer vistazo a un conjunto de datos

Tres funciones bastan para una primera exploración:

```
str(wage1)
```

```
'data.frame':  526 obs. of  24 variables:
 $ wage      : num  3.1 3.24 3 6 5.3 ...
 $ educ      : int   11 12 11 8 12 16 18 12 12 17 ...
 $ exper     : int   2 22 2 44 7 9 15 5 26 22 ...
```

A. Prerrequisitos matemáticos y estadísticos

```
$ tenure : int  0 2 0 28 2 8 7 3 4 21 ...
$ nonwhite: int  0 0 0 0 0 0 0 0 0 0 ...
$ female  : int  1 1 0 0 0 0 0 1 1 0 ...
$ married : int  0 1 0 1 1 1 0 0 0 1 ...
$ numdep  : int  2 3 2 0 1 0 0 0 2 0 ...
$ smsa    : int  1 1 0 1 0 1 1 1 1 1 ...
$ northcen: int  0 0 0 0 0 0 0 0 0 0 ...
$ south   : int  0 0 0 0 0 0 0 0 0 0 ...
$ west    : int  1 1 1 1 1 1 1 1 1 1 ...
$ construc: int  0 0 0 0 0 0 0 0 0 0 ...
$ ndurman : int  0 0 0 0 0 0 0 0 0 0 ...
$ trcompu : int  0 0 0 0 0 0 0 0 0 0 ...
$ trade   : int  0 0 1 0 0 0 1 0 1 0 ...
$ services: int  0 1 0 0 0 0 0 0 0 0 ...
$ profserv: int  0 0 0 0 0 1 0 0 0 0 ...
$ profocc : int  0 0 0 0 0 1 1 1 1 1 ...
$ clerocc : int  0 0 0 1 0 0 0 0 0 0 ...
$ servocc : int  0 1 0 0 0 0 0 0 0 0 ...
$ lwage   : num  1.13 1.18 1.1 1.79 1.67 ...
$ expersq : int  4 484 4 1936 49 81 225 25 676 484 ...
$ tenursq : int  0 4 0 784 4 64 49 9 16 441 ...
- attr(*, "time.stamp")= chr "25 Jun 2011 23:03"
```

`str()` describe la **estructura**: tipo de cada variable, número de observaciones y de columnas. Útil para confirmar que las variables numéricas no se han leído como texto.

```
summary(wage1[, c("wage", "educ", "exper", "tenure")])
```

wage	educ	exper	tenure
Min. : 0.530	Min. : 0.00	Min. : 1.00	Min. : 0.000
1st Qu.: 3.330	1st Qu.:12.00	1st Qu.: 5.00	1st Qu.: 0.000
Median : 4.650	Median :12.00	Median :13.50	Median : 2.000
Mean : 5.896	Mean :12.56	Mean :17.02	Mean : 5.105
3rd Qu.: 6.880	3rd Qu.:14.00	3rd Qu.:26.00	3rd Qu.: 7.000
Max. :24.980	Max. :18.00	Max. :51.00	Max. :44.000

`summary()` devuelve los **estadísticos descriptivos** —mínimo, máximo, media, mediana y cuartiles— de cada variable.

```
head(wage1[, c("wage", "educ", "exper", "female", "married")])
```

	wage	educ	exper	female	married
1	3.10	11	2	1	0
2	3.24	12	22	1	1
3	3.00	11	2	0	0
4	6.00	8	44	0	1
5	5.30	12	7	0	1
6	8.75	16	9	0	1

`head()` muestra las **primeras filas** para inspeccionar visualmente los datos.

i Glosario rápido de R

- `<-` es el operador de **asignación**: `x <- 5` guarda el valor 5 en el objeto `x`.
- `c()` **combina** valores en un vector: `c(1, 2, 3)`.
- `data.frame` es la estructura tabular estándar: una columna por variable, una fila por observación.
- `$` extrae una columna por su nombre: `wage1$wage`.
- `?nombre_funcion` abre la ayuda de `nombre_funcion`.

A.7. A.7 Primeros gráficos

Más allá de los estadísticos resumen, conviene **mirar** los datos. R ofrece comandos sencillos para histogramas, diagramas de dispersión y medias condicionales por grupos.

A.7.1. A.7.1 Histograma de una variable

```
hist(wage1$wage,
     breaks = 30, col = "lightblue",
     main = "Distribución del salario por hora",
     xlab = "Salario (USD/h)")
```




Figure A.1.: Distribución del salario por hora (USD).

A. Prerrequisitos matemáticos y estadísticos

La distribución es claramente **asimétrica a la derecha**: hay una cola larga de salarios altos. La media (aprox. 5,90 USD/h) supera a la mediana (4,65 USD/h). Es el patrón habitual en variables de renta.

```
hist(wage1$educ,  
     breaks = 18, col = "lightgreen",  
     main = "Años de educación",  
     xlab = "Años de educación")
```




Figure A.2.: Distribución de los años de educación.

A.7.2. A.7.2 Diagrama de dispersión

```
plot(wage1$educ, wage1$wage,  
     pch = 16, col = rgb(0, 0, 1, 0.3),  
     xlab = "Años de educación",  
     ylab = "Salario por hora (USD)",  
     main = "Salario vs. educación")
```




Figure A.3.: Salario por hora frente a años de educación.

La nube sugiere una **asociación positiva** entre educación y salario. Pero —como se discutió en el Capítulo 1— la correlación bruta no es el efecto causal de la educación: para acercarnos a éste necesitaremos los controles del Capítulo 3.

A.7.3. A.7.3 Medias condicionales

```
# Salario medio por género (female = 1 si mujer)
tapply(wage1$wage, wage1$female, mean)
```

```
0      1
7.099489 4.587659
```

```
# Salario medio por estado civil
tapply(wage1$wage, wage1$married, mean)
```

```
0      1
4.843884 6.573469
```

`tapply()` calcula una **media condicional**: la media de Y por grupos definidos por una variable categórica. Estas medias son útiles para detectar asociaciones brutas, pero no son efectos causales: una brecha salarial bruta entre hombres y mujeres puede reflejar diferencias en ocupación, experiencia, sector y horas trabajadas, además de —o en lugar de— discriminación.

 Pista: a partir de aquí

Con R instalado, los paquetes cargados y los descriptivos a la vista, ya se está en condiciones de abordar el primer modelo de regresión del Capítulo 2. La función `lm()` —el estimador MCO en R— se introduce allí; las propiedades teóricas de los estimadores, en los Capítulos 3 y 4; y los contrastes basados en valores críticos t , en §4.3.

Crosswalk Wooldridge Carter–Griffiths–Lim

B.1. B.1 Por qué este crosswalk

La mayoría de estudiantes de la UGR llega a este curso con dos libros de cabecera al alcance: Wooldridge (2020) —el manual de referencia internacional, con datos y ejemplos centrados en el mercado de trabajo estadounidense— y Hill et al. (2017) —el *Principles of Econometrics* de Carter, Griffiths y Lim (CGL), disponible en la biblioteca de la Facultad y muy utilizado en la docencia en castellano—. Por decisión editorial (D9), este libro adopta la **notación de Wooldridge**: misma letra griega para los mismos objetos, misma convención para el subíndice del intercepto, mismas siglas para las sumas de cuadrados. Las dos tradiciones son matemáticamente equivalentes, pero usan **letras distintas para nombrar las mismas cosas** y, en algún caso, asignan las **mismas siglas a objetos distintos**. Este apéndice es la tabla de equivalencias que permite leer ambos textos sin tropezarse.

B.2. B.2 Crosswalk de notación

La tabla siguiente recoge las equivalencias para los conceptos que aparecen una y otra vez a lo largo del libro.

Concepto	Wooldridge (este libro)	Carter–Griffiths–Lim 5e
Intercepto poblacional	β_0	β_1
Pendiente poblacional sobre x_1	β_1	β_2
Pendiente j -ésima (regresión múltiple)	$\beta_j, j = 1, \dots, k$	$\beta_j, j = 2, \dots, K$
Término de error	u	e
Valor ajustado	$\hat{y}$	$\hat{y}$
Residuo	$\hat{u}$	$\hat{e}$
Suma de cuadrados total	SCT	SCT
Suma de cuadrados residuales	SCR	SCE
Suma de cuadrados explicada	SCE	SCR
Coefficiente de determinación	R^2	R^2
Tamaño muestral	n	N
Número de regresores (sin intercepto)	k	$K - 1$

Concepto	Wooldridge (este libro)	Carter–Griffiths–Lim 5e
Número de parámetros (incl. intercepto)	$k + 1$	K
Estimador MCO	$\hat{\beta}_j$	b_{j+1}
Error estándar del estimador	$\text{se}(\hat{\beta}_j)$	$\widehat{\text{sd}}(b_{j+1})$
Varianza poblacional del error	$\sigma^2 = \text{Var}(u \mid x)$	$\sigma^2 = \text{Var}(e \mid x)$
Estimador de σ^2	$\hat{\sigma}^2 = \text{SCR}/(n - k - 1)$	$\hat{\sigma}^2 = \text{SCE}/(N - K)$
Estadístico t	$t = \hat{\beta}_j / \text{se}(\hat{\beta}_j)$	$t = b_{j+1} / \widehat{\text{sd}}(b_{j+1})$
Estadístico F , q restricciones	F con gl $(q, n - k - 1)$	F con gl $(J, N - K)$
IC del 95 % para β_j	$\hat{\beta}_j \pm t_{0.975, n-k-1} \cdot \text{se}(\hat{\beta}_j)$	$b_{j+1} \pm t_c \cdot \widehat{\text{sd}}(b_{j+1})$
Errores estándar robustos a heterocedasticidad	HC0/HC1/HC2/HC3 (sandwich)	“white” / robustos (HC1)
Modelo AR(1)	$u_t = \rho u_{t-1} + \varepsilon_t$	$e_t = \rho e_{t-1} + v_t$
Variable ficticia (0/1)	<i>dummy</i>	<i>indicator</i>
Interacción	$x_1 \cdot x_2$ o $x_1:x_2$	$x_1 \cdot x_2$
Forma cuadrática	$\beta_1 x + \beta_2 x^2$	$\beta_2 x + \beta_3 x^2$
log-nivel (semi-elasticidad)	$\ln(y) = \beta_0 + \beta_1 x + u$	$\ln(y) = \beta_1 + \beta_2 x + e$
nivel-log	$y = \beta_0 + \beta_1 \ln(x) + u$	$y = \beta_1 + \beta_2 \ln(x) + e$
log-log (elasticidad)	$\ln(y) = \beta_0 + \beta_1 \ln(x) + u$	$\ln(y) = \beta_1 + \beta_2 \ln(x) + e$

⚠ Atención: SCR y SCE están intercambiadas

Los nombres «SCR» y «SCE» están **intercambiados** entre las dos tradiciones. En Wooldridge, **SCR** es la *suma de cuadrados de los residuos* ($\sum_i \hat{u}_i^2$) y **SCE** es la *suma de cuadrados explicada*; en CGL, **SCE** es la *suma de cuadrados de los errores* (los residuos) y **SCR** es la *suma de cuadrados de la regresión* (la explicada). La identidad SCT = SCE + SCR vale en ambos libros, pero **cada componente se llama distinto**. Al leer la salida de R: `summary(lm())`, `anova()` y `deviance()` siguen la convención de Wooldridge.

Una segunda fuente de confusión es el **subíndice del intercepto**. Wooldridge numera los coeficientes empezando por el intercepto (β_0) y sigue con las pendientes ($\beta_1, \beta_2, \dots, \beta_k$); CGL empieza por el intercepto en β_1 y las pendientes son $\beta_2, \beta_3, \dots, \beta_K$. La consecuencia práctica es que **el coeficiente sobre la primera regresora se llama β_1 en Wooldridge pero β_2 en CGL**. Hay que estar atento al leer ecuaciones cruzadas entre ambos textos.

B.3. B.3 Mapeo de capítulos

La tabla siguiente empareja los capítulos de este libro con los del Wooldridge y los del CGL. La columna de páginas de CGL es orientativa (5.^a edición, 2017) y debe contrastarse con el ejemplar concreto que tenga el lector.

Capítulo en este libro	Wooldridge 7e	CGL 5e	Páginas en CGL 5e (aprox.)
Cap. 1 — Conceptos iniciales	Cap. 1	Cap. 1	1–40
Cap. 2 — Regresión lineal simple (RLS)	Cap. 2	Cap. 2	41–98

Capítulo en este libro	Wooldridge 7e	CGL 5e	Páginas en CGL 5e (aprox.)
Cap. 3 — Regresión lineal múltiple (RLM)	Cap. 3	Cap. 5	191–242
Cap. 4 — Inferencia	Cap. 4	Cap. 3 y 6	99–134, 243–290
Cap. 5 — Predicción	Partes del Cap. 6	Cap. 4	135–190
Cap. 6 — Formas funcionales y ficticias	Caps. 6 y 7	Caps. 7 y 8	291–392
Cap. 7 — Heterocedasticidad	Cap. 8	Cap. 8	355–392
Cap. 8 — Autocorrelación	Cap. 12	Cap. 9	393–446
Apéndice A — Prerrequisitos	Apéndices A–C	Apéndices A–B y P	—

B.4. B.4 Dónde divergen pedagógicamente

Aunque los dos libros cubren el mismo núcleo de econometría introductoria, presentan el material con énfasis distintos. Conviene tenerlo en mente al alternar lecturas.

Forma matricial. Wooldridge introduce la forma matricial de MCO temprano (Apéndice E, referenciado ya desde §3.4) y la usa como herramienta unificadora en los capítulos avanzados. CGL pospone el tratamiento matricial hasta un apéndice final y trabaja casi todo el libro en notación escalar. Si el lector viene de CGL y se encuentra por primera vez con $\hat{\beta} = (X'X)^{-1}X'y$, conviene repasar el §A.5 de este libro antes de seguir.

Conjuntos de datos y ejemplos. Wooldridge ancla la mayoría de sus ejemplos en el mercado laboral estadounidense: salarios (`wage1`, `wage2`), educación, vivienda (`hprice1`), y delincuencia. CGL prefiere el **gasto en alimentos** como ejemplo recurrente del Capítulo 2 en adelante —un conjunto de datos pequeño y muy didáctico— y completa con datos de demanda, producción y mercados financieros. Las prácticas de este libro siguen a Wooldridge para que la base `wooldridge` de R sea la única dependencia.

Vocabulario. Wooldridge usa *dummy variable* (en castellano, **variable ficticia**) de forma sistemática. CGL prefiere *indicator variable* (**variable indicadora**), reservando *dummy* para usos coloquiales. Ambos términos son intercambiables; este libro adopta «ficticia», con «indicadora» como sinónimo entre paréntesis la primera vez que aparece (§6.3).

Heterocedasticidad. Los dos libros enseñan el contraste de Goldfeld–Quandt (GQ) y el de Breusch–Pagan (BP). CGL añade un tratamiento explícito y temprano del **contraste general de White** —incluyendo su versión con productos cruzados— como caso particular del BP con todos los cuadrados e interacciones. Wooldridge introduce White más tarde y de forma menos central. El §7.4 de este libro presenta los tres contrastes (BP, White y GQ) en el mismo lugar, siguiendo a Wooldridge en la notación.

Autocorrelación. Wooldridge dedica el Capítulo 12 a las series temporales con errores correlacionados, integrando Durbin–Watson, Breusch–Godfrey, y la corrección de Cochrane–Orcutt. CGL lo trata en su Capítulo 9, con un orden ligeramente distinto y un énfasis mayor en la estimación por **MCG factibles** (FGLS) desde el principio. Las prácticas de este libro siguen a Wooldridge: DW y BG como diagnóstico, Cochrane–Orcutt (`orcutt`) como corrección.

B.5. B.5 Si solo tienes CGL: ruta de lectura

Para el lector que solo dispone del CGL, la ruta de lectura que cubre el mismo material que este libro es la siguiente:

- **Cap. 1 (Conceptos iniciales)** → CGL Cap. 1, §1.1–1.6.
- **Cap. 2 (RLS)** → CGL Cap. 2, §2.1–2.10.
- **Cap. 3 (RLM)** → CGL Cap. 5, §5.1–5.6, más §5.7 para multicolinealidad.
- **Cap. 4 (Inferencia)** → CGL Cap. 3 para el caso de un coeficiente; CGL Cap. 6, §6.1–6.3 para contrastes F conjuntos y restricciones lineales.
- **Cap. 5 (Predicción)** → CGL Cap. 4, §4.1–4.4 (intervalos de predicción) y §6.4.
- **Cap. 6 (Formas funcionales y ficticias)** → CGL Cap. 7 completo (ficticias e interacciones) y CGL Cap. 8, §8.1 para log-niveles y cuadráticos.
- **Cap. 7 (Heterocedasticidad)** → CGL Cap. 8, §8.2–8.6 (BP, White, MCG factibles, errores robustos).
- **Cap. 8 (Autocorrelación)** → CGL Cap. 9, §9.1–9.5 (DW, AR(1), Cochrane–Orcutt, errores estándar HAC).

Con esta correspondencia, **cualquier lectura de este libro puede cruzarse con un capítulo y unas secciones concretas del CGL**. La recomendación práctica: leer primero el capítulo de este libro —que sigue el orden y la notación de Wooldridge— y consultar las secciones equivalentes de CGL cuando se quiera una segunda exposición, un ejemplo numérico distinto o un tratamiento alternativo de un contraste. La inversa también funciona: alumnos que vengan de un curso con CGL pueden usar este libro como **traducción a la notación de Wooldridge** sin perder material.

Tablas estadísticas

Este apéndice reúne los **valores críticos** de las cuatro distribuciones que aparecen en los contrastes del libro: la t de Student (Cap. 4, contrastes sobre un coeficiente), la F de Snedecor (Cap. 4, restricciones múltiples; Cap. 7, Breusch–Pagan), la χ^2 (Cap. 7 y 8, contrastes de heterocedasticidad y autocorrelación) y las cotas de Durbin–Watson (Cap. 8). Las tablas se generan en el momento, llamando a `qt()`, `qf()` y `qchisq()` sobre los grados de libertad estándar, de modo que son exactas hasta la precisión de máquina —a diferencia de las tablas impresas, que suelen redondear al cuarto decimal.

Cómo leer estas tablas

Cada tabla devuelve, para unos **grados de libertad (gl)** dados y un **nivel de significación** α , el **valor crítico** c_α : el percentil de la distribución de referencia que deja a su derecha una probabilidad α . La regla práctica del contraste es entonces inmediata: se rechaza H_0 cuando el estadístico observado supera c_α (en valor absoluto, si el contraste es bilateral). El **p -valor**, por su parte, invierte la pregunta: dado un estadístico observado $\hat{s}$, ¿qué probabilidad hay, bajo H_0 , de observar algo tan extremo o más? Si $p < \alpha$, se rechaza H_0 .

La distinción **unilateral vs bilateral** solo afecta a la t (la F y la χ^2 son por construcción de una sola cola, la derecha). Las columnas de la Tabla C.1 están etiquetadas con α **unilateral**: para un contraste bilateral al 5 %, hay que leer la columna $\alpha = 0,025$. Como referencia: $t_{\infty, 0,025} = 1,96$ (el famoso valor crítico bilateral al 5 %), y $t_{\infty, 0,05} = 1,645$ (unilateral al 5 %).

C.1. C.1 Valores críticos de la distribución t

La Tabla C.1 da los valores críticos $t_{gl, \alpha}$ tales que $P(T > t_{gl, \alpha}) = \alpha$, con $T \sim t_{gl}$. Para un contraste **bilateral** al nivel α , úsease la columna $\alpha/2$.

```
gl_t <- c(1:30, 40, 60, 90, 120, Inf)
alpha_t <- c(0.10, 0.05, 0.025, 0.01, 0.005, 0.001)

tabla_t <- outer(gl_t, alpha_t, function(g, a) qt(1 - a, df = g))
tabla_t <- as.data.frame(tabla_t)
colnames(tabla_t) <- paste0(" = ", format(alpha_t, decimal.mark = ","))
rownames(tabla_t) <- ifelse(is.infinite(gl_t), "∞", as.character(gl_t))

knitr::kable(
  tabla_t,
```

```

digits = 3,
caption = "Valores críticos de la distribución $t$ (cola derecha, unilateral).",
format.args = list(decimal.mark = ",")
)

```

Table C.1.: Valores críticos de la distribución t (cola derecha, unilateral).

	= 0,100	= 0,050	= 0,025	= 0,010	= 0,005	= 0,001
1	3,078	6,314	12,706	31,821	63,657	318,309
2	1,886	2,920	4,303	6,965	9,925	22,327
3	1,638	2,353	3,182	4,541	5,841	10,215
4	1,533	2,132	2,776	3,747	4,604	7,173
5	1,476	2,015	2,571	3,365	4,032	5,893
6	1,440	1,943	2,447	3,143	3,707	5,208
7	1,415	1,895	2,365	2,998	3,499	4,785
8	1,397	1,860	2,306	2,896	3,355	4,501
9	1,383	1,833	2,262	2,821	3,250	4,297
10	1,372	1,812	2,228	2,764	3,169	4,144
11	1,363	1,796	2,201	2,718	3,106	4,025
12	1,356	1,782	2,179	2,681	3,055	3,930
13	1,350	1,771	2,160	2,650	3,012	3,852
14	1,345	1,761	2,145	2,624	2,977	3,787
15	1,341	1,753	2,131	2,602	2,947	3,733
16	1,337	1,746	2,120	2,583	2,921	3,686
17	1,333	1,740	2,110	2,567	2,898	3,646
18	1,330	1,734	2,101	2,552	2,878	3,610
19	1,328	1,729	2,093	2,539	2,861	3,579
20	1,325	1,725	2,086	2,528	2,845	3,552
21	1,323	1,721	2,080	2,518	2,831	3,527
22	1,321	1,717	2,074	2,508	2,819	3,505
23	1,319	1,714	2,069	2,500	2,807	3,485
24	1,318	1,711	2,064	2,492	2,797	3,467
25	1,316	1,708	2,060	2,485	2,787	3,450
26	1,315	1,706	2,056	2,479	2,779	3,435
27	1,314	1,703	2,052	2,473	2,771	3,421
28	1,313	1,701	2,048	2,467	2,763	3,408
29	1,311	1,699	2,045	2,462	2,756	3,396
30	1,310	1,697	2,042	2,457	2,750	3,385
40	1,303	1,684	2,021	2,423	2,704	3,307
60	1,296	1,671	2,000	2,390	2,660	3,232
90	1,291	1,662	1,987	2,368	2,632	3,183
120	1,289	1,658	1,980	2,358	2,617	3,160
∞	1,282	1,645	1,960	2,326	2,576	3,090

C.2. C.2 Valores críticos de la distribución F

La Tabla C.2 ($\alpha = 0,05$) y la Tabla C.3 ($\alpha = 0,01$) recogen los valores críticos $F_{q_1, q_2, \alpha}$ tales que $P(F > F_{q_1, q_2, \alpha}) = \alpha$, con $F \sim F_{q_1, q_2}$. En las filas, los **grados de libertad del denominador** q_2 ; en las columnas, los del **numerador** q_1 .

```

gl_num <- c(1, 2, 3, 4, 5, 6, 7, 8, 10, 15, 20, 30)
gl_den <- c(10, 15, 20, 25, 30, 40, 60, 120, Inf)

tabla_F_05 <- outer(gl_den, gl_num,
                    function(d, n) qf(0.95, df1 = n, df2 = d))
tabla_F_05 <- as.data.frame(tabla_F_05)
colnames(tabla_F_05) <- as.character(gl_num)
rownames(tabla_F_05) <- ifelse(is.infinite(gl_den), "∞", as.character(gl_den))

knitr::kable(
  tabla_F_05,
  digits = 2,
  caption = "Valores críticos de la  $F$  al 5% ( $\alpha = 0{,}05$ ). Filas: gl denominador",
  format.args = list(decimal.mark = ",")
)

```

Table C.2.: Valores críticos de la F al 5% ($\alpha = 0,05$). Filas: gl denominador; columnas: gl numerador.

	1	2	3	4	5	6	7	8	10	15	20	30
10	4,96	4,10	3,71	3,48	3,33	3,22	3,14	3,07	2,98	2,85	2,77	2,70
15	4,54	3,68	3,29	3,06	2,90	2,79	2,71	2,64	2,54	2,40	2,33	2,25
20	4,35	3,49	3,10	2,87	2,71	2,60	2,51	2,45	2,35	2,20	2,12	2,04
25	4,24	3,39	2,99	2,76	2,60	2,49	2,40	2,34	2,24	2,09	2,01	1,92
30	4,17	3,32	2,92	2,69	2,53	2,42	2,33	2,27	2,16	2,01	1,93	1,84
40	4,08	3,23	2,84	2,61	2,45	2,34	2,25	2,18	2,08	1,92	1,84	1,74
60	4,00	3,15	2,76	2,53	2,37	2,25	2,17	2,10	1,99	1,84	1,75	1,65
120	3,92	3,07	2,68	2,45	2,29	2,18	2,09	2,02	1,91	1,75	1,66	1,55
∞	3,84	3,00	2,60	2,37	2,21	2,10	2,01	1,94	1,83	1,67	1,57	1,46

```

tabla_F_01 <- outer(gl_den, gl_num,
                    function(d, n) qf(0.99, df1 = n, df2 = d))
tabla_F_01 <- as.data.frame(tabla_F_01)
colnames(tabla_F_01) <- as.character(gl_num)
rownames(tabla_F_01) <- ifelse(is.infinite(gl_den), "∞", as.character(gl_den))

knitr::kable(
  tabla_F_01,
  digits = 2,
  caption = "Valores críticos de la  $F$  al 1% ( $\alpha = 0{,}01$ ). Filas: gl denominador",
  format.args = list(decimal.mark = ",")
)

```

Table C.3.: Valores críticos de la F al 1% ($\alpha = 0,01$). Filas: gl denominador; columnas: gl numerador.

	1	2	3	4	5	6	7	8	10	15	20	30
10	10,04	7,56	6,55	5,99	5,64	5,39	5,20	5,06	4,85	4,56	4,41	4,25

	1	2	3	4	5	6	7	8	10	15	20	30
15	8,68	6,36	5,42	4,89	4,56	4,32	4,14	4,00	3,80	3,52	3,37	3,21
20	8,10	5,85	4,94	4,43	4,10	3,87	3,70	3,56	3,37	3,09	2,94	2,78
25	7,77	5,57	4,68	4,18	3,85	3,63	3,46	3,32	3,13	2,85	2,70	2,54
30	7,56	5,39	4,51	4,02	3,70	3,47	3,30	3,17	2,98	2,70	2,55	2,39
40	7,31	5,18	4,31	3,83	3,51	3,29	3,12	2,99	2,80	2,52	2,37	2,20
60	7,08	4,98	4,13	3,65	3,34	3,12	2,95	2,82	2,63	2,35	2,20	2,03
120	6,85	4,79	3,95	3,48	3,17	2,96	2,79	2,66	2,47	2,19	2,03	1,86
∞	6,63	4,61	3,78	3,32	3,02	2,80	2,64	2,51	2,32	2,04	1,88	1,70

i ¿Por qué la F no tiene cola izquierda?

El estadístico F de un contraste de restricciones múltiples se construye como el cociente entre la **mejora del ajuste** al relajar las restricciones y la varianza residual del modelo no restringido. Bajo H_0 , ese cociente debería ser próximo a 1; solo valores **grandes** son evidencia contra H_0 . Por eso los valores críticos viven siempre en la cola derecha.

C.3. C.3 Valores críticos de la χ^2

La Tabla C.4 da los valores críticos $\chi_{\text{gl}, \alpha}^2$ tales que $P(W > \chi_{\text{gl}, \alpha}^2) = \alpha$, con $W \sim \chi_{\text{gl}}^2$. Los contrastes del Capítulo 7 (Breusch–Pagan, White) y del Capítulo 8 (Breusch–Godfrey) emplean estos valores.

```
gl_chi <- c(1:10, 15, 20, 30, 50, 100)
alpha_chi <- c(0.10, 0.05, 0.025, 0.01, 0.005)

tabla_chi <- outer(gl_chi, alpha_chi,
  function(g, a) qchisq(1 - a, df = g))
tabla_chi <- as.data.frame(tabla_chi)
colnames(tabla_chi) <- paste0(" = ", format(alpha_chi, decimal.mark = ","))
rownames(tabla_chi) <- as.character(gl_chi)

knitr::kable(
  tabla_chi,
  digits = 3,
  caption = "Valores críticos de la  $\chi^2$  (cola derecha).",
  format.args = list(decimal.mark = ",")
)
```

Table C.4.: Valores críticos de la χ^2 (cola derecha).

	= 0,100	= 0,050	= 0,025	= 0,010	= 0,005
1	2,706	3,841	5,024	6,635	7,879
2	4,605	5,991	7,378	9,210	10,597
3	6,251	7,815	9,348	11,345	12,838
4	7,779	9,488	11,143	13,277	14,860
5	9,236	11,070	12,833	15,086	16,750

	= 0,100	= 0,050	= 0,025	= 0,010	= 0,005
6	10,645	12,592	14,449	16,812	18,548
7	12,017	14,067	16,013	18,475	20,278
8	13,362	15,507	17,535	20,090	21,955
9	14,684	16,919	19,023	21,666	23,589
10	15,987	18,307	20,483	23,209	25,188
15	22,307	24,996	27,488	30,578	32,801
20	28,412	31,410	34,170	37,566	39,997
30	40,256	43,773	46,979	50,892	53,672
50	63,167	67,505	71,420	76,154	79,490
100	118,498	124,342	129,561	135,807	140,169

C.4. C.4 Cotas de Durbin–Watson

El estadístico de Durbin–Watson d contrasta H_0 : no autocorrelación de primer orden en los errores. Su distribución exacta depende de la matriz de regresoras, por lo que Durbin and Watson (1951) tabularon **cotas** d_L y d_U que delimitan tres regiones: rechazo, no rechazo e inconcluso. La Tabla C.5 reproduce las cotas al 5 % para k' regresores (sin contar la constante) y tamaños muestrales n habituales.

```
dw <- data.frame(
  n = c(15, 20, 25, 30, 40, 50, 75, 100, 150, 200),
  dL_k1 = c(1.08, 1.20, 1.29, 1.35, 1.44, 1.50, 1.60, 1.65, 1.72, 1.76),
  dU_k1 = c(1.36, 1.41, 1.45, 1.49, 1.54, 1.59, 1.65, 1.69, 1.75, 1.78),
  dL_k2 = c(0.95, 1.10, 1.21, 1.28, 1.39, 1.46, 1.57, 1.63, 1.71, 1.75),
  dU_k2 = c(1.54, 1.54, 1.55, 1.57, 1.60, 1.63, 1.68, 1.72, 1.76, 1.79),
  dL_k3 = c(0.82, 1.00, 1.12, 1.21, 1.34, 1.42, 1.54, 1.61, 1.69, 1.74),
  dU_k3 = c(1.75, 1.68, 1.66, 1.65, 1.66, 1.67, 1.71, 1.74, 1.77, 1.80),
  dL_k4 = c(0.69, 0.90, 1.04, 1.14, 1.29, 1.38, 1.51, 1.59, 1.68, 1.73),
  dU_k4 = c(1.97, 1.83, 1.77, 1.74, 1.72, 1.72, 1.74, 1.76, 1.79, 1.81),
  dL_k5 = c(0.56, 0.79, 0.95, 1.07, 1.23, 1.34, 1.49, 1.57, 1.67, 1.72),
  dU_k5 = c(2.21, 1.99, 1.89, 1.83, 1.79, 1.77, 1.77, 1.78, 1.80, 1.82)
)

colnames(dw) <- c(
  "n",
  "k'=1 d_L", "k'=1 d_U",
  "k'=2 d_L", "k'=2 d_U",
  "k'=3 d_L", "k'=3 d_U",
  "k'=4 d_L", "k'=4 d_U",
  "k'=5 d_L", "k'=5 d_U"
)
```

```
knitr::kable(
  dw,
  digits = 2,
  row.names = FALSE,
  caption = "Cotas de Durbin-Watson al 5%\\%$. $k'$: número de regresores excluyendo la con"
```

```
format.args = list(decimal.mark = ",")
)
```

Table C.5.: Cotas de Durbin–Watson al 5 %. k' : número de regresores excluyendo la constante.
Fuente: Durbin and Watson (1951).

n	k'=1 d_L	k'=1 d_U	k'=2 d_L	k'=2 d_U	k'=3 d_L	k'=3 d_U	k'=4 d_L	k'=4 d_U	k'=5 d_L	k'=5 d_U
15	1,08	1,36	0,95	1,54	0,82	1,75	0,69	1,97	0,56	2,21
20	1,20	1,41	1,10	1,54	1,00	1,68	0,90	1,83	0,79	1,99
25	1,29	1,45	1,21	1,55	1,12	1,66	1,04	1,77	0,95	1,89
30	1,35	1,49	1,28	1,57	1,21	1,65	1,14	1,74	1,07	1,83
40	1,44	1,54	1,39	1,60	1,34	1,66	1,29	1,72	1,23	1,79
50	1,50	1,59	1,46	1,63	1,42	1,67	1,38	1,72	1,34	1,77
75	1,60	1,65	1,57	1,68	1,54	1,71	1,51	1,74	1,49	1,77
100	1,65	1,69	1,63	1,72	1,61	1,74	1,59	1,76	1,57	1,78
150	1,72	1,75	1,71	1,76	1,69	1,77	1,68	1,79	1,67	1,80
200	1,76	1,78	1,75	1,79	1,74	1,80	1,73	1,81	1,72	1,82

Regla de decisión del contraste de Durbin–Watson

Sea d el estadístico observado. Las cotas d_L y d_U delimitan cinco regiones:

- $0 < d < d_L$: se **rechaza** H_0 ; evidencia de **autocorrelación positiva**.
- $d_L \leq d \leq d_U$: zona **inconcluyente**; el contraste no decide.
- $d_U < d < 4 - d_U$: **no se rechaza** H_0 ; no hay evidencia de autocorrelación.
- $4 - d_U \leq d \leq 4 - d_L$: zona **inconcluyente**.
- $4 - d_L < d < 4$: se **rechaza** H_0 ; evidencia de **autocorrelación negativa**.

Como referencia, $d = 2$ corresponde exactamente a ausencia de correlación serial muestral. Si el contraste cae en la zona inconcluyente, en el Capítulo 8 se recurre al contraste **Breusch–Godfrey**, que sí da una decisión clara y admite regresoras endógenas retardadas.

Durbin, J., and G. S. Watson. 1951. “Testing for Serial Correlation in Least Squares Regression. II.” *Biometrika* 38 (1–2): 159–78. <https://doi.org/10.2307/2332325>.

Hill, R. Carter, William E. Griffiths, and Guay C. Lim. 2017. *Principles of Econometrics*. 5th ed. Wiley.

White, Halbert. 1980. “A Heteroskedasticity-Consistent Covariance Matrix Estimator and a Direct Test for Heteroskedasticity.” *Econometrica* 48 (4): 817–38. <https://doi.org/10.2307/1912934>.

Wooldridge, Jeffrey M. 2020. *Introductory Econometrics: A Modern Approach*. 7th ed. Cengage Learning.